

UNIVERSIDAD POLITÉCNICA DE MADRID

Máster Universitario en Ingeniería Acústica



TRABAJO FIN DE MÁSTER

**"MODELOS DE INTELIGENCIA ARTIFICIAL PARA LA
DETECCIÓN DE SUPERFICIES EN IMAGEN
ULTRASÓNICA TRIDIMENSIONAL"**

CÉSAR MARCELO LARREA ÁLVAREZ

Septiembre/2024



CAMPUS
DE EXCELENCIA
INTERNACIONAL

Máster Universitario en
Ingeniería Acústica



Trabajo Fin de Máster

Título	Modelos de inteligencia artificial para la detección de superficies en imagen ultrasónica tridimensional	
Autor	César Marcelo Larrea Álvarez	Firma
Tutor/Co-Tutor	Luis Elvira	Firma
Director Externo	Guillermo Cosarinsky	Firma

Tribunal Examinador

Presidente	
Secretario	
Vocal	
Fecha	
Calificación	

Secretario

*Dedicado a mis amados padres,
a mi queridísimo y gran hermano,
por todo, todo, todo el apoyo,
e incondicional confianza que me han brindado,
y también a mi hermosa perrita la "loba",
que le quiero muchísimo*

Agradecimientos

Quiero expresar mi más sincero agradecimiento al Instituto de Tecnologías Físicas y de la Información ITEFI (CSIC), donde llevé a cabo los experimentos y desarrollé todo este trabajo. Su apoyo y facilidades fueron fundamentales para la elaboración de este proyecto. A mi equipo de trabajo, Guillermo Cosarinsky, mi director externo, cuya paciencia, dedicación, conocimiento y esfuerzo permitió encaminar adecuada y sistemáticamente todo el contenido experimental y teórico, a Mario Muñoz y Jorge Camacho, les agradezco profundamente por su cooperación, bondad, conocimientos y colaboración en cada etapa del proceso. A mi director académico Luis Elvira, por su ayuda y apropiado seguimiento. Finalmente, a mi familia, mi mama Rita, mi papa Marco, gracias por su apoyo incondicional, amor, paciencia y aliento constante, significan todo para mi. Mi hermano cuyo esfuerzo me trajo acá, a seguir intentando salir adelante, sin su apoyo y empuje no me hubiera atrevido a esta travesía. Su presencia y motivación fueron un pilar fundamental durante este camino.

Resumen

En el campo de la Evaluación No Destructiva (END), la detección precisa de ecos provenientes de superficies es crucial para evaluar la integridad de los materiales. Esta tesis explora la aplicación de una Red Neuronal Convolucional (RNC) basada en una arquitectura originalmente desarrollada para manejar imágenes médicas en 3D, adaptada aquí para procesar datos ultrasónicos adquiridos mediante la técnica Full Matrix Capture (FMC). La arquitectura del modelo RNC fue definida utilizando un algoritmo de optimización de hiperparámetros conocido como Hyperband, lo que mejoró la eficiencia y el rendimiento del proceso de entrenamiento. Los resultados de la RNC se compararon con técnicas convencionales como el cruce de umbral, la técnica de Promedio a Corto Plazo/Promedio a Largo Plazo (STA/LTA) y el filtro de correlación. Estos métodos tradicionales de detección de tiempos de llegada, adaptados de campos como la sismología, han mostrado limitaciones, especialmente en la generación de valores atípicos y la precisión en la detección. La RNC fue entrenada utilizando datos teóricos de Tiempo de Vuelo (TOF), generados automáticamente durante el proceso de adquisición, automatizando la fase de etiquetado que generalmente se realiza manualmente. El conjunto de datos incluye señales ultrasónicas adquiridas mediante ensayos por inmersión de piezas con geometrías simples como superficies planas, cilindros y esferas, que son representativas de escenarios reales en aplicaciones de END. Los resultados demuestran el mejor desempeño de la RNC en la reducción de valores atípicos y en la mejora de la confiabilidad en la detección. El trabajo futuro se centrará en extender la aplicación del modelo a geometrías más complejas y evaluar su capacidad para generalizar a morfologías más intrincadas. Este estudio destaca el potencial del aprendizaje profundo para mejorar la eficiencia y precisión en el procesamiento de señales ultrasónicas en aplicaciones de END.

Abstract

In the field of Non-Destructive Evaluation (NDE), accurate detection of echoes from surfaces is crucial for assessing material integrity. This thesis explores the application of a Convolutional Neural Network (CNN) based on an architecture originally developed to handle 3D medical images, adapted here to process ultrasound data acquired through a Full Matrix Capture (FMC) approach. The CNN architecture was defined using a hyperparameter optimization algorithm known as Hyperband, which enhanced the efficiency and performance of the training process. The CNNs results were compared against conventional techniques such as threshold crossing, the Short-Term Average/Long-Term Average (STA/LTA) method, and matched filtering. These traditional time-of-arrival detection methods, adapted from fields like seismology, have shown limitations, particularly in terms of outlier generation and detection accuracy. The CNN was trained using theoretical Time-of-Flight (TOF) data generated automatically during the acquisition process, automating the labeling stage typically performed manually. The dataset comprises ultrasonic signals acquired via immersion testing applied to simple geometries such as flat surfaces, cylinders, and spheres, which are representative of real scenarios in NDE applications. The results demonstrate the superior performance of the CNN in reducing outliers and improving detection reliability. Future work will focus on extending the models application to more complex geometries and evaluating its ability to generalize to more intricate morphologies. This study underscores the potential of deep learning to enhance the efficiency and accuracy of ultrasonic signal processing in NDE applications.

Índice

Agradecimientos	iii
Resumen	v
Abstract	vii
Lista de Acrónimos	xiii
1 Introducción	1
1.1 Planteamiento del Trabajo	1
1.2 Objetivos	4
2 Fundamentos Teóricos	5
2.1 Introducción a Evaluación No Destructiva	6
2.1.1 Definición e Importancia	6
2.1.2 Antecedentes Históricos	7
2.1.3 Principios y Técnicas de la END	10
2.2 Ultrasonidos en END	10
2.2.1 Técnicas de Evaluación	11
Técnica de Pulso-Eco (incidencia normal y oblicua)	12
Técnica Pitch-Catch	12
Técnica basada en Inmersión	12
Técnica de Phased Array (PA)	13
2.2.2 Representación Visual de Escaneo Ultrasónico	14
A-Scan	14
B-scan	15
C-scan	16
D-scan	16
2.2.3 Imágenes mediante múltiples elementos (Phased-Array)	16

Método de imagen Phased-Array (PA)	19
Total Focusing Method (TFM)	20
Imagen de Onda Plana	20
2.3 Aprendizaje Profundo en END	21
2.3.1 Redes Neuronales Convolucionales (RNC) en END	23
Fundamentos de las RNCs	23
Arquitectura V-Net	27
3 Descripción Experimental	31
3.1 Configuración del ensayo	31
3.1.1 Materiales y métodos	31
3.1.2 Configuración del Sistema	38
Configuración inicial	40
Ajuste del Centro del Transductor	41
Alineamiento (Paralelismo) del transductor con respecto al sistema de referencia base	47
3.2 Adquisición de Datos	54
3.2.1 Estimación de Δz	55
3.2.2 Plano Rectangular	56
3.2.3 Cilindro 1 y 2 (35 y 12 mm)	62
3.2.4 Cilindro 3 y 4 (25 y 40 mm)	66
3.2.5 Esfera	70
3.2.6 Plano Fibra de carbono	73
3.2.7 Adquisiciones en distancias cercanas a la pieza	74
3.3 Red Neuronal Convolutional	75
3.3.1 Implementación de arquitectura de la red	75
Hiperparámetros	75
Optimización de Hiperparámetros	77
Definiendo Ground Truth	78
Definiendo métricas de evaluación de red	78
Criterio de selección de la arquitectura de red	80
Entrenamiento y Prueba	81

ÍNDICE

4 Resultados y Conclusiones	83
4.1 Resultados	83
4.1.1 Optimización de hiperparámetros	83
4.1.2 Resultados de Prueba	85
Cruce de umbral vs Red	86
STA/LTA vs Red	87
Filtro adaptado vs Red	89
Evaluación estadística de los resultados	90
4.2 Conclusiones y Discusión	92
4.2.1 Conclusiones	92
4.2.2 Discusión	93
Bibliografía	98

Lista de Acrónimos

AM	Aprendizaje de Máquina.
AP	Aprendizaje Profundo.
ASNT	Sociedad Americana de Pruebas No Destructivas.
EA	Emisión Acústica.
END	Evaluación No Destructiva.
FMC	Full Matrix Capture.
GT	Ground Truth.
IA	Inteligencia Artificial.
IOP	Imagen de Onda Plana.
PA	Phased Array.
PCH	Punto Central de la Herramienta.
ReLU	Unidad de Rectificación Lineal.
RNC	Red Neuronal Convolucional.
RSR	Relación Señal Ruido.
SVM	Support Vector Machine.
TDA	Tiempo de Arrivo.
TDV	Tiempo de Vuelo.
TFM	Total Focusing Method.

Índice de figuras

2.1	Vagón de inspección Sperry, versión temprana	8
2.2	Unidad ultrasónica temprana de Sperry	9
2.3	Transductor monolítico y sus componentes principales	11
2.4	Sistema Phased Array	13
2.5	Detección de grietas mediante sondas mono-cristal y multielemento	13
2.6	Ejes principales de sondeo en adquisición ultrasónica	14
2.7	A-scan	15
2.8	Vistas lateral, superior y trasera (B-scan, C-scan, D-scan)	15
2.9	Ejemplo B-scan	16
2.10	Ejemplo C-scan	17
2.11	Ejemplo de haz colimado	18
2.12	Arreglo lineal	19
2.13	Arreglo matricial	19
2.14	Ilustración de convolución en capa convolucional	24
2.15	Tipos de submuestreo	25
2.16	Arquitectura general de autocodificador	26
2.17	Ejemplo de máscara de segmentación	27
3.1	Piezas de referencia	32
3.2	Transductor matricial Imasonic: esquema y fotografía	33
3.3	Brazo robot colaborativo UR10e	35
3.4	GUI 1	36
3.5	GUI 2	38
3.6	GUI 3	39
3.7	Posición de Punto Central de Herramienta (PCH)	41
3.8	Alineamiento del PCH al centro del transductor	42
3.9	Esquema del procedimiento para obtener Δ_z	44

3.10	Esquema del procedimiento para obtener ΔTDV^*	46
3.11	Ajuste del modelo con respecto a las mediciones experimentales	47
3.12	Alineamiento paralelo: Esquema de exploración inicial y $\Delta TDV(\theta_x, \theta_y)$	49
3.13	Alineamiento paralelo: Esquema de exploración final y $\Delta TDV(\theta_x, \theta_y)$	50
3.14	Alineamiento paralelo: Esquema de exploración en componente- z	51
3.15	Alineamiento paralelo: Esquema de exploración en componente- z	52
3.16	Alineamiento paralelo: Esquema de exploración en componente- z	52
3.17	Cubo de inmersión para piezas de referencia en proceso de adquisición de datos	54
3.18	Estimación de Δz para TDVs teóricos	55
3.19	Evaluación de alineamiento transductor-plano en GUI 1	57
3.20	Geometría de la ley de reflexión (imagen especular)	58
3.21	Posición de componente z con respecto a plano de referencia	59
3.22	Ejemplo de adquisición y sus respectivos TDVs teóricos	61
3.23	Esquema de posicionamiento del cilindro para la etapa de adquisición	62
3.24	Evaluación de alineamiento transductor-cilindro1 en GUI 1	63
3.25	Posición de componente z con respecto a plano de referencia (cilindro 1 y 2)	64
3.26	Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 1 y 2	64
3.27	Esquema de posicionamiento de cilindros en configuración cóncava y convexa para la etapa de adquisición	66
3.28	Evaluación de alineamiento: a) transductor-cilindro 4 (cóncavo); b) transductor-cilindro 3 (convexo) en GUI 1	67
3.29	Posición de componente z con respecto a plano de referencia: cilindro 3 convexo	68
3.30	Posición de componente z con respecto a plano de referencia: cilindro 4 cóncavo	68
3.31	Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 3 (convexo)	69
3.32	Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 4 (cóncavo)	69
3.33	Esquema de posicionamiento de esfera para la etapa de adquisición	71
3.34	Evaluación de alineamiento transductor-esfera 3 en GUI 1	71

ÍNDICE DE FIGURAS

3.35 Posición de componente z con respecto a plano de referencia: esfera	72
3.36 Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 4 (cóncavo)	72
3.37 Evaluación de alineamiento transductor-plano 2 en GUI 1	73
3.38 Ejemplo de adquisición y sus respectivos TDVs teóricos, caso plano fibra de carbono	74
3.39 Ejemplo de <i>Ground Truth</i>	79
4.1 Exploración <i>Hyperband</i> : configuraciones de hiperparámetros	84
4.2 Optimización hiperparámetros: Exploración final	84
4.3 Esquema final de la red neuronal propuesta	85
4.4 Comparación cruce de umbral vs Red propuesta	86
4.5 Comparación cruce de STA/LTA(10,100) vs Red propuesta	87
4.6 Comparación cruce de STA/LTA(10,50) vs Red propuesta	88
4.7 Comparación cruce de filtro adaptado vs red propuesta	89
4.8 Resutados de estadística descriptiva	90
4.9 Histogramas de comparación	91

Índice de tablas

3.1 Piezas de referencia y sus características	32
3.2 Entrenamiento y prueba: distribución de piezas	81
4.1 Hiperparámetros Óptimos	85

Índice de Ecuaciones

2.1	Cálculo de tiempo de vuelo (TDV)	18
2.2	Retraso y suma para conformación de haces en recepción	19
2.3	Amplitud de imagen para método de enfoque total	20
2.4	Amplitud de imagen para método de enfoque total	20
2.5	Ley focal para retraso uniforme con inclinación θ en IOP	21
2.6	Expresión matemática genral de convolución	24
2.7	Cómputo de pesos en retroapropagación	26
3.1	Vector de rotación	41
3.2	Cálculo de Δ_{TDV}	43
3.3	Δ_z como función de coordenadas iniciales de PCH y rotaciones aplicadas .	44
3.4	Rotación combinada en (θ_x, θ_y)	45
3.5	Transformación de coordenadas x_0, y_0, z_0	45
3.6	Cálculo de Δ_z	45
3.7	Cálculo de ΔTDV^*	45
3.8	Cálculo de residuos ponderados para alineamiento de elemento central del arreglo	45
3.9	Cálculo de corrección de PCH	47
3.10	Alineamiento paralelo: diferencia en TDVs por cada par de orientaciones $(\theta_x$ y $\theta_y)$	48
3.11	Alineamiento paralelo: orientación $(\theta_x$ y $\theta_y)$ óptima	48
3.12	Composición de rotaciones para definir ángulos de PCH final	53
3.13	Cálculo Δz	56
3.14	Cálculo de TDV en función del vector $\overline{EE^*}$	58
3.15	Vector homogéneo de elemento emisor	59
3.16	Matriz homogénea de elementos receptores	60
3.17	Vector homogéneo de elemento emisor	60

3.18 Matriz roto-traslación T	60
3.19 Rotación y traslación de elemento emisor	60
3.20 Rotación y traslación de elementos receptores	60
3.21 Cómputo de <i>Ground Truth</i>	78
3.22 métrica 2: número de valores atípicos	80
3.23 métrica 3: error de índice	80

Capítulo 1

Introducción

1.1. Planteamiento del Trabajo

En la práctica de Evaluación No Destructiva (END), dentro de las técnicas basadas en ultrasonidos, los transductores de arreglo matricial ofrecen un gran potencial debido a la versatilidad que ofrecen en la detección de fallas y en los métodos de generación de imagen, ya que permiten el direccionamiento y enfoque del haz en todas las direcciones espaciales [1, 2, 3]. Debido al desajuste de impedancias entre aire y sólidos, la técnica ultrasónica, por lo general, se la ejecuta en ensayos de inmersión, es decir, tanto el transductor como la pieza a evaluar se sumergen en agua para conseguir condiciones de acoplamiento adecuadas. El método de inmersión es particularmente útil al inspeccionar geometrías complejas, ya que el medio líquido permite a las ondas ultrasónicas adaptarse con mayor facilidad a la forma de la pieza [4]. No obstante, el efecto de refracción de las ondas entre el medio acoplante (agua) y el objeto de prueba imponen ciertas restricciones sobre el cálculo de leyes focales para la conformación de haces en emisión y recepción, específicamente, es necesario conocer con alta precisión, la localización y orientación del transductor con respecto a la pieza evaluada, y la forma de la superficie de la pieza. Esto impulsó el desarrollo de algoritmos denominados de *auto-enfoque*, es decir, el ajuste automático de parámetros focales a partir de datos recolectados [5, 6, 7]. Dichos ajustes requieren de la detección y estimación de la geometría del objeto. Para ello existen dos tipos de algoritmo: **1)** aquellos basados en el método Total Focusing Method (TFM); y **2)** aquellos que nos conciernen más en este trabajo, los algoritmos basados en detección de Tiempo de Vuelo

(TDV), es decir, el tiempo que le toma a la señal emitida llegar a una superficie, reflejarse y ser detectada. Estos últimos requerirán, por lo tanto, métodos robustos de medición de TDVs.

Para medir TDVs, se debe detectar el primer eco contenido en la señal reflejada por la superficie de la pieza. Entre **las técnicas convencionales**, el método más común para cuantificar este tiempo de llegada es la prueba de **Cruce de Umbral**¹. Esta técnica consiste en definir un nivel límite, de tal manera que cuando la amplitud rectificada del eco de reflexión supere dicho límite, el tiempo de cruce asociado corresponderá al tiempo de vuelo medido. A pesar de la efectividad del método, debido a su simplicidad, esta puede verse comprometida, principalmente por la detección de falsos positivos, es decir, existen posibles fuentes que generarán pulsos que arribarán con anterioridad al pulso asociado al eco de interés. Entre las posibles fuentes se pueden nombrar al generador de pulsos², cuyo efecto puede ser detectado, y mal registrado como TDV. Otro error puede darse por pulsos provenientes de burbujas en el agua, por ondas de superficie que se propagan desde el elemento emisor, a través de la superficie del transductor, entre otras. Todas estas señales son consideradas valores atípicos (*outliers*) en el desempeño del método de detección de ecos.

Otra técnica de detección convencional es la denominada técnica de **Filtro Adaptado**³, técnica clásica en procesamiento de señales, que utiliza un filtro lineal con una función de transferencia que maximiza la Relación Señal Ruido (RSR) de salida de una señal de entrada con propiedades conocidas [8], con el fin de detectar una señal plantilla, o de referencia, a partir de una señal no conocida, al correlacionarlas. Este tipo de método, aunque presenta una considerable habilidad anti-ruido, no es lo suficientemente robusto a diferencias de forma entre la señal objetivo y la señal de referencia [9], lo que, en el contexto de detección de ecos genera valores atípicos en los tiempos de vuelo estimados. Otro método habitual de detección es el algoritmo **STA/LTA**⁴, diseñado para detectar cambios repentinos en la amplitud de una señal, que a menudo indican el inicio de un evento. El principio básico de STA/LTA es comparar la amplitud promedio de una señal durante

¹Threshold Crossing technique

²Componente en la circuitería del transductor encargado de excitar a los elementos individuales para generar las señales ultrasónicas

³Matched Filter technique

⁴Short-Time-Average/Long-Time-Average trigger

1.1. PLANTEAMIENTO DEL TRABAJO

una ventana de tiempo corta (STA) con la amplitud promedio durante una ventana de tiempo más larga (LTA). Cuando la relación entre STA y LTA supera un cierto umbral, el algoritmo sugiere que se ha producido un evento, como el inicio de una onda sísmica o una reflexión ultrasónica de un defecto [10]. En sismología, el uso del algoritmo STA/LTA es muy usual para detectar el inicio de ondas sísmicas, que son indicativas de terremotos u otros eventos del subsuelo. Este se implementa en sistemas de monitoreo sísmico para automatizar la detección de ondas P (ondas primarias) y ondas S (ondas secundarias) [11]. No obstante, a pesar de sus fortalezas, como se reporta en [12], la técnica se desempeña pobremente con una RSR baja, y en condiciones de estructuras geológicas complejas cercanas a la superficie. Esto puede manifestarse, en el contexto de END, en mediciones incorrectas de tiempos de vuelo, comprometiendo la caracterización de la superficie del objeto evaluado.

Es en este punto donde entran en juego las capacidades de algoritmos de aprendizaje de máquina y aprendizaje profundo en categorización y segmentación de imágenes al aplicarse en la detección de señales, ya que son altamente efectivos en analizar patrones temporales y espaciales en los datos. En especial, se ha explorado el desempeño de redes neuronales en automatizar procedimientos que involucran gran cantidad de información, requieren la experiencia de técnicos, y son propensos a generar falsos positivos [9]. Por ejemplo, métodos tradicionales como STA/LTA emplean configuraciones predefinidas para ventanas de tiempo y umbrales, que pueden necesitar ajustes según el tipo de material o el nivel de ruido. Una Red Neuronal Convolucional (RNC), por otro lado, puede aprender estas características directamente de los datos de entrenamiento, lo que hace que el proceso sea más adaptativo y robusto [12, 13].

Para concluir, un aspecto relevante que se considera en este trabajo es definir el cálculo de los tiempos de vuelo teóricos como el etiquetado a partir del cual se entrenarán las redes. Los algoritmos de aprendizaje profundo requieren que el conjunto de datos de entrenamiento se etiqueten con información que represente el resultado verdadero que se desea predecir, es decir, se debe definir adecuadamente qué aspecto de los datos es lo que el sistema debe ser capaz de aprender, y esta información se la conoce como el *Ground Truth* (GT) de dichos datos. Para asignar las etiquetas apropiadas a las señales ultrasónicas adquiridas, en este trabajo se utilizaron modelos físicos específicos para el

cálculo de sus correspondientes TDVs, a partir de los cuales quedará definido el GT. Estos cálculos teóricos se los realiza a partir de la geometría de la pieza bajo evaluación, y conociendo la posición y orientación del transductor con respecto a la misma, como se detalla en [6].

1.2. Objetivos

El objeto de este trabajo de fin de máster consiste en llevar acabo una comparación del desempeño de tres distintos métodos de detección de TDVs convencionales (cruce de umbral, filtro adaptado, y STA/LTA), y una arquitectura de redes neuronales convolucionales, específicamente diseñada para esta tarea.

Para lograr este objetivo, se identifican una serie de objetivos secundarios:

- La configuración del sistema experimental para la adquisición de datos de entrenamiento a emplear para la detección de superficie mediante redes neuronales.
- La adquisición, procesado y etiquetado de datos a partir de piezas representativas.
- La investigación sobre redes neuronales convolucionales adaptadas al problema, y su entrenamiento con el juego de datos obtenidos.
- Explorar distintas configuraciones de parámetros para la optimización de modelos RNC.
- Implementar y aplicar los métodos convencionales para los datos adquiridos.

Capítulo 2

Fundamentos Teóricos

En los siguientes apartados se presentarán los fundamentos teóricos relevantes para comprender el contenido del presente trabajo. Se ha decidido dividir la exposición en 3 temas generales: 1) Métodos de evaluación no destructiva (END); 2) principios teóricos de ultrasonidos; y 3) técnicas de aprendizaje de máquina (con especial énfasis en redes neuronales)

Por lo tanto, para proporcionar un marco comprensivo, cada sección abordará el corpus conceptual relacionado con cada uno de estos temas. En primer lugar, se explorarán los métodos de evaluación no destructiva (END), fundamentales para la inspección y análisis de materiales sin causar daños. A continuación, se describirán los principios teóricos de los ultrasonidos, que son esenciales para entender su aplicación en diversas áreas científicas y tecnológicas. Finalmente, se examinarán las técnicas de aprendizaje automático, destacando las redes neuronales debido a su relevancia y potencial en la resolución de problemas complejos.

Estas secciones no solo ofrecerán una visión detallada de los conceptos teóricos, sino que también proporcionarán el contexto necesario para aplicar estos conocimientos en el desarrollo y análisis del presente trabajo. Con esta estructura, se espera facilitar una comprensión integral y coherente de los temas abordados.

2.1. Introducción a Evaluación No Destructiva

En términos generales, la práctica de evaluación no destructiva se emplea para verificar la integridad y fiabilidad de un producto, máquina o estructura. Son ensayos que se realizan como control de calidad en plantas de producción. Sin END, la seguridad y la fiabilidad de los componentes pueden verse significativamente comprometidas. Esto subraya la importancia crítica de END en la prevención de incidentes catastróficos como accidentes de aviones y trenes, fugas y explosiones de tuberías, fallos de reactores nucleares y desastres marítimos.

2.1.1. Definición e Importancia

El principio básico de la END es simple. Determinar la calidad e integridad de un objeto, sin influenciar destrutivamente su estructura y composición. Aunque la técnica no garantiza realmente la no ocurrencia de fallos, desempeña un papel importante al minimizar las posibilidades de fallo. Otros factores, como un diseño inadecuado y una aplicación incorrecta del objeto, pueden contribuir a los fallos incluso cuando la END se aplica correctamente. En la industria la END puede efectivamente aplicarse al: 1) examen de materias primas previo a su procesamiento; 2) proceso de control de materiales durante procesamiento; 3) examen de producto finales; y 4) seguimiento de evaluación de productos ya en servicio [14].

El proceso de END viene dictado por el caso específico de uso, que impone requerimientos en el método y procedimiento. Teniendo en cuenta, por ejemplo, una de las áreas con mayor relación con las tecnologías END, los procesos de control de calidad, el enfoque suele dividirse en: a) *control en retroalimentación*, donde el proceso es monitoreado por el sensor, el cual retorna la información adquirida al módulo de control que, en base a dicha información, modifica las variables necesarias para mantener la producción dentro de los límites predeterminados; y b) un criterio de control de calidad *de aceptación/rechazo*. Aquí la técnica END examina productos ya finalizados. Si la inspección da visto bueno al producto, este retorna a su función o tarea. De ser rechazado por el criterio, el producto es entonces reciclado o desecharido. En base a esto es necesario señalar el componente económico en la decisión de aplicar la técnica END en el proceso de control. Si el proceso es muy costoso de producir, la exploración no destructiva se vuelve necesaria. Estos son

2.1. INTRODUCCIÓN A EVALUACIÓN NO DESTRUCTIVA

los casos de industrias donde el fallo en un único componente puede causar resultados catastróficos, es decir, componentes de *seguridad crítica*. Por estas razones, la industria aérea y de energía, así como el gobierno mantienen amplios programas de evaluación no destructiva. A menudo, estas inspecciones son exigidas por regulaciones federales, por ejemplo en el caso de los EE.UU. [15].

Otro aspecto imperativo en el proceso de END, y que depende de un criterio económico y de supervisión regulatoria, es la decisión de si inspeccionar el 100 % de una parte de la estructura, o si inspeccionar o no todas las piezas o un subconjunto representativo. Para evaluar el alcance de evaluación necesaria, programas END exitosos emplean criterios estadísticos, por ejemplo, basados en el análisis de *mecánica de fracturas*, que combina condiciones de carga, propiedades de los materiales y mecánica de los materiales [15]. Con respecto a los llamados componentes de *seguridad-crítica*, estos reciben procesos de control de calidad más rigurosos, y en este contexto se han elaborado técnicas END categorizadas en dos enfoques: a) métodos de *Retiro-por-causa*, donde, en lugar de que los componentes sean retirados posterior a su lapso de vida predeterminado, estos son separados, solamente en el caso de haber detectado una falla mediante técnicas END; y b) métodos de *Inspección-basada-en-riesgos*, en los que el alcance de la inspección se determina en base a la probabilidad de falla y a los riesgos asociados a dicha falla. Es un procedimiento en donde la probabilidad de falla de un componente se pondera en términos de las consecuencias de dicho desperfecto, y en base a esta valoración se le asigna al componente un valor que indica la frecuencia y el alcance de la inspección END requerida. Aplicar este criterio de inspección puede reducir considerablemente el alcance de evaluación en las estructuras, lo que se traduce a un decremento en los gastos necesarios.

2.1.2. Antecedentes Históricos

En [14], el autor expone el desarrollo histórico de las técnicas de END. En esta sección se presenta entonces una descripción sucinta del planteamiento del autor.

Se puede partir de la siguiente aseveración: "*El esfuerzo por detectar e identificar defectos pequeños en estructuras continuará hasta que ya no sea posible vincular fallas catastróficas con imperfecciones del material en cuestión*". Para la referencia mencionada, tales

coyunturas catastróficas consistieron en, principalmente, los esfuerzos bélicos impuestos durante la segunda guerra mundial. Sin embargo, se alude también a una contingencia desastrosa en la industria de las calderas, un accidente determinante (en 1854 Hartford Connecticut) para la implementación de una ley de inspección de calderas, que exhortaba regulaciones frecuentes de seguridad en la fabricación y manejo de estos equipos. Se considera entonces esto como un momento crucial en el desarrollo de la evaluación de estructuras, especialmente de las técnicas de END.



Figura 2.1: Vagón de inspección Sperry, versión temprana (tomado de [15])

El siguiente desarrollo clave mencionado en [14], se debe a otra catástrofe, el trágico descarrilamiento de un tren, que, como consecuencia, dio lugar al primer sistema de *Inducción de corriente eléctrica / Detección de campo magnético*, desarrollado por el Dr. Elmer Sperry y H. C. Drake (Figura 2.1), que tenía como fin inspeccionar y identificar posible discontinuidades en las vías del tren. De esta manera, ya para 1929 se empieza a promover el uso de principios magnéticos para aplicaciones industriales de END. Para la década de 1930, con significativo aporte del Dr. Robert F. Mehl, el uso de radiografía basada en rayos gamma empieza a tomar momentum como alternativa a la tecnología basada en rayos X. Sin embargo, en la década de 1940, hubo avances notables en el campo de la radiografía industrial. General Electric introdujo las primeras máquinas de rayos X de un millón de voltios, lo que permitió la inspección de secciones de material más gruesas gracias a los niveles de energía más altos. Además, a pesar de que los principios fundamentales de la técnica de *Ensayo por Corrientes de Foucault* se remonta a 1831 con Michael Faraday, es en los 1940s donde ésta alcanza su mayor potencial (mediada por la

2.1. INTRODUCCIÓN A EVALUACIÓN NO DESTRUCTIVA

segunda guerra mundial) en el desarrollo de instrumentos capaces de medir el espesor de un material.

Por otro lado, en la época de 1950 se reporta el primer estudio extensivo del fenómeno conocido como Ensayo por Emisión Acústica (EA) por el Dr. Joseph Kaiser. Aquí se demuestra que los eventos de emisión acústica por materiales eran causados por pequeñas fallas en un material que estaba siendo sometido a estrés. Hoy en día la mayor parte de la monitorización de emisión acústica se realiza en frecuencias muy altas o ultrasónicas. Esta técnica ha crecido significativamente y este método se ha convertido en una valiosa técnica END para determinar la condición, el comportamiento y las características en servicio de muchos materiales y estructuras.

Emplear ondas ultrasónicas para detectar discontinuidades en materiales, es una actividad introducida también en la década de 1940. En la figura 2.2 se muestra un reflectoscopio supersónico, considerado un avance tecnológico significativo en la historia de la inspección ultrasónica. Diseñado por el Dr. Floyd Firestone, el reflectoscopio supersónico funciona basándose en la emisión y recepción de ondas ultrasónicas. Estas ondas son enviadas a través de un material, y cualquier discontinuidad o defecto en el material (como grietas, poros o inclusiones) reflejará las ondas de regreso al dispositivo. Al analizar las ondas reflejadas, se pueden identificar y localizar estos defectos.



Figura 2.2: Unidad ultrasónica temprana de Sperry (tomado de [15])

2.1.3. Principios y Técnicas de la END

El avance científico y tecnológico de los ensayos no destructivos (END) de materiales se basa en la integración interdisciplinaria de diversos métodos científicos y de ingeniería complementarios. Además de la física, la ciencia de materiales es fundamental. El desarrollo de sistemas de ensayo requiere también tecnología de manipulación y robótica, hardware electrónico, informática y software, así como algoritmos matemáticos para la simulación numérica [16].

La Sociedad Americana de Pruebas No Destructivas (ASNT) define la evaluación no destructiva como la inspección de un objeto utilizando una tecnología que no afecte su utilidad futura. Existen diversos métodos de evaluación (Ensayo por Corrientes de Foucault, Ensayo-Radiográfico, Ensayo con Partículas Magnéticas, Ensayo por Líquidos Penetran tes, Evaluación de emisión acústica, Prueba Térmica Infrarroja [17]). En este trabajo se utilizan los ultrasonidos como técnica END.

2.2. Ultrasonidos en END

Las técnicas de ensayo ultrasónico son relativamente sencillas, altamente sensibles y eficientes en consumo de tiempo, por lo que se han aprobado para su uso en diversos ámbitos como el ensayo de materiales compuestos, la industria aeroespacial, automotriz y de transporte. El sistema de inspección ultrasónica común consta de tres componentes esenciales, una fuente, una muestra y un receptor, donde la fuente genera la señal ultrasónica, que llega a la muestra y la señal de reflección es cuantificada por el receptor [18]. En general, teniendo en cuenta un único transductor, al cambiar su posición y/o orientación, se puede obtener una serie de señales medidas que ayudan a determinar las propiedades del objeto bajo evaluación. De hecho, con suficiente información obtenida en dicho movimiento mecánico del transductor, incluso se puede sintetizar una imagen ultrasónica de la muestra. Sin embargo, el escaneo mecánico es lento y costoso de realizar en la configuración de transductor de elemento único. Un enfoque más efectivo para realizar inspecciones y formar imágenes es usar un arreglo ultrasónico, un *phased-array*¹, donde el haz de sonido

¹En el resto del documento se referirá al sistema en cuestión con su término en inglés, ya que en la comunidad dedicada a ultrasonidos es común utilizar dicho vocablo

puede ser manipulado electrónicamente.

Para entender como funciona un *phased array* ayuda primero comprender el comportamiento convencional de transductores monolíticos. La configuración más simple consiste en 4 componentes: 1) elemento piezo-cerámico; 2) amortiguador (backing); 3) capa de adaptación; y 4) ensamblaje de cables (Ver figura 2.3). En el sistema se genera un pulso que excita el elemento piezoelectrónico. Este convierte energía eléctrica en mecánica, que se manifiesta como un onda acústica que se propaga en el medio (rectángulo gris en la figura 2.3, izquierda). De igual manera al recibir las ondas reflejadas el sistema genera información eléctrica que permite digitalizarla y post-procesarla. A partir de esta configuración se pueden determinar distintos métodos convencionales de evaluación y de técnicas de imagen ultrasónica.

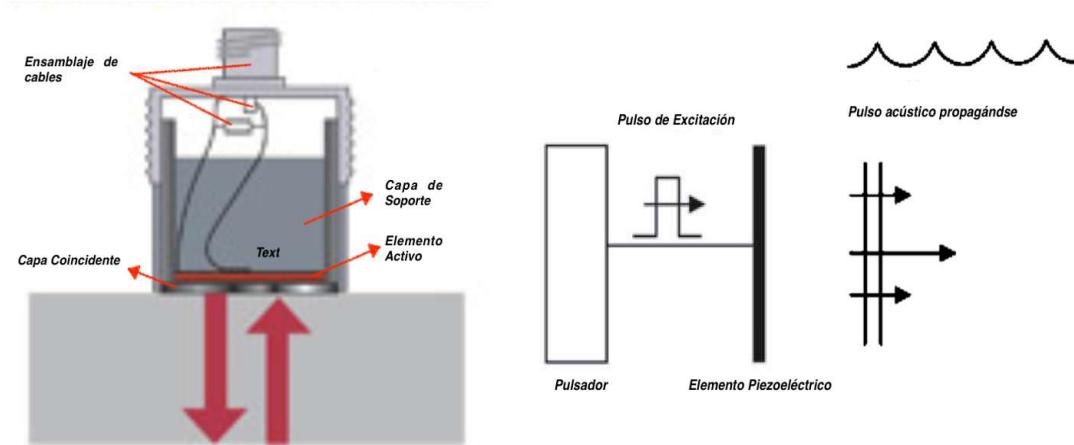


Figura 2.3: Transductor monolítico y sus componentes principales

2.2.1. Técnicas de Evaluación

Las formas en que las ondas sonoras se propagan a través de los materiales y cómo se atenúan, reflejan o transmiten, determinan las diferentes técnicas de ultrasonido utilizadas para detectar los diversos tipos de discontinuidades que pueden existir en los materiales. Se detallan a continuación las técnicas convencionales en END ultrasónica relevantes para este documento.

Técnica de Pulso-Eco (incidencia normal y oblicua)

Técnica utilizada mediante un único transductor, dispuesto a lo largo de la superficie de la pieza, y que actúa tanto como emisor y como receptor. La ubicación y el tamaño del defecto se lo determina mediante amplitud el tiempo de vuelo (TDV). La ubicación o profundidad de la imperfección se la infiere apartir del tiempo de vuelo, que es el tiempo que le toma al pulso viajar desde el tranductor a la falla y retornar. Por otro lado, la amplitud del eco detectado, suministra datos sobre el tamaño de la falla, ya que mayores imperfecciones reflejarán con mayor intensidad que fallas de menor extensión. En configuración de incidencia normal, el método es más sensible a fallas que yacen paralelas a la superficie, como la delaminación [19]. Por otro lado, la incidencia oblicua optimiza la sensibilidad a ciertos tipos de fallas con posicionamiento perpendicular a la superficie de la pieza [20, 21].

Técnica Pitch-Catch

La técnica *Pitch-Catch*² consiste en que un transductor emite el pulso y otro distinto lo recibe. Necesariamente involucra emisores y receptores separados, donde el receptor puede ubicarse en una posición contigua u opuesta al emisor (posición con respecto al espécimen de evaluación). Fallos en la estructura con perfiles más ocultos para el método de pulso-eco resultan más sensibles a esta técnica [18]. Se han propuesto configuraciones que mejoran la efectividad de las evaluaciones, por ejemplo, la combinación de pitch-catch con incidencia oblicua en [22].

Técnica basada en Inmersión

Debido a la desadaptación de impedancias entre medios sólidos y aire, resulta necesario sumergir la pieza bajo evaluación en un acoplante líquido (agua, gel o grasa). En estudios comparativos se ha demostrado una mayor efectividad de este método (con respecto al método de contacto) en mediciones de espesor y en la precisión de escaneo lograda, en términos de una considerable reducción en la dispersión de ondas generada [23].

²En el resto del documento se referirá a la técnica en cuestión con su término en inglés, ya que en la comunidad dedicada a ultrasonidos es común utilizar dicho vocablo

Técnica de Phased Array (PA)

Un sistema phased array está compuesto por pequeños elementos piezoelectricos, donde cada uno puede ser separadamente excitado, y su respuesta independientemente recibida, lo que proporciona la posibilidad de manipular el haz ultrasónico en términos de su ángulo y distancia focal [24, 25]. Ver figura 2.4

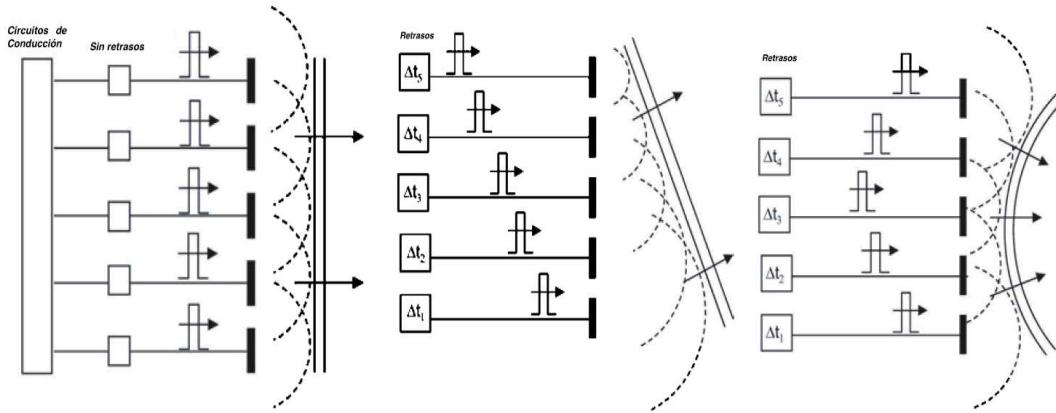


Figura 2.4: Sistema Phased Array: Pulsos de cada elemento llegan al unísono (izquierda); Una configuración de retrasos permite dirigir el haz (centro); Otra configuración de retrasos permite enfocar el haz (derecha). Modificado de [24]

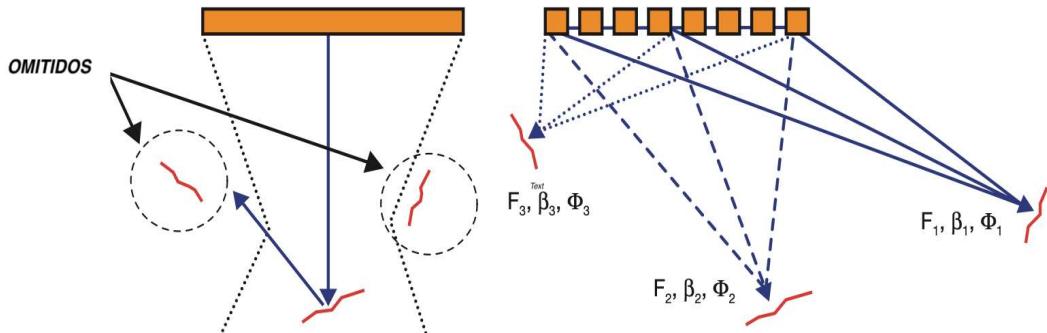


Figura 2.5: Detección de grietas mediante sondas mono-cristal y multielemento. Haz unidireccional falla la detección de dos grietas (izquierda). Haces enfocados y multiángulo son capaces de detectarlas (derecha), donde F , β y ϕ representan los ángulos de dirección para cada elemento emisor considerado en el ejemplo. Tomado de [25]

Con un único transductor se genera una onda que interactúa con la muestra a evaluar, dispersándose en todas direcciones. Una parte de dicha energía acústica dispersa retorna al transductor para ser visualizada como voltaje vs tiempo. Sin embargo, información sobre el tamaño u otras propiedades mecánicas requieren una colección de señales a partir

de distintas posiciones y orientaciones del transductor, y es esto lo que se puede lograr con el arreglo tipo *phased-array*, ya que es posible mediante la manipulación de tiempos de retraso direccionar los haces, y permitir mayor cobertura de inspección. La figura 2.5 muestra como una sonda de un solo elemento, con movimiento limitado tiene una alta probabilidad de omitir grietas ubicadas fuera del eje de su haz, mientras que el sistema multi-canal, logra, mediante manipulación de ángulos de emisión para cada elemento, alcanzar lo que antes era excluido (en la figura las variables F , β y ϕ representan ángulos de dirección para tres elementos. Se indican solamente tres por cuestiones de visualización, sin embargo esto se aplica a cualquier cantidad de elementos).

2.2.2. Representación Visual de Escaneo Ultrasónico

Existen distintas maneras de representar información ultrasónica. Para esto, se considera necesario tener en cuenta los conceptos de eje de escaneo y eje de índice. La figura 2.6 nos permite visualizar dichos ejes para los dos primeros patrones.

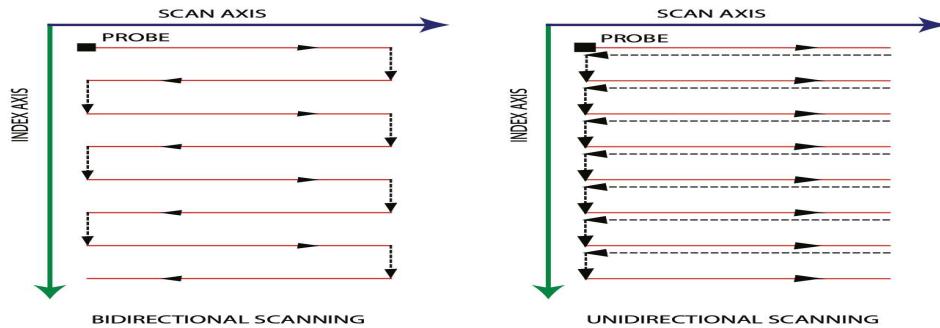


Figura 2.6: Ejes principales de sondeo en adquisición ultrasónica. Las líneas rojas continuas representan el camino de adquisición, y las negras entrecortadas son movimientos sin toma de datos (tomado de [25])

A continuación se aporta una definición concisa las técnicas más básicas y generales de imagen ultrasónica (A-scan, B-scan, C-scan, y D-scan). Además se presenta una introducción a métodos de imagen generadas mediante sistemas phased-array (método Phased-Array, método de enfoque total, e imagen de onda plana).

A-Scan

Este tipo de representación es un despliegue de amplitud vs tiempo de vuelo. Es una forma de onda del eco de reflexión de la estructura al ser captada en el receptor. A-scan

ayuda a identificar defectos como delaminación, desunión, huecos planos y erosión. La sonda está ubicada solo en una posición específica [18]. A diferencia del resto de imágenes, esta visualización es unidimensional, y se la suele desplegar en su forma rectificada y no rectificada (figura 2.7)

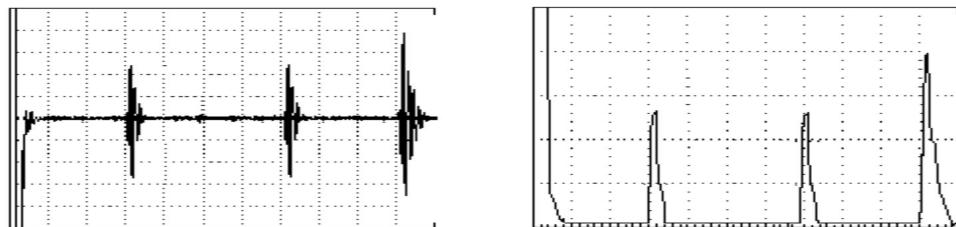


Figura 2.7: A-scan. A la izquierda su forma no-rectificada (con deflexiones positivas y negativas) y a la derecha su envolvente (tomado de [14])

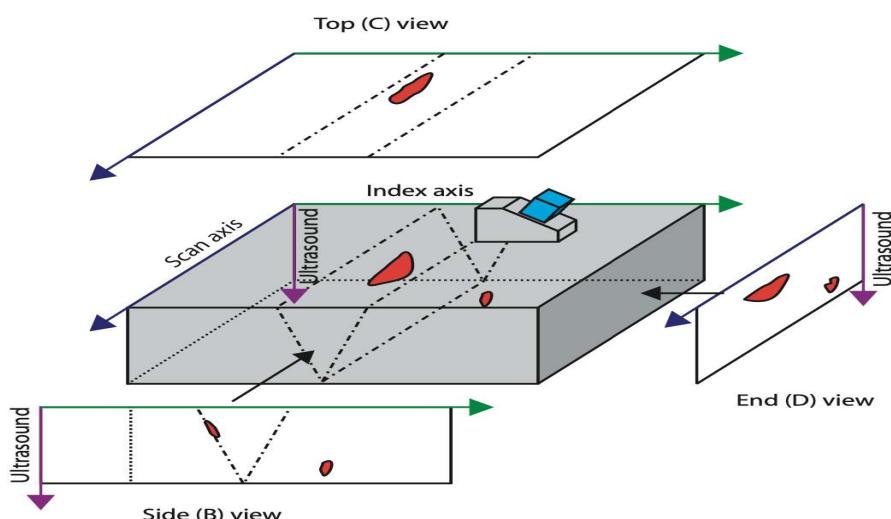


Figura 2.8: Vistas lateral, superior y trasera (B-scan, C-scan, D-scan) (tomado de [25])

Para las restantes 3 visualizaciones disponibles, apelamos al esquema detallado en la figura 2.8, donde cada alternativa representa distintas proyecciones a la pieza bajo evaluación.

B-scan

Aquí se genera una visualización en sección transversal, donde, por lo general, el eje horizontal viene dado por el eje de índice y el eje vertical por el camino del haz. Básicamente, un B-scan es una serie de formas de onda (A-scan) empaquetadas. Cada A-scan mide la amplitud de la señal en código de color, y, por ejemplo, ayuda a detectar arrugas u ondulaciones de las fibras en aeroestructuras. La imagen bi-dimensional se forma al desplazar el

transductor a lo largo del eje de índice, y se representa cada A-scan en un formato basado en color. Valga notar que este desplazamiento es a lo largo de una única linea recta, o mediante un barrido electrónico para el caso de la técnica Phased Array (PA). La figura 2.9 muestra un ejemplo de esta representación.

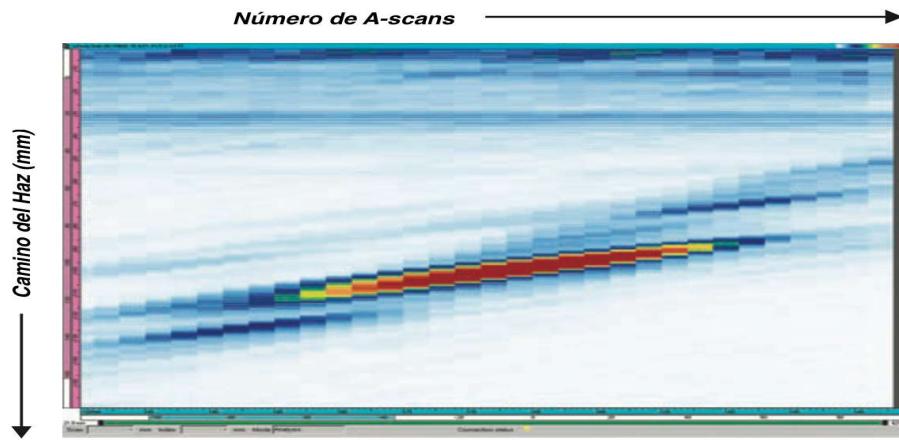


Figura 2.9: Ejemplo B-scan (tomado de [25])

C-scan

Un C-scan es una vista 2-D de los datos ultrasónicos mostrados como una vista superior o en planta del espécimen de prueba (ver figura 2.8). Uno de los ejes es el eje de escaneo; el otro es el eje de índice. Este tipo de imagen muestra los defectos distribuidos a lo largo de un plano dentro del material, pero, a diferencia de un B-scan, este no indica información de profundidad. Para generar la imagen, el transductor se desplaza dentro de un área de la superficie de la muestra, cubriendo varias líneas en paralelo. La imagen final se crea al juntar estas líneas, mostrando la distribución de defectos dentro del área sondeada. Se podría decir que un C-scan es un apilamiento de B-scans en dicha región (ver figura 2.10).

D-scan

Es similar a la B-scan, pero la vista está en ángulo recto con respecto a la B-scan. [18].

2.2.3. Imágenes mediante múltiples elementos (Phased-Array)

Se considera relevante tener presente los siguientes conceptos para la correcta compresión de estas técnicas: 1) **El campo acústico generado por el transductor** viene dado por la relación entre el ancho del transductor (W_x) y la longitud de onda (λ) de la onda

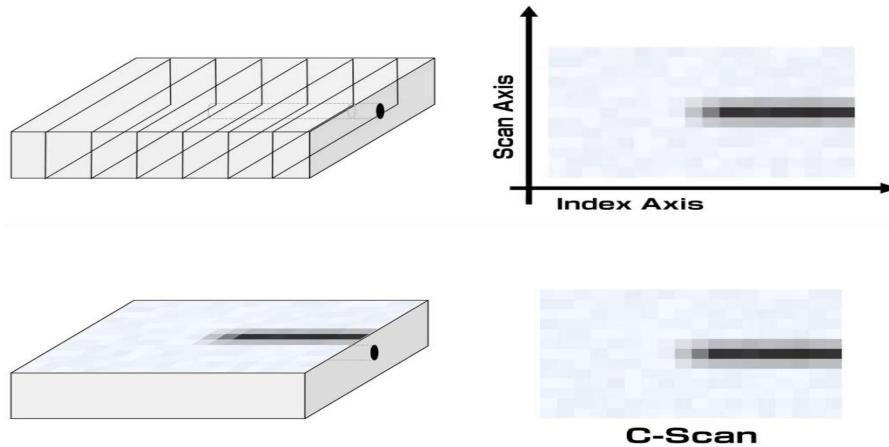


Figura 2.10: Ejemplo C-scan. Tomado de [26]

generada. Como modo de ejemplo de la formación de campos acústicos, la configuración mediante la cual se obtiene un haz de energía *colimado*³, es decir, un campo con frentes de onda paralelos, baja divergencia, y alta direccionalidad e intensidad, que permite “apuntar” más eficazmente a un punto de interés, requiere un ancho del transductor mayor a λ (En este caso, $W_x > 20\lambda$), ver figura 2.11a. Por otro lado, para un elemento pequeño ($W_x = \lambda$), que es el escenario de los componentes en un arreglo matricial (phased-array), la figura 2.11.b indica los obtenido: la energía acústica se distribuye en un ángulo angular amplio.

El arreglo multi-elemento de un phased-array posibilita desplazar y direccionar el haz ultrasónico de manera electrónica, sin necesidad de trasladar e inclinar el transductor físicamente. Los elementos en el arreglo se distribuyen periódicamente, tanto para arreglos lineales (con $W_y \gg W_x$, figura 2.12), como para arreglos matriciales (con $W_y = W_x$, ver figura 2.13) y cada período toma el nombre de “*pitch*”. En un proceso conocido como **2) Conformación de haces**, cada elemento se puede controlar de forma independiente, con distintos instantes de excitación y fases para generar un campo acústico determinado, esto mediante la definición de distintos valores de retardos, lo que se conoce como **3) leyes focales** [27].

En este contexto , la **conformación de haces en emisión** trata de direccionar y enfocar el haz, definiendo una ley focal determinada mediante el cómputo de un **4) tiempo de vuelo** desde cada elemento del arreglo (E) hacia el punto de interés (F). La ecuación

³Ondas ultrasónicas en la que los frentes de onda son paralelos y el haz se dispersa muy poco a medida que se propaga a través del medio

2.1 indica dicho cálculo, teniendo en cuenta un medio isotrópico, donde d representa la distancia Euclídea, y c la velocidad de propagación.

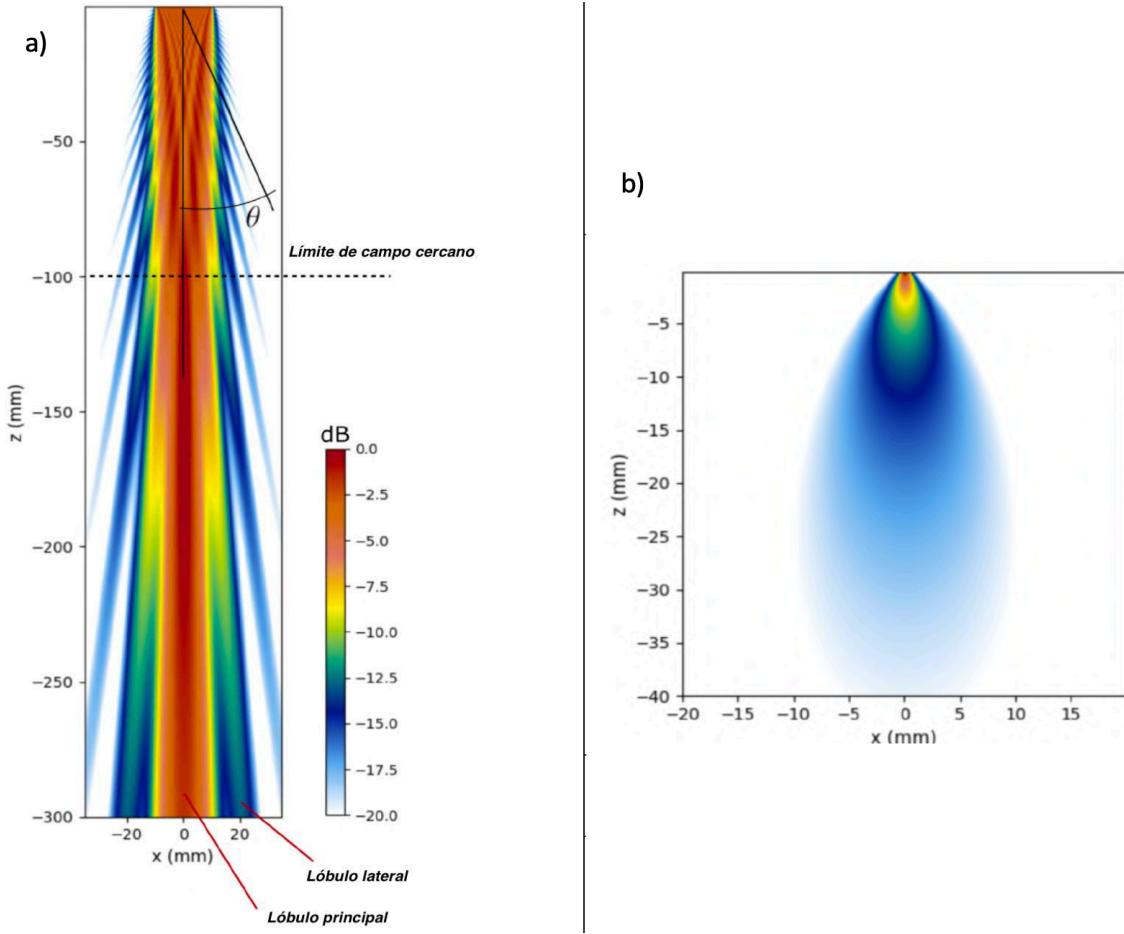


Figura 2.11: Ejemplo de haz colimado: $W_x > \lambda$ (tomado de [27])

$$TDV(E, F) = \frac{d(E, F)}{c} \quad (2.1)$$

Por otro lado, las ondas reflejadas a partir de las heterogeneidades del material hacia el transductor generan señales fuera de fase en cada elemento del arreglo. La **conformación de haces en recepción** consiste entonces en el proceso de alineamiento y suma de dichas señales, con el fin de obtener un eco reforzado en los canales de entrada [27]. La ecuación 2.2 muestra la operación para obtener la señal reflejada en el medio, $S(t)$, a lo largo de la linea de propagación del haz. Aquí, τ representa los retrasos necesarios para alinear las señales, y N_{el} el número de elementos del arreglo.

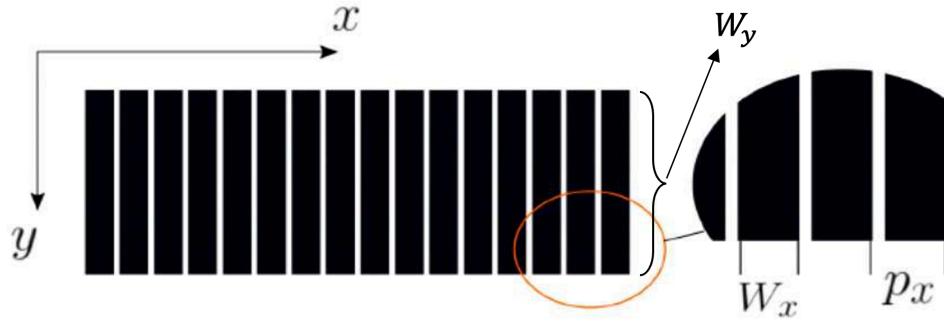


Figura 2.12: Arreglo lineal: p_x “pitch” en dirección x del plano. (modificado de [27])

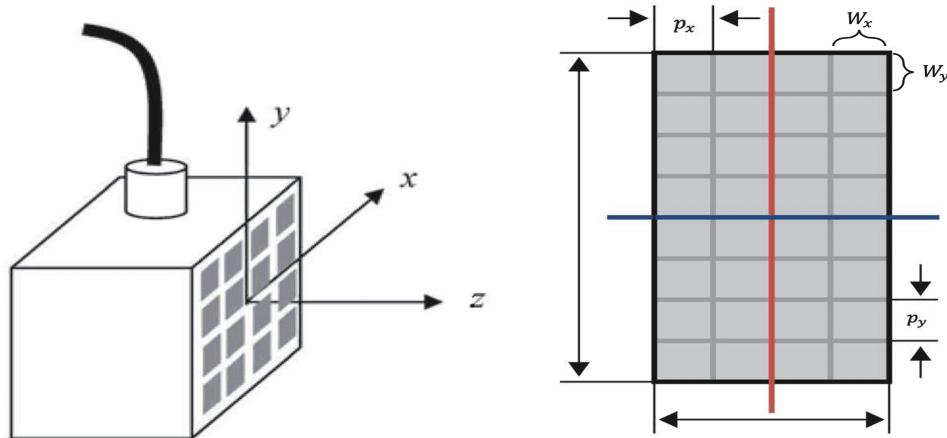


Figura 2.13: Arreglo matricial: p_x y p_y “pitch” en cada dirección del plano del arreglo. (Modificado de [25])

$$S(t) = \sum_{j=1}^{N_{el}} s(t - \tau_j, j) \quad (2.2)$$

Método de imagen Phased-Array (PA)

Se escanea una región de interés, generando una secuencia de disparos de distintos haces, a través del uso de distintas leyes focales. En recepción se obtiene una “línea” (A-scan) por cada disparo. La imagen compuesta es el conjunto consecutivo de dichas “líneas”. En un **escaneo PA sectorial** se emplea la apertura⁴ completa del arreglo, el conjunto de elementos son activados simultáneamente, generando un haz en 0° , pero al variar el tiempo de retrasos de distintos elementos, el haz puede ser direccionado permitiendo un barrido a lo largo de un rango angular (-45° a $+45^\circ$, por ejemplo). Los mismos elementos

⁴Superficie de la sonda a partir de la cual las ondas son emitidas

reciben los ecos reflejados, y las líneas de imagen se generan mediante conformación de haz en recepción. Por otro lado, un **escaneo PA lineal** involucra la activación secuencial de un sub-conjunto de elementos adyacentes (sub-apertura) para crear una serie de haces paralelos que cubren el área de inspección. La sub-apertura se desplaza a lo largo de la sonda generando haces que cubren diferentes secciones del área. Los mismos elementos reciben los ecos reflejados, y se agrupa la información de los tiempos de vuelo para generar imágenes transversales.

Total Focusing Method (TFM)

Este método está basado en los principios de adquisición conocida como **Full Matrix Capture (FMC)**, que implica registrar todas las posibles combinaciones de transmisión-recepción de los elementos en el arreglo. El resultado es una matriz consistente en el conjunto total de datos en el dominio temporal (A-scans) de todas las combinaciones de elementos de transmisión y recepción [28]. El procesamiento de datos involucra el cómputo de tiempo de vuelo en cada punto de la región de interés (una rejilla de puntos o pixeles). Las señales en cuestión son sumadas coherentemente para construir una imagen de amplitud en cada punto. La ecuación 2.3 define este proceso, donde $s(t, i, j)$ representa la matrix FMC, i, j son los elementos emisor y receptor, respectivamente, y \mathbf{P} el punto reflector.

$$I_{TFM}(P) = \sum_{i=1}^{N_{el}} \sum_{j=1}^{N_{el}} s(t(P, i, j), i, j) \quad (2.3)$$

Donde,

$$t(P, i, j) = \frac{2r(P)}{c} - \tau_j \quad (2.4)$$

Siendo τ_j los retardos necesarios para alinear las señales, y c la velocidad de propagación.

Imagen de Onda Plana

En lugar de enfocar el haz ultrasónico en un punto específico, la técnica de Imagen de Onda Plana (IOP) transmite una onda plana que se propaga por toda la región de interés

con una inclinación $\theta = 0^\circ$. Esto se logra aplicando un retardo uniforme a través de los elementos del arreglo (es decir, se define un mismo valor de retraso en todos los componentes), lo que crea un frente de onda que es esencialmente plano. Para lograr una onda plana con cierta inclinación θ , es necesario emplear un retraso con un incremento consistente a lo largo del arreglo, es decir, desde un extremo del arreglo cada elemento se dispara con un pequeño retraso con respecto al anterior. La ley focal que determina dicha configuración se muestra en la ecuación 2.5.

$$\tau_j = p_x j \sin(\theta) \quad (2.5)$$

Todos los elementos del arreglo reciben los ecos simultáneamente, lo que da como resultado una matriz completa de señales para cada transmisión de onda plana. El proceso se repite para múltiples ángulos, proporcionando así diferentes perspectivas de la región de interés. Finalmente las señales (provenientes de distintos ángulos) se combinan mediante algoritmos de conformación de haces para reconstruir una imagen de alta resolución [29].

2.3. Aprendizaje Profundo en END

La **Inteligencia Artificial (IA)** es un campo amplio que abarca cualquier técnica que permita a los computadores “imitar” la inteligencia humana. Su fin es generar sistemas basados en reglas y algoritmos que permitan llevar a cabo tareas como razonamiento, aprendizaje y resolución de problemas. El **Aprendizaje de Máquina (AM)** es un subconjunto de IA, que permite a un sistema computacional aprender a partir de datos, y optimizar su desempeño a lo largo del tiempo sin ser explícitamente programados. Incluye técnicas como aprendizaje supervisado, no-supervisado, y reforzado. El **Aprendizaje Profundo (AP)** es, a su vez, un sub-conjunto especializado del aprendizaje de máquina, que involucra redes neuronales con muchas capas. El término “profundo” en “aprendizaje profundo” hace referencia al uso de capas sucesivas de representación, es decir, la cantidad de capas que contribuyen a la modelización de los datos es la *profundidad* del modelo. Estos algoritmos son capaces de aprender patrones y relaciones complejas en los datos.

Avances en el poder computacional han incrementado el interés en la industria en automatizar el análisis de datos END. La disponibilidad de algoritmos de AM posibilitan dicha

automatización. El requerimiento de emplear algoritmos AM puede plantearselo desde el punto de vista de suministrar apoyo a operadores entrenados en el proceso de evaluación e interpretación de datos END, proceso que se caracteriza por ser una actividad que consume mucho tiempo, necesita mucha experiencia en la detección y categorización de ecos, y puede verse comprometida por escenarios de fatiga y dificultad de discernir señales con alto contenido de ruido. En la literatura sobre aprendizaje de máquina para END ultrasónica, se evidencia una alta diversidad en los algoritmos empleados y en la forma que estos se aplican [30, 31, 32].

Con el fin de exponer el uso de estos algoritmos y los aspectos que intentan resolver u optimizar se hace referencia, a continuación, a 3 ejemplos concretos (en base a métodos AM representativos) que permiten apreciar el potencial de esta tecnología en abordar tareas específicas de END.

Support Vector Machine (SVM): SVM es un método AM diseñado principalmente para tareas de clasificación, que se basa en encontrar una frontera de decisión óptima (hiperplano), que permita distinguir de mejor manera entre dos (o más) clases dentro de un conjunto de datos. El modelo resultante dependerá de los *vectores de soporte*, es decir, aquellos puntos de datos que yacen más cerca al hiperplano, y por lo tanto definirán su posición y orientación. En el ámbito de inspección de soldadura [33] presenta esta técnica como clasificador automático en la detección de fallas mediante el método TOFD⁵, concluyendo que los modelos SVM son robustos en su desempeño, a pesar de la falta de datos de entrenamiento, y que presentan un tiempo corto en su capacidad de detección exitosa.

Árboles de Decisión (Bosques Aleatorios): Este método AM trabaja dividiendo recursivamente los datos en subconjuntos según la característica que mejor los categoriza, esto en base a un criterio determinado, lo que da como resultado una estructura de decisiones similar a un árbol. En [34] se discute un ejemplo de aplicación en la evaluación de soldadura por puntos, en base a información de oscilogramas ultrasónicos, que, debido a la necesidad de interpretarlos repetidamente, la eficacia del operador puede verse comprometida. Su reporte sobre el desempeño de algoritmos de bosques aleatorios indica que estos proveen una buena ejecución de clasificación, reduciendo el sobre ajuste. Sugieren en-

⁵Time-of-flight diffraction

tonces que son algoritmos útiles en control de calidad, ya que reducen considerablemente la carga de trabajo del operador.

AM no-supervisado: En [32] se discute la aplicación de dos algoritmos representativos de los método no-supervisados: 1) algoritmo *K-mean clustering* que divide los datos en un número predefinido de racimos (clusters) partiendo de centroides aleatorios y asignando los puntos de datos al centriode más cercano en base a distancias euclídeas. Dichas asignaciones se aplican iterativamente, buscando disminuir la varianza dentro de cada racimo y maximizando la varianza entre racimos, y así se determina la clasificación. 2) Modelamiento mixto Gaussiano. Es un método probabilístico que modela cada racimo como distribuciones Gaussianas, asignando a cada punto de datos parámetros iniciales de media y varianza. La clasificación se lleva a cabo iterativamente hasta maximizar la probabilidad de que cada punto de dato pertenezca a cada distribución. Los autores aplican cada algoritmo para localizar y detectar fallas en base a datos A-scan. El desempeño de los modelos se evalúa a través de matrices de confusión, que indican una exitosa categorización falla/no-falla con una precisión del 93 %.

2.3.1. Redes Neuronales Convolucionales (RNC) en END

Fundamentos de las RNCs

Las Redes Neuronales Convolucionales (RNCs) son una clase de modelos de aprendizaje profundo específicamente diseñados para procesar y analizar estructuras de datos en forma de cuadrícula, como las imágenes. A diferencia de las redes neuronales tradicionales, las RNCs aprovechan la estructura espacial de los datos, lo que las hace especialmente poderosas para tareas que involucran imágenes, videos y otras entradas visuales. A continuación consideraremos los componentes clave para la arquitectura de una RNC.

Capas Convolucionales: El término convolucional indica que la red utiliza la operación matemática conocida como *convolución*. En su forma más general, la convolución es una operación matemática entre dos funciones, para generar una tercera función que expresa cómo la forma de la primera cambia al interactuar con la segunda. La ecuación 2.6 muestra la expresión integral del producto de ambas funciones, donde la una segunda función ($g(t)$)

se desplaza con respecto a la primera ($f(t)$).

$$s(t) = (f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau) d\tau \quad (2.6)$$

En la terminología de redes convolucionales, la primera función ($f(t)$) se la denomina **entrada**, la segunda función ($g(t)$) **kernel**, y el resultado ($s(t)$), **mapa de características**. Entonces, en la arquitectura de una RNC, esta capa es el primer elemento, y se encarga de la extracción de características de los datos de entrada al aplicar filtros (kernel) sobre estos. Si los datos de entrada, por ejemplo una imagen, consisten en una matriz de 4×3 , y el filtro se lo define como una arreglo de 2×2 , éste se desplazará a lo largo de toda la imagen en pasos previamente definidos, generando, en cada posición, un valor único, que corresponderá a la suma del producto de los elementos del filtro y la sección correspondiente de la matriz de entrada. De esta manera, el filtro se encarga de detectar patrones específicos, como bordes, texturas, u otras estructuras complejas. La figura 2.14 captura el algoritmo.

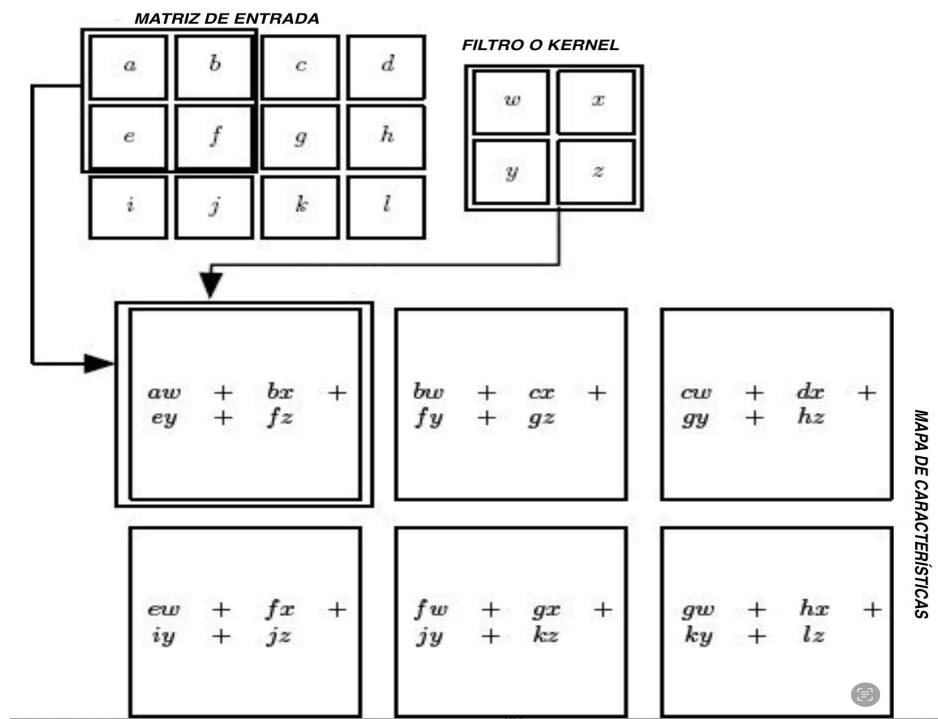


Figura 2.14: Ilustración de convolución en capa convolucional. Tomado de [35]

Función de activación: Cada valor en cada nodo de la red se lo denomina *valor de activación*. El resultado de cada bloque de suma de productos en la operación de convolución determina el valor de activación en la capa actual. Sin embargo, con el fin de obtener

un comportamiento no-lineal de la red (que le permite aprender patrones y relaciones complejas en los datos) se apela a funciones de activación. Entre las más comunes están la función sigmoide, y la función de Unidad de Rectificación Lineal (ReLU).

Capa de submuestreo (Pooling): El tamaño de los tensores posterior a la capa de convolución dependen de la cantidad de filtros utilizados, su tamaño, y el valor de desplazamiento de cada uno (conocido como *stride*). Para el caso de la figura 2.14, si, por ejemplo, se aplican 2 filtros, el tensor resultante tendrá entonces un tamaño de (3x3x2), es decir un arreglo de 3x3 valores de activación y 2 canales. Esta operación requiere también una ventana que se desplazará con un valor de *stride* específico a lo largo del cada canal del tensor mencionado, y en cada iteración se aplica un criterio de submuestreo, que puede ser el de extraer los valores con mayor activación (**maxpooling**), u obtener el promedio de la ventana actual (**average-pooling**). Si la ventana de desplazamiento es, por ejemplo, de 2x2, esto implica que la reducción de las dimensiones del tensor será a la mitad de su tamaño actual. La figura 2.15 muestra el resultado de los dos posibles métodos de submuestreo mencionados.

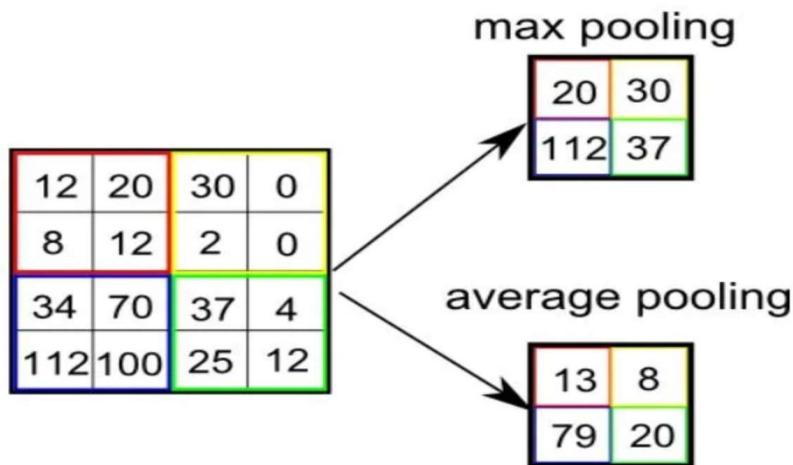


Figura 2.15: Tipos de submuestreo. Tomado de [36]

Autocodificador: en el contexto de RNCs es una arquitectura diseñada especialmente la extracción de características, o el aprendizaje de representaciones en los datos de entrada en un espacio dimensional reducido. Consiste de dos etapas principales:

- **Codificador:** comprime los datos de entrada reduciendo sus dimensiones espaciales. Esto se logra mediante una serie de capas convolucionales y de agrupamiento

(*pooling layers*) que reducen progresivamente las dimensiones espaciales y capturan las características esenciales de los datos de entrada. La salida del codificador es una representación compacta y codificada de la entrada.

- **Decodificador:** toma la representación comprimida e intenta reconstruir los datos de entrada originales a partir de ella. El decodificador normalmente utiliza una serie de capas convolucionales transpuestas (también conocidas como capas deconvolucionales) para sobremuestrear la representación codificada y devolverla a las dimensiones de entrada originales. El objetivo es hacer que la salida reconstruida se parezca lo más posible a la entrada original. La figura 2.16 muestra la estructura general de un autocodificador.

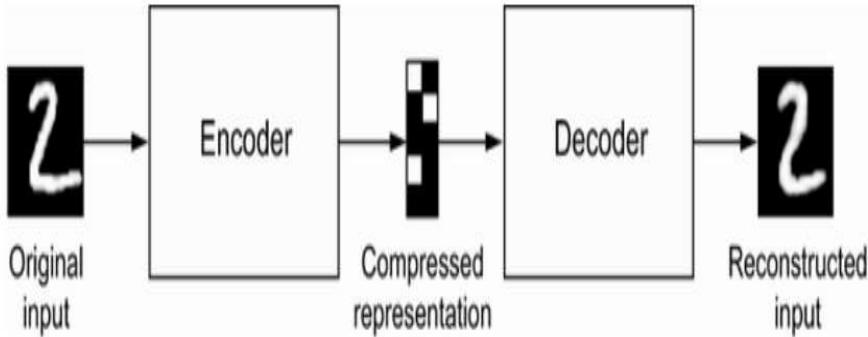


Figura 2.16: Arquitectura general de autocodificador. Tomado de [37]

Entrenamiento mediante retropropagación: Algoritmo que implica calcular el gradiente de la función de pérdida con respecto a cada peso en la red, y luego usar este gradiente para actualizar los pesos de manera que se minimice la pérdida. La regla de actualización de pesos se la da en la ecuación 2.7, donde θ representa los pesos en la red, α es la tasa de aprendizaje, y $\frac{\partial L}{\partial \theta}$ es el gradiente de la función de pérdida (L) con respecto a los pesos.

$$\theta_i = \theta_{i-1} - \alpha \frac{\partial L}{\partial \theta} \quad (2.7)$$

Funcionalidades principales de deep learning para visión artificial⁶: De manera general existen tres tareas esenciales de visión por computadora:

⁶computer vision

1. **Clasificación de imagen:** Donde el objetivo es asignar una o más etiquetas a una imagen. Esto puede ser clasificación de una sola etiqueta (una imagen solo puede pertenecer a una categoría, excluyendo a las demás) o clasificación de múltiples etiquetas (etiquetando todas las categorías a las que pertenece una imagen)
2. **Detección de objetos:** Donde el objetivo es dibujar rectángulos (llamados cajas delimitadoras) alrededor de objetos de interés en una imagen y asociar cada rectángulo con una clase. Por ejemplo, un sistema de seguridad podría utilizar un modelo de detección de objetos para vigilar a personas, animales y vehículos en las áreas monitoreadas por sus cámaras.
3. **Segmentación de imagen:** Aquí el objetivo es ‘es categorizar cada pixel de la imagen para ser capaces de identificar y diferenciar los distintos objetos que sean de interés. La figura 2.17 muestra el ejemplo de un máscara de segmentación predicha a partir de su imagen de entrada.



Figura 2.17: Ejemplo de máscara de segmentación. Tomado de [37]

Arquitectura V-Net

Esta es una arquitectura de tipo RNC, diseñada específicamente para la segmentación de imágenes médicas en 3D, fue introducida por [38], y amplía las ideas de la popular red U-Net [39]. De esta última, dos conceptos clave permiten su eficaz desempeño: **1)** la estructura *codificador-decodificador*, para **extracción de características**; y **2)** el *salto de conexiones* entre la capa codificadora y la capa decodificadora, como criterio de **preservación y traslado de la información** aprendida entre una etapa (codificación) a la otra (decodificación). La arquitectura V-net extiende estas funcionalidades a imágenes 3D

al aplicar capas convolucionales que operan en datos volumétricos [38, 40, 41]. De forma muy general se puede sintetizar su estructura en:

1. **Capas convolucionales 3D**: cada filtro convolucional opera sobre la altura, ancho, y profundidad de los datos volumétrico, capturando características espaciales en todas las dimensiones.
2. **Etapa Codificadora**: consiste en varias capas de convolución 3D, seguidas de operaciones de submuestreo. Reduce la dimensión espacial mientras incrementa el número de canales. Mientras el codificador progresiona extrae características cada vez más abstractas de la imagen volumétrica de entrada.
3. **Etapa Decodificadora**: se realiza el sobremuestreo (utilizando convoluciones transpuestas) para incrementar las dimensiones espaciales de vuelta a su tamaño original. Su objetivo es generar una máscara de segmentación que coincida con las dimensiones de la imagen original.
4. **Conexiones residuales**:
 - **Skip Connections**: una V-net incorpora para vincular capas que se corresponden en las etapas de codificación y decodificación. Estas ayudan a retener información espacial que podría perderse durante el submuestreo (se las presentará en una figura más adelante).
 - **Bloques residuales**: Cada capa en la etapa de codificación y del decodificación utiliza bloques residuales, que incluyen conexiones de rebote dentro del propio bloque. Este diseño ayuda con el flujo de gradiente y hace que la red sea más fácil de entrenar al mitigar el *problema de desvanecimiento de gradiente* [38].

5. **Mapa de segmentación**: El resultado final de V-Net es un mapa de segmentación volumétrica que asigna etiquetas a cada voxel (píxel 3D) en el volumen de entrada. Este resultado representa las regiones segmentadas de interés.

Valga notar que los siguientes conceptos son relevantes describirlos brevemente para la siguiente sección:

Época: Se refiere a la cobertura completa de todo el conjunto de datos de entrenamiento..

2.3. APRENDIZAJE PROFUNDO EN END

Es una medida de cuántas veces el algoritmo de aprendizaje ha procesado todo el conjunto de datos. El uso de múltiples épocas es crucial para que la red aprenda de manera efectiva, y la cantidad correcta de épocas se determina monitoreando el rendimiento del entrenamiento y la validación.

Tamaño de lote:⁷ Número de muestras de entrenamiento utilizadas para estimar el gradiente de error en cada iteración. Tamaños grandes pueden generar estimaciones de gradiente más estables, pero requieren más recursos computacionales. Tamaños de lote más pequeños pueden introducir más ruido en las estimaciones de gradiente, lo que potencialmente ayuda a escapar de los mínimos locales, pero puede ralentizar el entrenamiento.

Ground Truth (GT): es el conjunto de datos precisos y confiables que se utilizan como referencia para entrenar la RNC. Representa el resultado verdadero o correcto que se espera que prediga un modelo.

Dropout Rate Técnica de regularización aleatoria que implica establecer una proporción de unidades de entrada en cero durante el entrenamiento para evitar el sobreajuste. El porcentaje definido controla la fracción de unidades descartadas.

⁷Batch size

Capítulo 3

Descripción Experimental

En general, para el desarrollo de este proyecto fue necesario adquirir datos ultrasónicos que permitan detectar ecos generados por las superficies de estructuras con diversas geometrías. En este capítulo se revisan y analizan los criterios empleados para la recolección de dichos datos, los cuales son posteriormente procesados y utilizados para entrenar una red neuronal convolucional diseñada específicamente para la segmentación de imágenes 3D. Del mismo modo, se describe la arquitectura de la red seleccionada y de la adecuación requerida para aplicarla a los datos ultrasónicos obtenidos.

3.1. Configuración del ensayo

3.1.1. Materiales y métodos

Las adquisiciones se llevaron a cabo utilizando piezas de referencia de acero, aluminio y fibra de carbono (ver figura 3.1). La tabla 3.1 muestra cada pieza y sus características. La toma de datos fue mediante ensayos en inmersión, empleando un transductor matricial de marca Imasonic (Francia) con las siguientes propiedades acústicas:

1. **Frecuencia central:** $3\text{MHz} \pm 10\%$;
2. **Adaptación de impedancia acústica:** 2.45 MRayl en Rexolite;
3. **Tipo de arreglo:** Matricial 2D;
4. **Número de elementos:** 11x11;

5. **Dimensiones:** $11.0 \text{ mm} \pm 0.1 \text{ mm} \times 11.0 \text{ mm} \pm 0.1 \text{ mm}$;
6. **Pitch individual:** 1.0 mm en cada dirección;
7. **Espaciado entre elementos:** 0.2 mm en cada dirección.

La figura 3.2 indica un esquema gráfico del transductor.

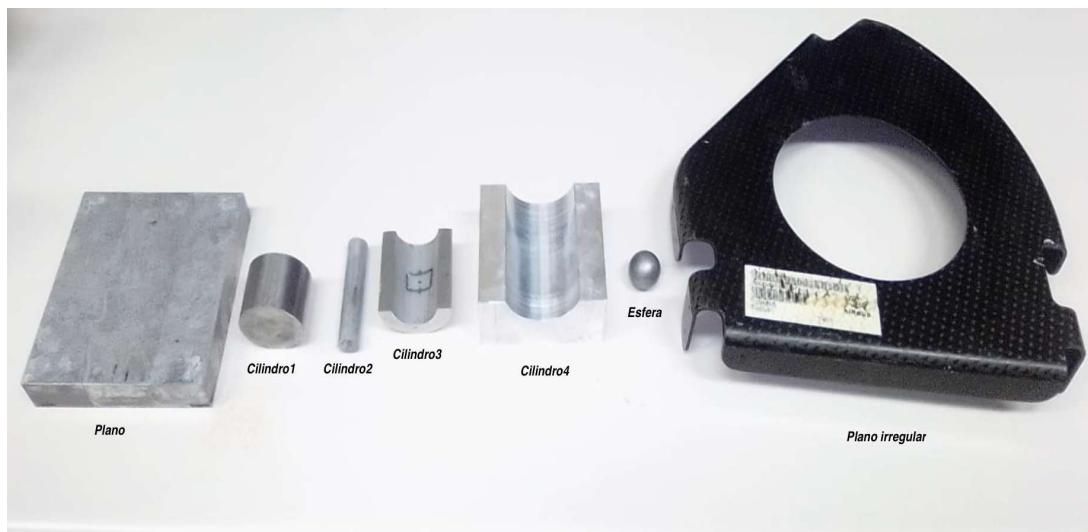


Figura 3.1: Piezas de referencia

Pieza	Material	Dimensiones/Diámetro
Plano rectangular	Aluminio	95x110x20 mm
Cilindro 1	Aluminio	35mm
Cilindro 2	Aluminio	12mm
Cilindro 3	Aluminio	25mm
Cilindro 4	Aluminio	40mm
Esfera	Acero	19mm
Plano irregular	Fibra de carbono	1.9mm (espesor)

Tabla 3.1: Piezas de referencia y sus características. Para los casos de cilindros y esfera, la dimensión indicada corresponde a su diámetro

La adquisición de las señales se las realizó con un equipo ultrasónico multicanal **SITAU**, de 128 canales en paralelo , de la empresa Dasel S.L (España). El sistema permite la adquisición de las señales en dos distintos modos [42]:

3.1. CONFIGURACIÓN DEL ENSAYO

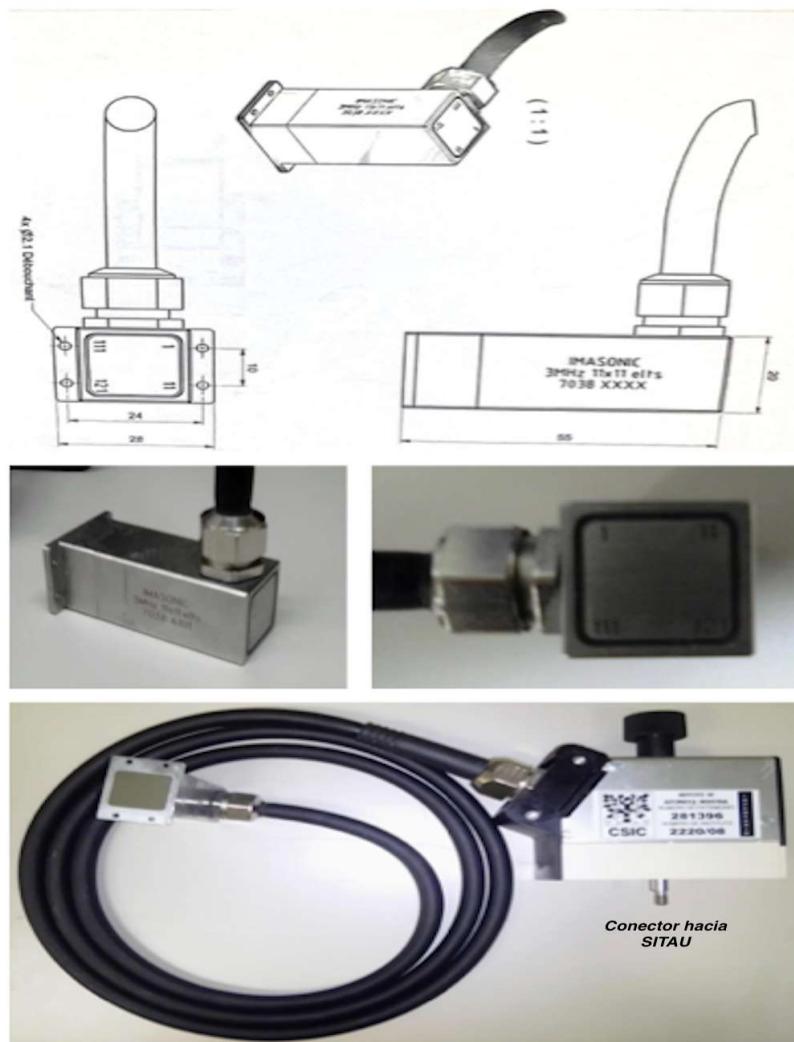


Figura 3.2: Transductor matricial Imasonic: esquema y fotografía

1) Modo “Phased Array”:

- Tiempos de retardo programables para cada canal. Hasta $409 \mu\text{s}$, con resolución de 6.25 ns . Independiente para emisión y recepción
- Hasta 256 líneas de escaneo por imagen.
- Apertura activa programable desde 1 hasta el número completo de canales.
- Profundidad de adquisición programable hasta 20000 muestras por línea de escaneo.

2) Modo multicanal:

- Modo que se utiliza para el tipo de adquisición FMC (*Full Matrix Capture*)
- Tiempos de retraso programables para cada canal. Hasta $409 \mu\text{s}$, con resolución de

6.25 ns. Independiente para emisión y recepción

- Apertura activa programable desde 1 hasta el número completo de canales.
- Profundidad de adquisición programable hasta 4096 muestras por línea de escaneo.

Para cada pieza de referencia, se realizó un serie de adquisiciones modificando la posición y orientación del transductor. De este modo se obtienen múltiples imágenes con variaciones en los ecos de superficie, que permiten el posterior entrenamiento de la RNC. Como se comentado anteriormente, para el etiquetado estas imágenes se utilizará un método automático basado en el cálculo de los TDV teóricos a partir de la geometría del sistema. Para ello, es necesario conocer conocer con precisión esta geometría. De lo contrario, el etiquetado contendría errores que perjudicarían el entrenamiento de la red. La geometría del sistema está determinada por la forma de la pieza ensayada, y por la posición y orientación del transductor respecto a esa pieza. Esta última fue determinada mediante la utilización de un brazo robótico para manipular el transductor.

Las trayectorias del transductor se las implementaron mediante un brazo robótico tipo colaborativo **UR10e**, de la empresa Universal Robot, en Dinamarca (figura 3.3). El UR10e es un brazo robótico industrial de seis ejes, lo que significa que tiene seis grados de libertad (GDL). Cada GDL corresponde a una articulación que permite el movimiento rotatorio, con un rango de $\pm 360^\circ$. La geometría del robot está caracterizada por sus articulaciones y enlaces. Sus **articulaciones** se categorizan en 4 tipos: **1) Base (A1)**, se encuentra fija a la base y permite la rotación sobre el eje vertical. **2) Hombro (A2)**: permite que el robot se balancee hacia adelante y hacia atrás. **3) Codo (A3)**: permite que el robot extienda o retraiga su brazo. **4) Muñecas (A4, A5 y A6)**: controlan el movimiento en los ejes, lateral, longitudinal y vertical (ver figura 3.3). Por otro lado, los **enlaces** son los segmentos rígidos que se encuentran entre las articulaciones (puntos del 0 al 5 en figura 3.3). Las longitudes y los ángulos entre estos enlaces determinan el alcance del robot y su capacidad de maniobra en el espacio tridimensional.

Tanto para el equipo SITAU como para el robot UR10e, las compañías proveen librerías de programación compatibles con lenguaje Python. En ambos casos se implementaron secuencias de códigos e interfaces de usuario para el debido manejo de ambos equipos,

3.1. CONFIGURACIÓN DEL ENSAYO

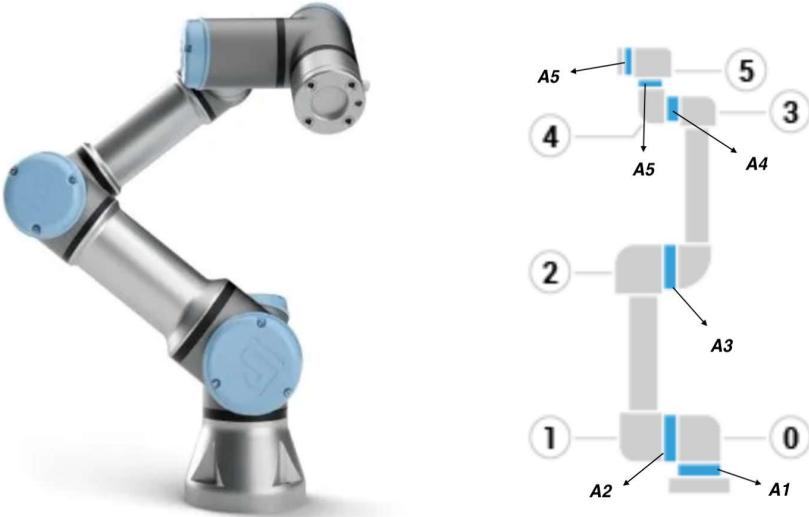


Figura 3.3: Brazo robot colaborativo UR10e. Tomado de [43]

es decir, leyes focales y conformación de haces para SITAU, y definición de sistemas de coordenadas y trayectorias para el UR10e.

Finalmente, para la implementación de la red neuronal se utilizó la plataforma de aprendizaje automático *tensorflow* [44] que proporciona una muy versatil librería con un amplio rango de algoritmos de aprendizaje profundo. Los detalles de los paquetes y la definición de arquitecturas se describirán con mayor profundidad en subsecuentes secciones.

Para el manejo remoto del robot, la adquisición y procesamiento de datos se implementaron 3 interfaces de usuario (GUIs), utilizando **Qt-Designer**, que permite a los desarrolladores diseñar y editar interafces gráficas (GUI) para aplicaciones en Python con *frameworks* como PyQt o Qt¹ [45]. Esta herramienta permite a los usuarios colocar widgets, botones, campos de texto y otros elementos de la interfaz en un formulario sin necesidad de escribir código manualmente. La herramienta luego genera automáticamente el código subyacente necesario para renderizar la GUI, lo que facilita la creación y gestión de GUIs complejas en proyectos de Python. A continuación se da una breve explicación de las funciones definidas en cada una.

GUI 1: La figura 3.4 muestra la GUI que permite la adquisisción de las señales ultrasónicas, al controlar el hardware SITAU. Al abrir la interfaz se cargan las funciones requeridas para la interacción con SITAU, para esto se ha implementado una clase en python que

¹Librería de GUIs que se puede utilizar desde C o desde Python, u otros lenguajes

contiene los métodos necesarios.

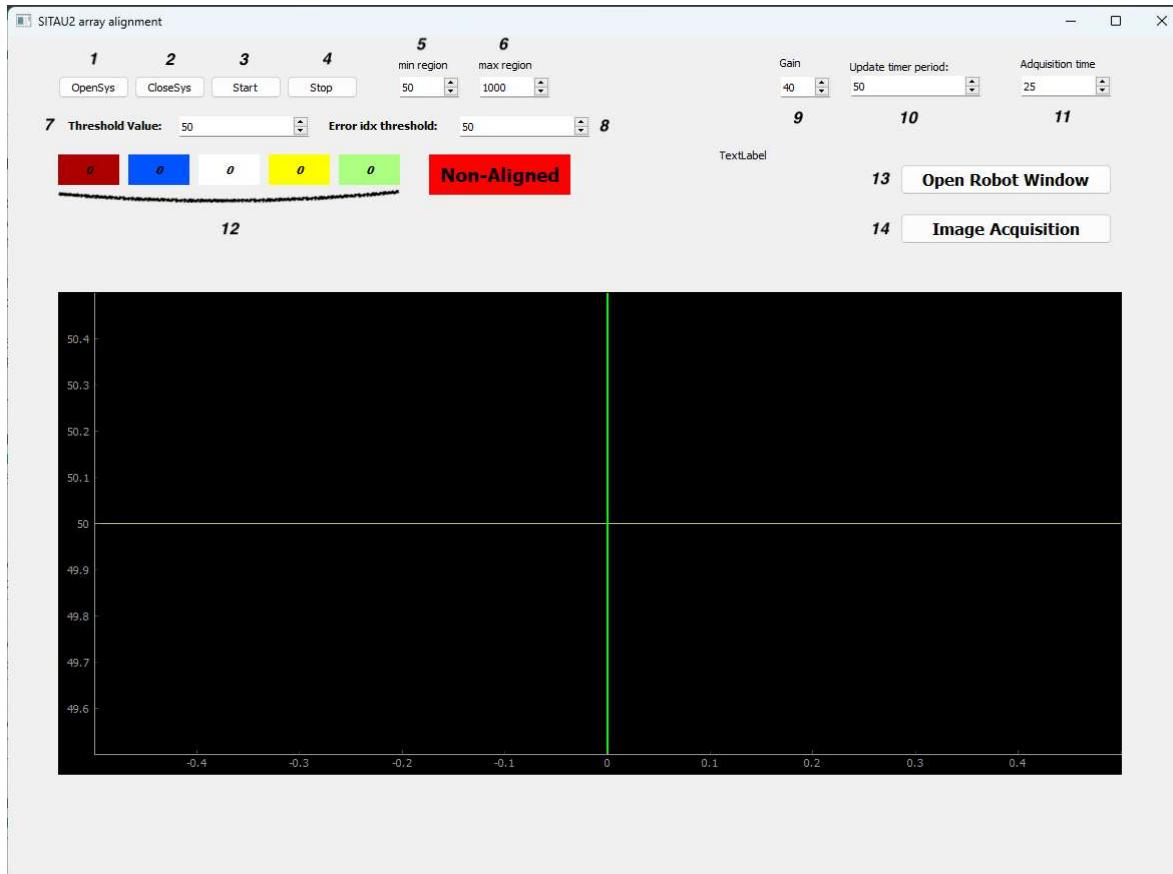


Figura 3.4: GUI 1

Las funciones implementadas en cada botón son las siguientes: **1**) establece conexión con el hardware mediante puertos de enlace predefinidos; **2**) culmina conexión; **3**) inicia proceso de adquisición en los canales del equipo mediante los elementos del transductor, y en base a las leyes focales definidas; **4**) detiene la adquisición en curso; **5 y 6**) definen los límites inferior y superior de la ventana de trabajo para determinar los TDVs de cada A-scan detectado, para la técnica de cruce de umbral. Esto permite concentrarse en una sección específica de la señal completa, y poder descartar información proveniente de las colas del pulser, es decir aquellas señales detectadas que se generan por los pulsos que excitan los elementos del transductor; **7**) valor de umbral de detección de ecos; **8**) este valor determina la diferencia mínima para que los elementos del arreglo se consideren alineados (se explicará con más detalle en la sección de alineamiento con respecto al plano); **9**) ajusta la amplificación de la señal recibida por el transductor; **10**) este valor establece el período de adquisición, es decir, el tiempo entre una adquisición y la siguiente; **11**) se refiere a la duración durante la cual se recopilan datos de ultrasonido durante una sola exploración o

3.1. CONFIGURACIÓN DEL ENSAYO

medición. **12)** estas etiquetas despliegan los índices actuales asociados al cruce de umbral de las señales para cada uno de los elementos seleccionados del transductor, en este caso las cuatro esquinas y el elemento central (se explicará con más detalle en la sección de alineamiento con respecto al plano); **13 y 14)** permiten acceso al las interfaces de manejo del robot, y adquisición de imágenes respectivamente.

GUI 2: la figura 3.5 muestra cada sección de la interface. Aquí se define cada módulo de manera concisa, y en posteriores secciones del capítulo se discutirá con mayor profundidad la funcionalidad correspondiente. **1)** Establece conexión remota con el robot; **2)** despliega el estado actual del PCH²; **3)** módulo que permite definir coordenadas y valores de orientación para el PCH; **4)** en esta sección se definen los parámetros para generar un barrido del transductor en distintos ángulos de orientación para el procedimiento de ajuste del elemento central y alineamiento con respecto al plano del transductor. Ambos procesos se explicarán dentro de la sección 3.1.2, sobre preparación y toma de datos. **5)** dos funciones, una nos permite reconectar el robot de ser necesario, y la segunda posiciona el transductor en la ubicación de partida para cualquier trayectoria que se determine. Las cajas de selección modifican esta ubicación de referencia en base al contexto de la medición, en posteriores secciones se comentará al respecto. **6)** En la etapa de toma de datos de cada pieza, es necesario determinar una distancia específica en el eje z (que se la ha denominado Δz), para poder llevar a cabo el cálculo de los TDVs teóricos (se explicará en la sección correspondiente también).

7) estos parámetros son relevantes en el proceso en que se determina el paralelismo del transductor con respecto al plano de referencia (la pieza plana rectangular, ver figura 3.1)

GUI 3: Figura 3.6. El modo de adquisición implementado en esta interface es la configuración *pitch-catch*, que implica el emitir la señal ultrasónica mediante un solo elemento y recibir los ecos con todos los componentes del arreglo matricial. Permite, de este modo, la visualización de señales adquiridas por todos los canales del equipo, señales asociadas a la emisión por parte de un elemento específico del transductor (seleccionable en el campo ubicado sobre el botón **Acquire**). Dentro del código está implementado el cálculo de los

²Punto Central de la Herramienta: concepto asociado al brazo robótico. Es el punto en el espacio donde se encuentra el extremo de la herramienta o pinza del robot y donde el robot realiza sus tareas, como soldar, recoger o colocar un objeto. Se lo explicará con más detalle en la sección 3.1.2, sobre preparación y toma de datos

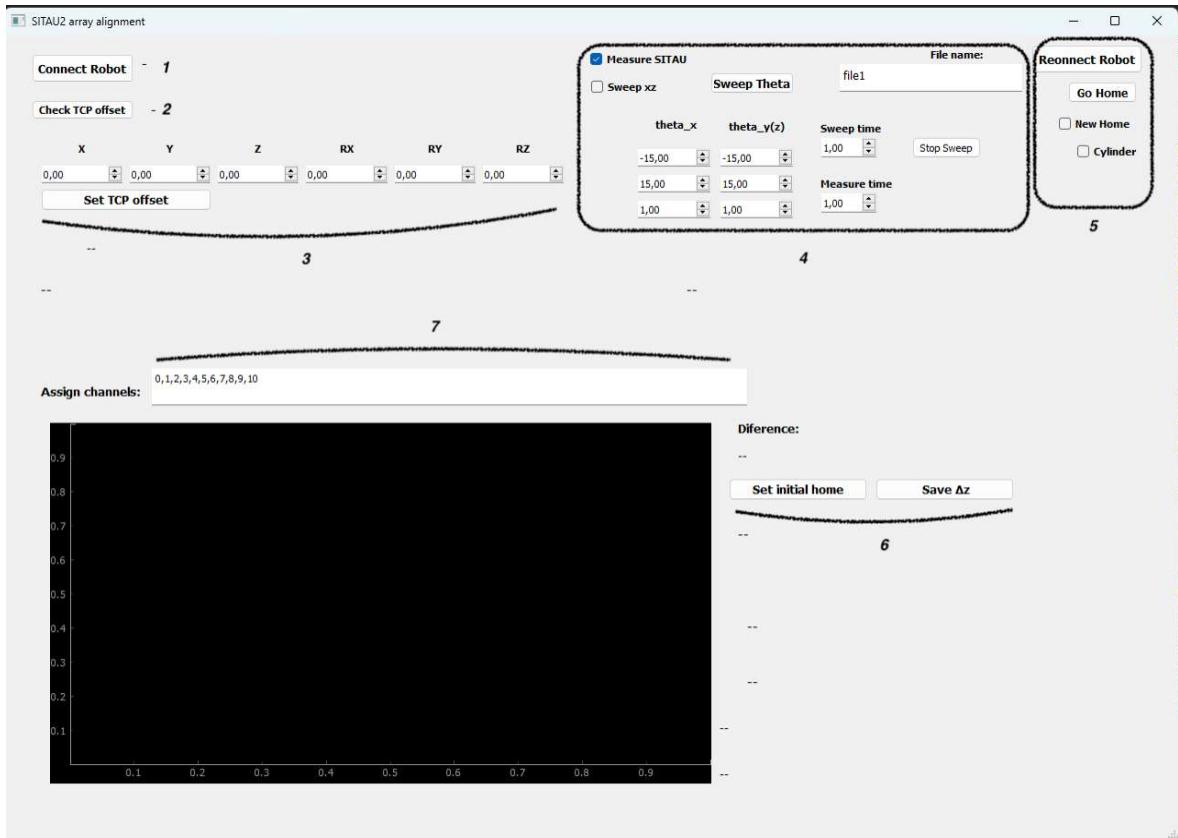


Figura 3.5: GUI 2

TDVs teóricos de tal manera que en la ventana de despliegue se muestran las señales detectadas (en B-scans) superpuestas a los valores teóricos. Se disponen de campos para determinar parámetros específicos en función a la geometría de la pieza a medir, y para definir variables relevantes en el cálculo de los TDVs teóricos (Δz y $home_z$ (posición de referencia para calcular Δz)).

3.1.2. Configuración del Sistema

El proceso que se describe a continuación se requiere para lograr una referenciación adecuada de sistemas de coordenadas durante las adquisiciones. El proceso de calibración descrito se basa en la metodología propuesta en [46], donde se indica que, básicamente, para el cálculo correcto de TDVs teóricos (que serán indispensables en el entrenamiento de las RNCs) es crucial definir el sistema de coordenadas que permita determinar la localización y orientación del transductor con respecto a la superficie del componente. Esto debe definirse empleando un sistema Cartesiano de componentes (x , y , z) y rotaciones parametrizadas mediante ángulos de rotación ($\theta_x \theta_y \theta_z$). Esto se concreta en términos de un vector de posición propio del lenguaje del robot colaborativo, consistente en los valo-

3.1. CONFIGURACIÓN DEL ENSAYO

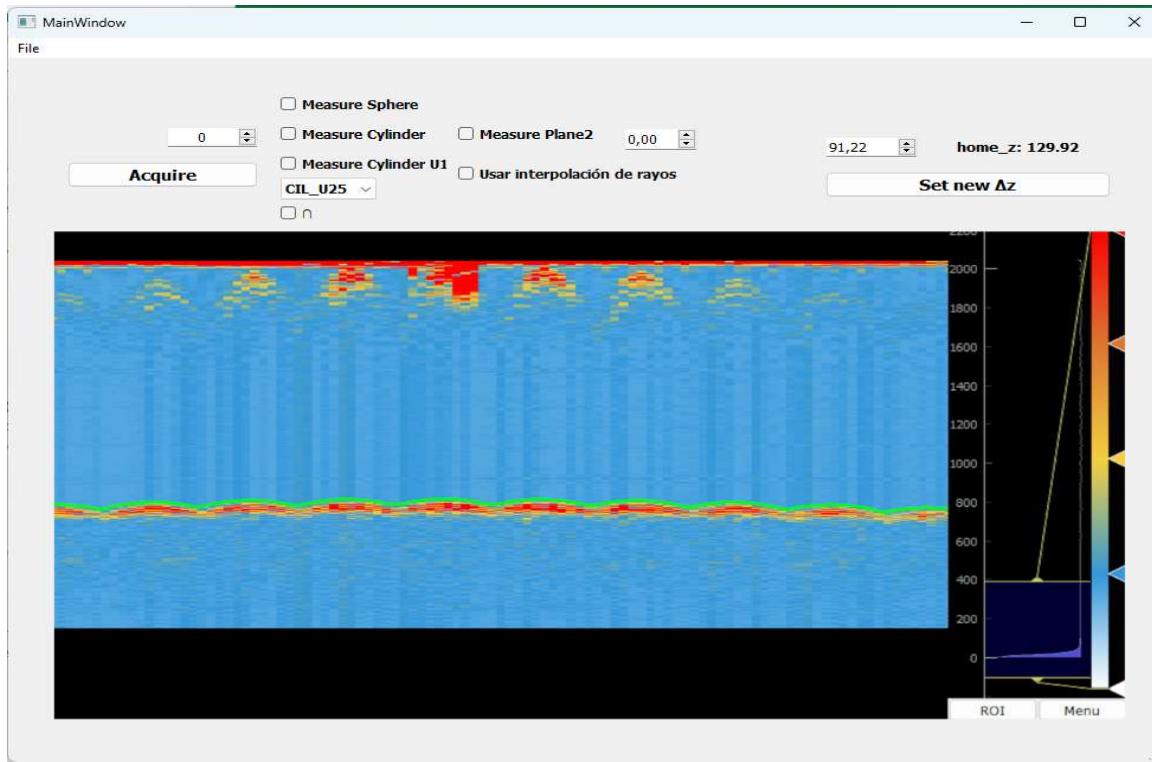


Figura 3.6: GUI 3

res de traslación y orientación, un vector de posición conocido como Punto Central de la Herramienta (PCH).

Es necesario, entonces, dar una descripción de la relación entre el sistema de coordenadas base, el sistema de coordenadas del *flange* (rectángulo naranja en figura 3.7), y el **Punto Central de la Herramienta (PCH)**, que es el punto en el espacio donde se ubica el transductor, y a partir del cual se determinarán las trayectorias del mismo. En términos generales: **1) El sistema de coordenadas base**, está fijado en la base del robot, normalmente donde se encuentra la primera articulación del brazo del robot. Este sistema sirve como referencia global para todos los demás sistemas de coordenadas. Todas las posiciones y orientaciones de las articulaciones, el *flange* y el PCH del robot se describen inicialmente en relación con este sistema de coordenadas base. **2) El sistema de coordenadas del *flange***, es importante para definir la orientación de montaje de las herramientas. Cualquier herramienta montada en el *flange* hereda este sistema de coordenadas como referencia inicial. **3) El sistema de coordenadas asociado al PCH** se fija al punto exacto de la herramienta donde se centra la operación del robot (en nuestro caso, el elemento central del transductor matricial). Este sistema de coordenadas es crucial para

especificar la posición y la orientación de la herramienta en el espacio, especialmente al programar tareas. Además, cuando el controlador del robot aplica una rotación al PCH, en realidad está rotando todo el sistema de coordenadas local del PCH alrededor de los ejes del sistema de coordenadas base.

Desde la base al *flange*: la posición y la orientación del sistema de coordenadas del *flange* se definen en relación con el sistema de coordenadas de la base. A medida que las articulaciones del robot se mueven, la posición y la orientación del *flange* cambian en relación con la base, según lo determinan las ecuaciones de cinemática directa del robot. Matemáticamente, esta relación se puede expresar mediante una serie de transformaciones (rotaciones y traslaciones) que definen la posición y la orientación del *flange* en relación con la base. **Desde el *flange* al PCH:** La posición y la orientación del PCH se definen en relación con el sistema de coordenadas del *flange*. La transformación del *flange* al PCH, se la denomina PCH_{offset} , e implica trasladar una distancia fija (si el PCH está desplazado con respecto al *flange*) y posiblemente rotar, según cómo esté montada la herramienta. Si la herramienta está alineada con el *flange*, el sistema de coordenadas del PCH_{offset} puede ser una simple traslación a lo largo del eje-*z* del sistema del *flange*. Sin embargo, si la herramienta está montada en un ángulo o desplazada, será necesaria una combinación de traslación y rotación para definir el PCH_{offset} en relación con el *flange*. Esta es una constante asociada al montaje de la herramienta.

Configuración inicial

El primer paso que se debió realizar fue determinar la posición de partida del PCH. La posición y orientación del transductor en el PCH, es relativa a la base del robot, y la programación de sus movimientos es en base a esta relación. A este punto inicial se lo denominó HOME. En la figura 3.7 se indica el PCH por defecto del brazo, i.e., el *flange* (rectángulo naranja), pero a este se añadió una extensión donde se emplazaría al transductor, definiendo así un PCH_0 como aproximación inicial basada en el diseño nominal de la extensión para montar el transductor (círculo naranja). En el código de control se define entonces el PCH inicial teniendo en cuenta dicha extensión (262 mm). El comando de control de movimiento del robot trabaja con vectores posición de 6 valores, 3 para desplazamiento y 3 para rotaciones dentro del sistema de coordenadas. Los tres valores de

3.1. CONFIGURACIÓN DEL ENSAYO

rotación los interpreta en términos de un vector de rotación, que es una manera compacta de representar una rotación en un espacio 3D. Este vector (\mathbf{r}) lleva la siguiente información: en su **1) dirección** indica el eje de rotación, $\hat{\mathbf{v}}$, es decir, el vector que representa la linea alrededor de la cual se llevará a cabo dicha rotación; y en su **2) magnitud**, $\|\mathbf{r}\|$, indica el ángulo de rotación, θ , expresado en radianes (ver ecuación 3.1).

$$\mathbf{r} = \theta \hat{\mathbf{v}} = \theta \begin{pmatrix} v_x \\ v_y \\ v_z \end{pmatrix} \quad (3.1)$$

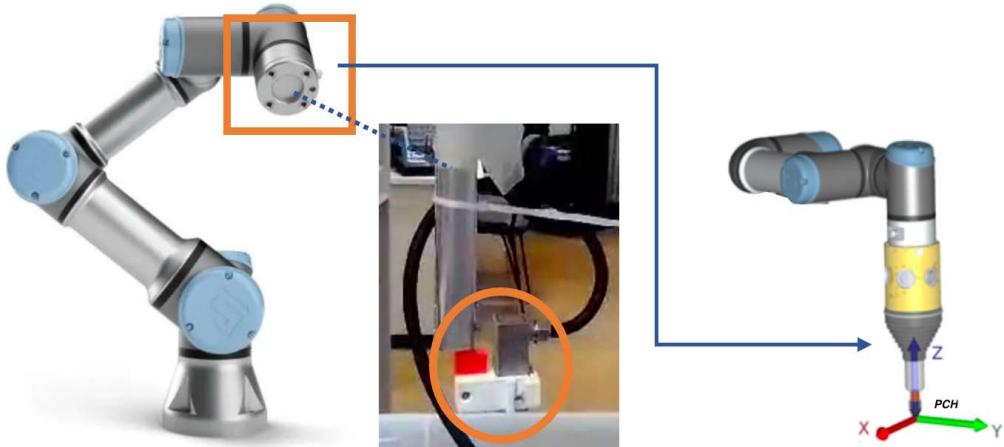


Figura 3.7: Posición de Punto Central de Herramienta (PCH). *Flange* (rectángulo naranja). PCH_{offset} (círculo naranja). Y sistema de coordenadas *flange*. Modificado de [43]

Ajuste del Centro del Transductor

Valga aclarar que se necesita realizar este ajuste de redefinir el punto PCH al elemento central del transductor, por que, como se ha comentado con anterioridad, es este punto a partir del cual se determinan todas las trayectorias, por consiguiente, si se desea que las traslaciones y posiciones del transductor sean lo más exactas posibles es necesario posicionar este punto de referencia en el centro del transductor.

Primero se parte con una estimación inicial del punto central de la herramienta, un $PCH_0 = [30\text{ mm}, 0\text{ mm}, 262\text{ mm}, 180^\circ, 0^\circ, 0^\circ]$. Los primeros tres valores indican

la distancia desde el origen del sistema de coordenadas base, es decir, el PCH_0 se encuentra a 31 mm en el eje- x , 0.1 mm en el eje- y , 262 mm en el eje- z . Las tres últimas cantidades representan la orientación del PCH_0 , lo que quiere decir que el sistema de coordenadas de la estimación inicial se ha rotado en 180° en el eje- x . Valga notar que en el proceso que se describe a continuación, todas las rotaciones se harán con respecto a este punto. Ahora, la idea de alinear el centro del transductor tiene que ver con redefinir el PCH de tal manera que éste corresponda al elemento central del arreglo matricial. La figura 3.8 muestra la situación descrita.

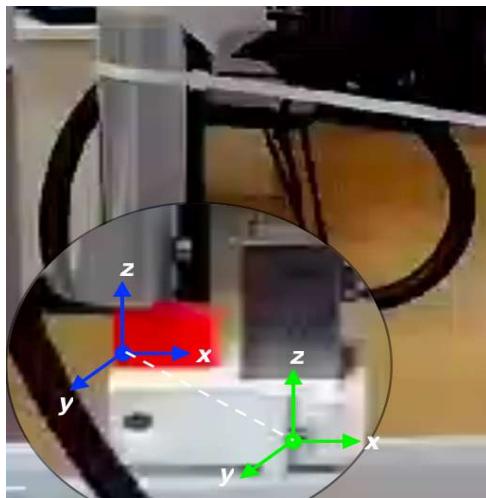


Figura 3.8: Alineamiento del PCH al centro del transductor

Como se ha comentado anteriormente, el transductor es un arreglo matricial de 121 elementos, distribuidos en filas de 11 elementos (del 1 al 11, del 12 al 22, hasta la fila del elemento 111 hasta el 121). El elemento central corresponde entonces al elemento 60, ubicado en el centro de la matriz. El cambio del PCH hacia el elemento central del transductor resulta necesaria por que, una vez establecida dicha posición, todos los subsecuentes movimientos y acciones del robot se calcularán en base al PCH definido. Ahora, el proceso consistió en generar un barrido del transductor en distintas combinaciones de ángulos para los ejes x e y , sobre una pieza plana rectangular. Esto con el fin de utilizar el efecto de dichas inclinaciones en los TDVs del elemento central (figura 3.9). Por otro lado, para corregir el desajuste entre PCH_0 , y PCH se utiliza un modelo de optimización por cuadrados mínimos, que depende de dicho desajuste. El modelo calcula TDVS teóricos, y obtiene valores de corrección del desajuste al minimizar la diferencia entre TDVs medidos y calculados. Esta técnica garantiza que el PCH represente la posición del elemento central, lo que permite un control y alineación precisos de la posición del transductor. A continuación se

3.1. CONFIGURACIÓN DEL ENSAYO

desglosa este procedimiento paso por paso.

1) Mediante la interfaz gráfica se automatiza las trayectorias del transductor sobre la pieza plana. Se decidió por un rango de inclinaciones para x e y entre -12° a 12° (ver figura 3.5, módulo 5, campos θ_x y θ_y), de tal manera que para cada inclinación en x se recorrian todas las inclinaciones en y , hasta culminar todas las combinaciones posibles, obteniendo en cada una su correspondiente A-scan. Valga notar que la ley focal definida para estas adquisiciones fue de *pulso-eco*, es decir, el mismo elemento que emite, recibe la señal. **2)** Posterior a la adquisición de las señales, los tiempos de vuelo se miden empleando el método de cruce de umbral, que se logra seleccionando el primer punto (índice) donde la envolvente de cada señal supera un umbral preestablecido, y dividiéndolo por la frecuencia de muestreo. La función que implementa la técnica retorna también el valor máximo de amplitud del eco detectado, que se utilizará en un subsecuente cálculo. **3)** A continuación se calculan los valores ΔTDV , es decir, la diferencia entre el TDV para cada par de ángulos de rotación y el TDV obtenido para la posición base, i.e., el par $(0^\circ; 0^\circ)$. Este cálculo básicamente nos da información del efecto que cada orientación tiene en el tiempo de vuelo para el elemento central. El TDV para la inclinación base representa el valor de referencia, a partir del cual se evalúa el efecto de las inclinaciones aplicadas. Cualquier inclinación del transductor modificará este TDV de referencia, y la diferencia entre estos valores, ΔTDV , nos entrega una cantidad que nos permite caracterizar la posición del elemento central, que es nuestro PCH objetivo (ecuación 3.2).

$$\Delta TDV = TDV(\theta_x, \theta_y) - TDV(0^\circ, 0^\circ) \quad (3.2)$$

La figura 3.9 muestra el esquema del procedimiento para obtener los valores ΔTDV . Aquí se puede visualizar como el elemento central del transductor traza una trayectoria sobre un círculo en cada rotación (con respecto a PCH_0). Se indica también el vector que representa los parámetros a optimizar mediante la búsqueda de mínimos cuadrados, que se explica más adelante ($PCH - PCH_0$).

4) Ahora, para redefinir el PCH actual para que coincida con el elemento central , se debe modificar las coordenadas de posición de la estimación inicial, PCH_0 , es decir, se

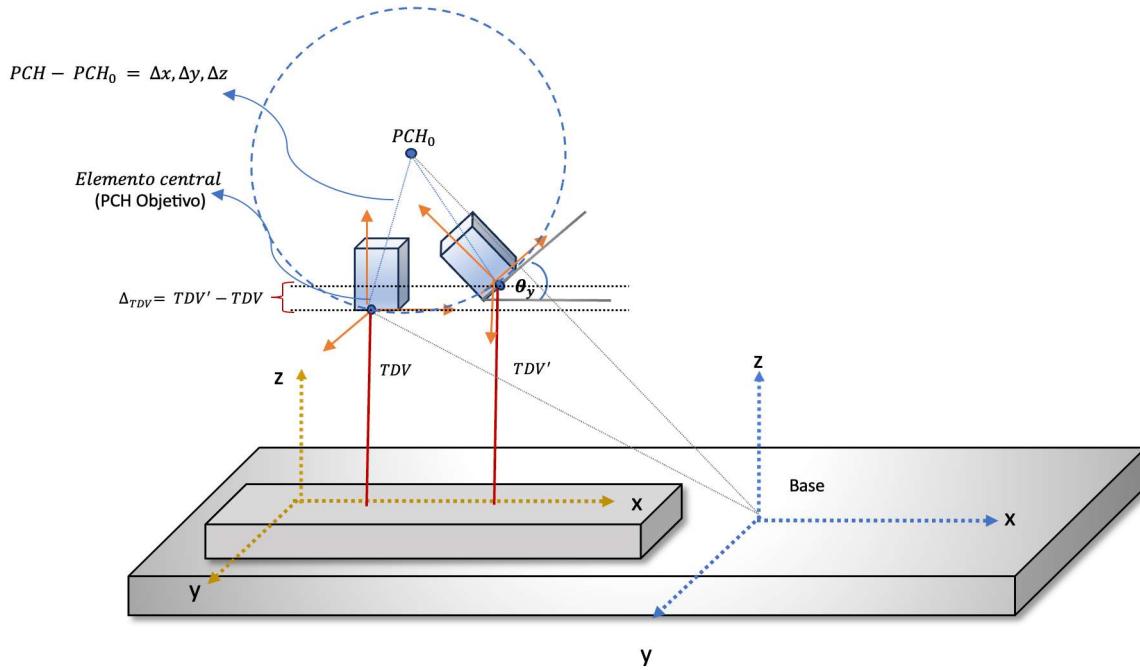


Figura 3.9: Esquema del procedimiento para obtener Δz

requieren los valores que transladen dichas coordenadas a nuestro PCH objetivo. La idea general es buscar los valores (Δx , Δy , Δz), que se indican en la figura 3.9, para minimizar lo más posible los residuos de las diferencias entre TDVs medidos y TDVs teóricos. Se genera una modelo que simula la trayectoria circular que recorre el elemento central del transductor al rotar sobre los ejes x e y con respecto a PCH_0 . Esto se logra al aplicar las mismas combinaciones de ángulos de rotación empleados en el barrido descrito en el punto 1) a distintos valores de (Δx , Δy , Δz)³. A partir de esto se calculan valores de Δz (ver figura 3.10) y se obtienen tiempos de vuelo teóricos para cada inclinación, y su correspondiente ΔTDV^* al dividir Δz por la velocidad de propagación del sonido en el agua, teniendo en cuenta que los datos medidos se los adquiere mediante la técnica de inmersión. Las ecuaciones 3.3 a 3.7 sintetizan el cómputo definido. En la ecuación 3.4 R_x y R_y representan las rotaciones aplicadas en los componentes x e y respectivamente, y R_{xy} es la rotación compuesta.

$$\Delta z = f(\Delta x, \Delta y, \Delta z; \theta_x, \theta_y) \quad (3.3)$$

³Para esto se empleó el método `Rotation.from_euler()` del paquete `transform`, de la librería `scipy.spatial` de Python. Esta función se utiliza para crear una rotación a partir de ángulos de Euler, en este caso las orientaciones definidas

$$\mathbf{R}_{xy} = \mathbf{R}_y(\theta_y) \cdot \mathbf{R}_x(\theta_x) \quad (3.4)$$

$$\begin{pmatrix} x' \\ y' \\ z' \end{pmatrix} = \mathbf{R}_{xy} \cdot \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta z \end{pmatrix} + \mathbf{PCH}_0 \quad (3.5)$$

$$\Delta z(\theta_x, \theta_y) = z'(\theta_x, \theta_y) - z'(0^\circ, 0^\circ) \quad (3.6)$$

$$\Delta TDV^* = \frac{\Delta z}{c} \quad (3.7)$$

5) Para llevar a cabo esta exploración de posibles coordenadas de posición, ($\Delta x, \Delta y, \Delta z$), se apela a la función de mínimos cuadrados⁴, que iterativamente adapta los parámetros para encontrar el mejor ajuste entre los ΔTDV y los ΔTDV^* . Esta función requiere, a su vez, un método que compute residuos ponderados, en este caso se pondrá la diferencia ($\Delta TDV^* - \Delta TDV$) con los valores máximos de amplitud de los ecos detectados en la técnica de cruce de umbral, mencionados previamente (w) (ver ecuación 3.8).

$$res = w(\Delta TDV^* - \Delta TDV) \quad (3.8)$$

La figura 3.10 muestra el proceso descrito en la exploración de parámetros llevada a cabo por el método de mínimos cuadrados.

Como se indicó, esta función explora el efecto de rotaciones sobre un amplio conjunto de posibles coordenadas de posición que determinarán los valores de corrección para redefinir el PCH sobre el elemento central del transductor matricial. Lo que se visualiza en la

⁴Se utiliza la función *least_squares*, del paquete *optimize*, de la librería *scipy* de Python

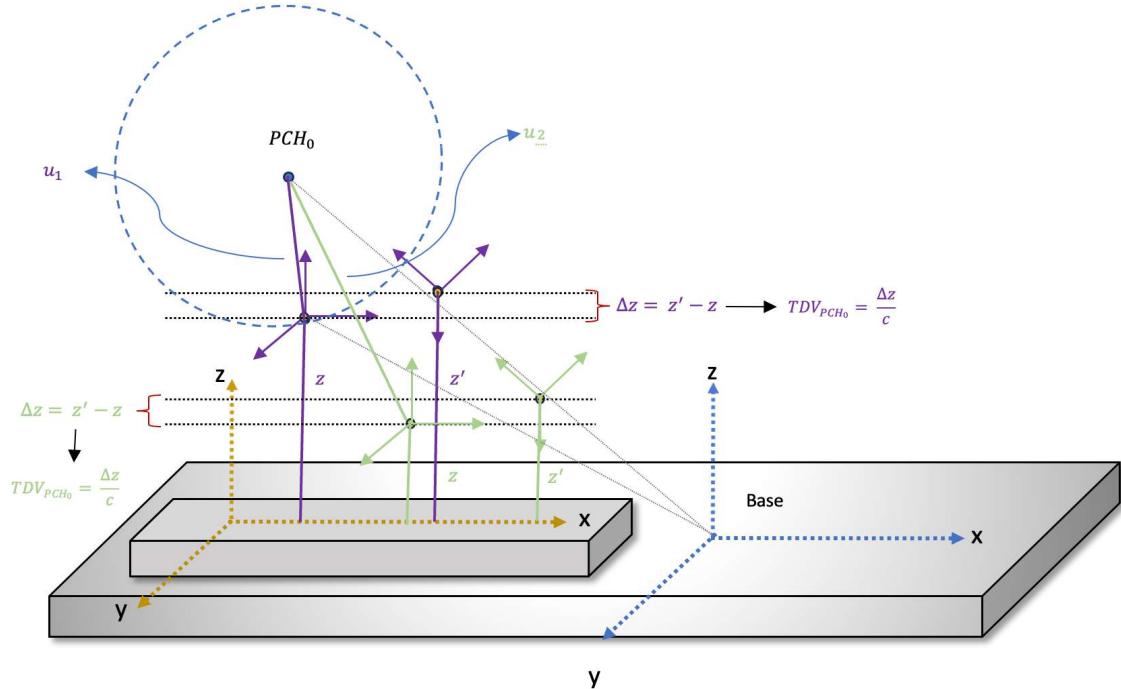


Figura 3.10: Esquema del procedimiento para obtener ΔTDV^*

figura es un ejemplo de dos posibles y arbitrarias estimaciones sugeridas por la función de mínimos cuadrados. La posición representada por las coordenadas violetas representa la posición que coincide idealmente con el elemento central del transductor, y por lo tanto aquella que minimizaría por completo la función de residuos ponderados (vector \mathbf{u}_1). Por otro lado, la posición representada por las coordenadas verdes calcula un ΔTDV^* que discrepa considerablemente de los ΔTDV (medidos), y por consiguiente la función de mínimos cuadrados no la seleccionaría para determinar los parámetros de corrección que modifiquen PCH_0 para posicionar PCH sobre el elemento central del transductor (vector \mathbf{u}_2).

El resultado entregado por la función de optimización (mínimos cuadrados) de parámetros se lo aplica a las coordenadas de la estimación inicial, PCH_0 , $\text{xyz_PCH}_0 = (x_0, y_0, z_0)$, para obtener los valores correspondientes del PCH corregido. La ecuación 3.9 muestra el cálculo, donde $\Delta_{xyz} = (\Delta x^*, \Delta y^*, \Delta z^*)$, corresponden a los valores de corrección óptimos.

$$\text{xyz_PCH} = \text{xyz_PCH}_0 + \Delta_{xyz} \quad (3.9)$$

3.1. CONFIGURACIÓN DEL ENSAYO

Tenemos entonces:

Estimación Inicial: $\text{PCH}_0 = [30 \text{ mm}, 0 \text{ mm}, 262 \text{ mm}, 180^\circ, 0^\circ, 0^\circ]$

Ajuste: $\text{PCH}^* = [29.6 \text{ mm}, 0.5 \text{ mm}, 262.1 \text{ mm}, 180^\circ, 0^\circ, 0^\circ]$

La figura 3.11 muestra la comparación entre los TDVs medidos para el elemento central (puntos), y los TDVs ajustados con los parámetros optimizados (superficie gris). Lo que se desea mostrar es el resultado del modelo de mínimos cuadrados al aproximar los valores de corrección Δ_{xyz} (en términos de los TDVs correspondientes) como el plano que mejor representa la distribución de los valores medidos. Valga notar que la figura en la derecha presenta un gradiente de color debido a la función ponderada que la función de optimización utiliza para minimizar los errores.

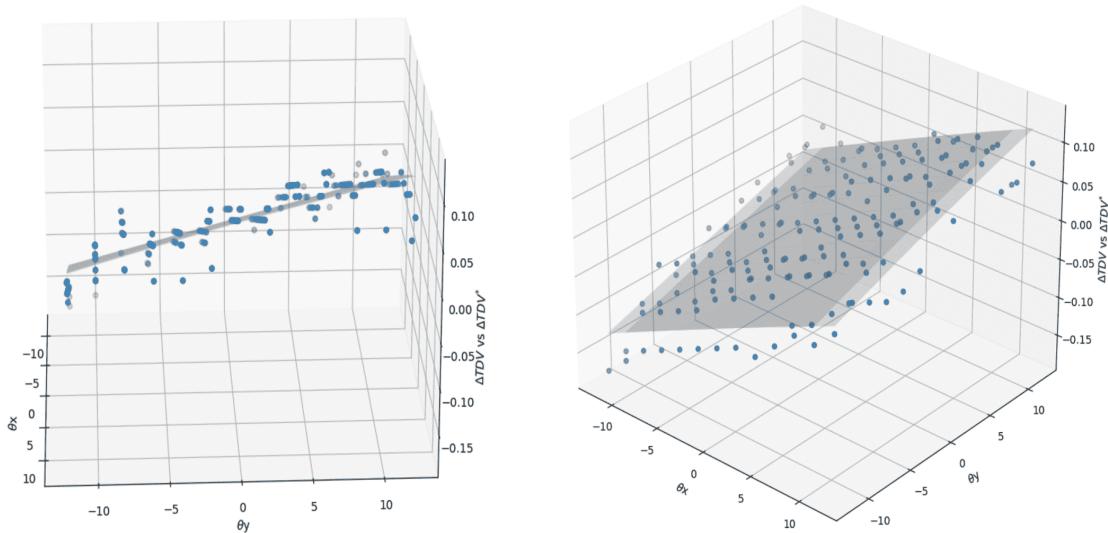


Figura 3.11: Ajuste del modelo (ΔTDV^* , superficie gris) con respecto a las mediciones experimentales (ΔTDV , puntos)

Alineamiento (Paralelismo) del transductor con respecto al sistema de referencia base

El procedimiento llevado a cabo involucra dos distintos barridos del transductor sobre la pieza plana. El primero de estos es el mismo que se ha descrito para el ajuste del elemento central en el apartado anterior. El segundo barrido consiste ahora en fijar una inclinación en el componente x y variar la orientación en el componente z para un rango específico.

La razón para esto es aislar el efecto que los cambios en el componente z tienen sobre los TDVs a lo largo de una fila determinada de elementos del transductor (elementos del 1 al 11). El propósito de ambas exploraciones es, entonces, ajustar la orientación del transductor para garantizar que esté alineado correctamente (paralelo) con respecto a la superficie desde la cual recibe los ecos.

Búsqueda θ_x y θ_y : El criterio aplicado fue iniciar con una exploración amplia en el rango de ángulos, y luego, en base a los resultados reducir el espacio de búsqueda con variaciones más sutiles en cada inclinación. Para la exploración amplia, se arranca con un rango de (-12° a 12°) para cada componente, el transducto cubre todos las inclinaciones en el eje x , para la cada inclinación en el eje y , hasta culminar todas las posibles combinaciones; esto en pasos de 2° para cada iteración. Para cada combinación de orientaciones, se obtienen los TDVs para cada uno de los 5 elementos activos (esquinas y elemento central), se calcula la diferencia entre el TDV_{max} y el TDV_{min} , y se evalua la mejor combinación de ángulos de rotación como aquella que corresponda a la menor diferencia. Esto nos informa de la mejor posición del transductor para que este se encuentre lo más paralelo posible con respecto al plano reflectante. Las siguientes ecuaciones expresan el criterio de evaluación para cada par de ángulos de orientación. Siendo $i, j = [-12^\circ; 12^\circ]$, y $(\theta_x, \theta_y)^*$ la combinación óptima:

$$\Delta TDV_{i,j} = \max(TDV_{i,j}) - \min(TDV_{i,j}) \quad (3.10)$$

$$(\theta_x, \theta_y)^* = \arg \min_{i,j} (\Delta TDV_{i,j}) \quad (3.11)$$

De esta manera, se obtiene una primera estimación de las rotaciones que posicionarán al transductor paralelamente a la superficie de referencia. Tras aplicar los cálculos descritos, la combinación óptima resultante fue $(\theta_x, \theta_y)^* = [-2^\circ; 2^\circ]$. Como se ha comentado previamente, posterior a esta primera búsqueda se define un nuevo rango de exploración en base a este resultado, y se lleva a cabo un sondeo más sutil dentro del mismo, es decir, apelando a una variación angular más pequeña. El criterio fue tomar cada ángulo

3.1. CONFIGURACIÓN DEL ENSAYO

resultante como centro de los nuevos rangos para cada θ , y desplazarse 2° para adelante y atrás, es decir, los nuevos rangos fueron los siguientes: $\theta_x = [-4^\circ; 0^\circ]$ y $\theta_y = [0^\circ; 4^\circ]$. La figura 3.12 indica: por un lado, el esquema de la búsqueda de ángulos de rotación óptimos iniciales, donde se muestra la combinación que minimiza el $\Delta TDV_{i,j}$, y la nueva área de exploración; y por otro lado, cada valor de $\Delta TDV_{i,j}$ para cada par (θ_x, θ_y) .

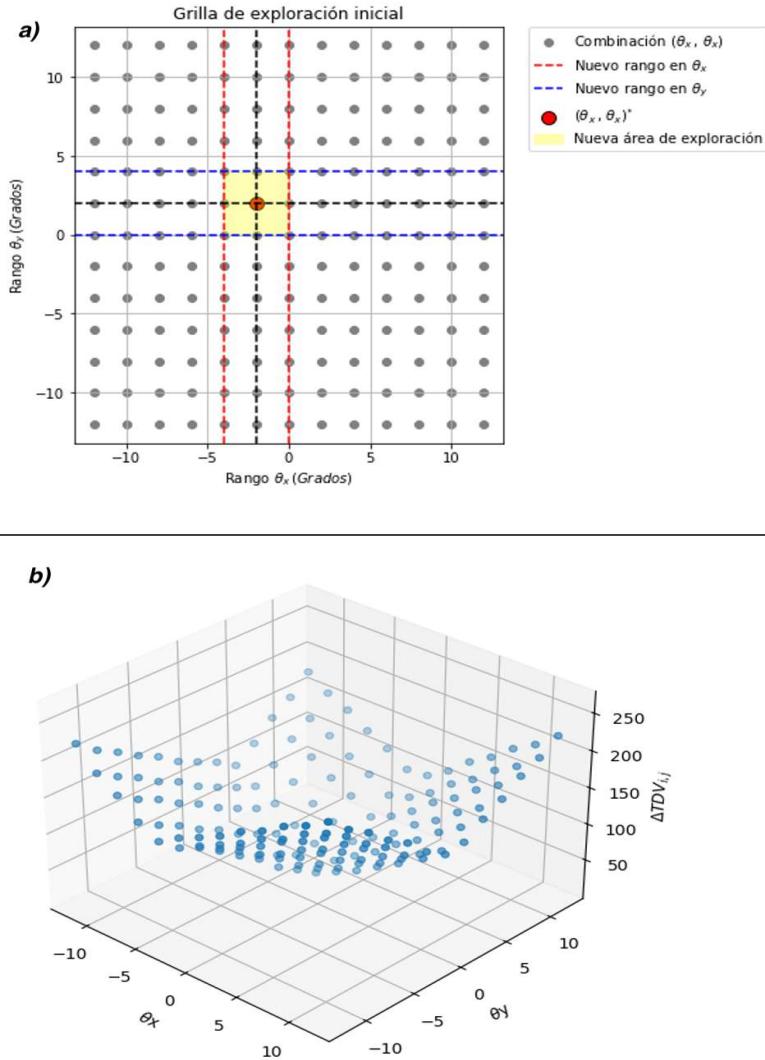


Figura 3.12: Alineamiento paralelo: a) Esquema de exploración inicial. b) $\Delta TDV(\theta_x, \theta_y)$

La segunda exploración, sobre los nuevos rangos (θ_x, θ_y) , se la realiza con pasos de 0.2° . El procedimiento para determinar la combinación óptima de orientaciones es el mismo que se ha descrito en el párrafo anterior. El resultado de esta búsqueda nos entrega un par óptimo de $(\theta_x, \theta_y)^* = [-2.2^\circ; 2.6^\circ]$. De la misma manera, la figura 3.13 indica el esquema final de sondeo, y los $\Delta TDV_{i,j}$.

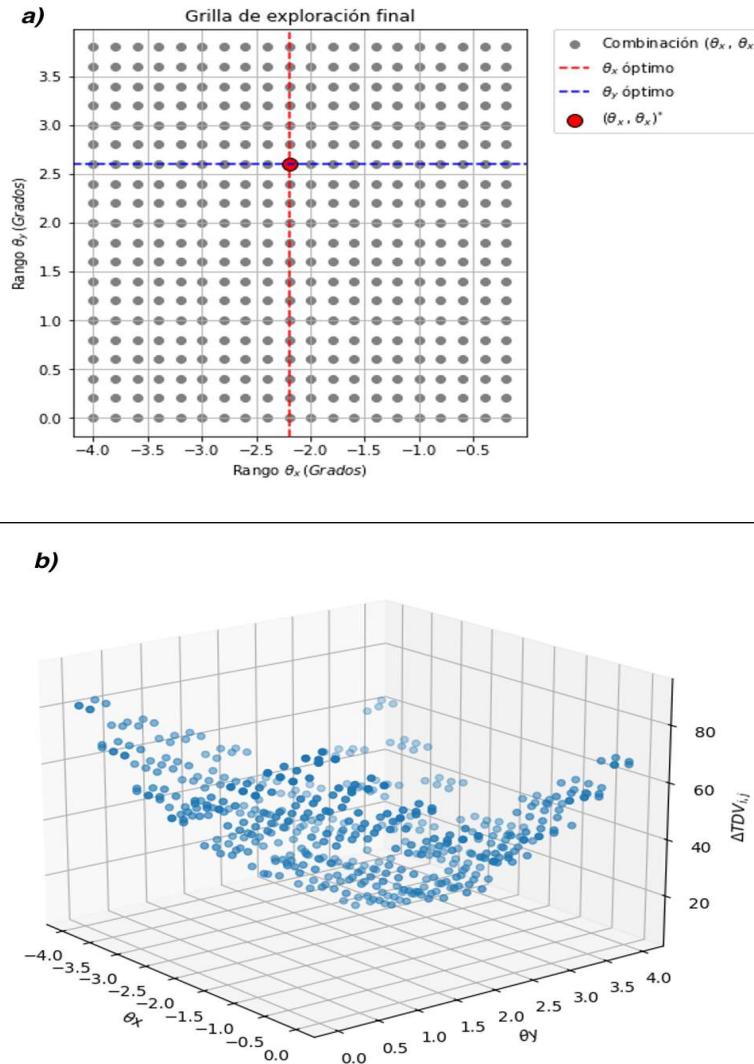


Figura 3.13: Alineamiento paralelo: a) Esquema de exploración final. b) $\Delta TDV(\theta_x, \theta_y)$

Búsqueda θ_z : Como se indicó previamente, en este caso se mantiene fija una inclinación en el componente- x mientras se varía la orientación para la coordenada z . Más exactamente, las rotaciones se las instancia como ángulos de Euler, es decir, primero se aplica la rotación en z , y luego la rotación en x . Esta rotación se la define en una posición sin translación, y en cada iteración cada movimiento parte desde una posición base (que se la denominó HOME). El criterio es el mismo, al recorrer distintas inclinaciones del componente z , se evalúa cómo la orientación en la dirección z afecta las diferencias del tiempo de vuelo en los elementos de la fila. La adquisición de datos es igual, i.e., mediante la técnica *pulso-eco*, utilizando una fila de elementos del transductor, se calcula la diferencia entre TDV mínimo y máximo por cada posición, y se extrae la combinación de ángulos de orientación que minimiza dicha diferencia. La lógica detrás de la exploración consiste

3.1. CONFIGURACIÓN DEL ENSAYO

en localizar la posición en que la fila activa de elementos del transductor (que corresponde a su eje- x), se encuentre alineada con la coordenada x del punto HOME, ya que es en este punto en el que las distancias (Δz) desde cada elemento hacia el plano de referencia—representadas por los TDVs medidos—son iguales para todos.

Partimos de una posición en la cual el eje- x del transductor se encuentra desalineado con respecto al eje- x de las coordenadas HOME, y se da inicio al barrido en θ_z . Debido a la inclinación fija en x , para específicas rotaciones en z los elementos en la fila activa tomarán posiciones en diferentes alturas con respecto al plano de referencia, y esto se evidenciará en distintos TDVs. En la figura 3.14.a, se muestra una posible posición en la búsqueda, donde se puede observar claramente como los elementos activos toman diferentes posiciones a lo largo de la coordenada z . El efecto sobre los tiempos de vuelo de una rotación en z , que desalinea los ejes- x del HOME y del transductor, se representa en la figura 3.14.b, haciendo referencia a las alturas Δz . Ambas líneas verdes tienen la misma longitud, y el pequeño segmento en rojo indica el excedente para Δz_{10} .

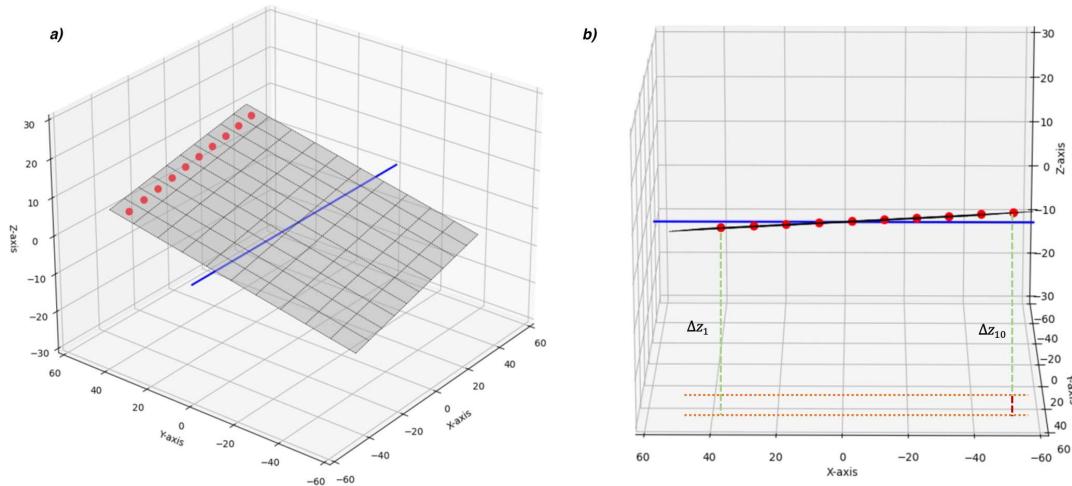


Figura 3.14: Alineamiento paralelo: Esquema de exploración en componente- z . **a)** Inclinación fija en x , y rotación en z , que desalinea con HOME- x . **b)** Distancias de recorrido distintas para los elementos ($\Delta z_1 \neq \Delta z_{10}$)

Por otro lado, la figura 3.15 representa el escenario ideal, donde se ha logrado el objetivo de alinear ambos ejes x . En la izquierda se representa al transductor con orientación fija en el eje- x , y rotación en z tal que los elementos activos coinciden con el eje- x de las coordenadas HOME. En la derecha se muestra una perspectiva que permite visualizar que en dicha posición los TDVs reflejarán las mismas distancias Δz para todos los elementos activos.

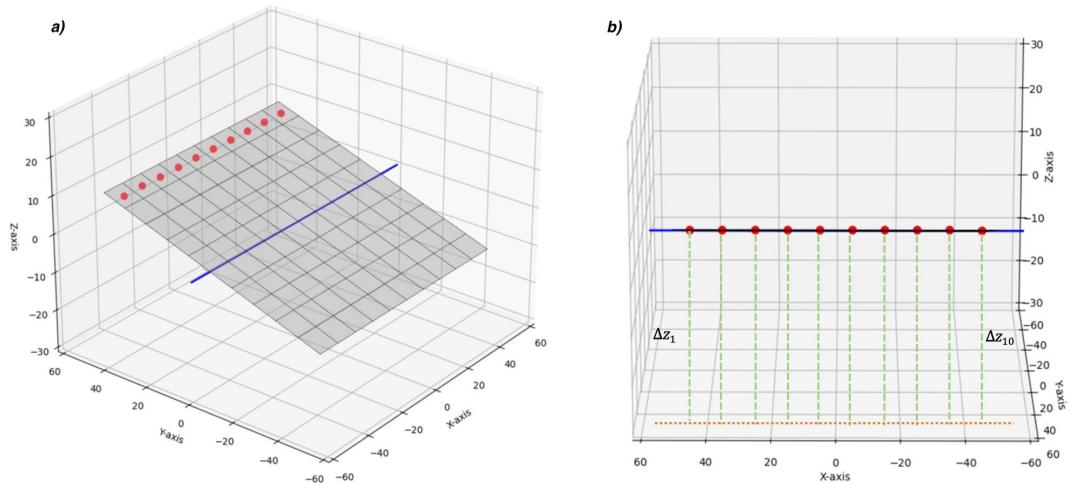


Figura 3.15: Alineamiento paralelo: Esquema de exploración en componente- z . a) Inclinación fija en x , y rotación en z , que alinea con HOME- x . b) Distancias de recorrido iguales para los elementos ($\Delta z_1 = \Delta z_{10}$)

Se consideró que el rango de búsqueda en el eje z no necesariamente debía cubrir muchas posibilidades, ya que visualmente se podía reconocer que la corrección necesaria no lo requería. Por lo tanto, el rango de exploración se lo delimitó entre, $\theta_z = [0^\circ; 15^\circ]$, con pasos de 0.5° . De esta manera se determinó una orientación óptima en z , $\theta_z^* = 8^\circ$, teniendo en cuenta que la figura 3.16, que indica los resultados de esta búsqueda, en términos de la minimización de $\Delta TDV(\theta_z)$, muestra distintos valores mínimos que se distribuyen con un promedio aproximado de 8° .

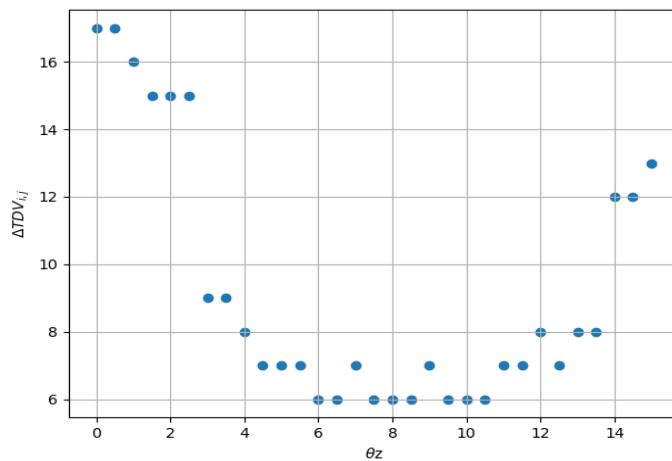


Figura 3.16: Alineamiento paralelo: Exploración de θ_z óptimos en función de los TDVs medidos

Configurando rotaciones: Una vez obtenidos los ángulos de rotación óptimos para cada

3.1. CONFIGURACIÓN DEL ENSAYO

componente del sistema de coordenadas del transductor, se procede a aplicarlos para el correspondiente alineamiento con respecto al plano de referencia. El criterio de corrección implicó una composición de rotaciones. La primera rotación aplicada, un giro de 180° , se considera la configuración inicial del sistema de coordenadas del *flange*, que presenta su eje-*z* apuntando en dirección contraria a la cara inferior del transductor, que es la dirección en que se emiten las señales ultrasónicas. La segunda rotación, toma los ángulos óptimos resultantes de la exploración (θ_x , θ_y), i.e., $[-2.2^\circ; 2.6^\circ]$, con un orden de inclinaciones, primero en el eje-*x*, y luego en el eje-*y*. La tercera considera la rotación en el eje-*z* (8°). Cada una de estas rotaciones se las instancia individualmente como objetos rotación a partir de ángulos de Euler, utilizando el método *transform*, del paquete *spatial*, de la librería *scipy* de Python. Esto permite generar la rotación compuesta como el producto de cada rotación, y se obtiene el resultado representado como un ángulo de Euler⁵ aplicado a las tres coordenadas. La ecuación 3.12 muestra la operación descrita, siendo entonces \mathbf{R}_F los ángulos correspondientes a nuestro PCH_{offset}, con el cual llevaremos a cabo el proceso de adquisición de datos a partir de las piezas de referencia.

$$\mathbf{R}_F = \mathbf{R}(\theta_z^*)^{-1} \mathbf{R}((\theta_x, \theta_y)^*)^{-1} \mathbf{R}(\theta_x = 180^\circ) \quad (3.12)$$

La aplicación de las inversas de las rotaciones en *x-y* y en *z*, tiene que ver con la relación entre el PCH y el sistema de coordenadas del *flange*.

Tenemos entonces:

Estimación Inicial: $\text{PCH}_0 = [30 \text{ mm}, 0 \text{ mm}, 262 \text{ mm}, 180^\circ, 0^\circ, 0^\circ]$

Ajuste: $\text{PCH}^* = [29.6 \text{ mm}, 0.5 \text{ mm}, 262.1 \text{ mm}, 180^\circ, 0^\circ, 0^\circ]$

Alineamiento: $\text{PCH}_1 = [29.6 \text{ mm}, 0.5 \text{ mm}, 262.1 \text{ mm}, -177.8^\circ, 2.6^\circ, 8^\circ]$

⁵Los ángulos de Euler son una forma de representar la orientación de un objeto en un espacio tridimensional mediante tres ángulos. Estos ángulos describen la rotación del objeto alrededor de los tres ejes principales (normalmente denominados *x-y-z*). Las tres rotaciones se aplican de forma secuencial.

3.2. Adquisición de Datos

En este apartado se describirá el proceso de toma, almacenamiento y procesamiento de datos para cada una de las piezas de referencia. En general, para cada pieza, el proceso consistió en: **1)** determinar parámetros necesarios para el cálculo preciso de los TDVs teóricos, y verificarlos con los B-scans asociados a cualquiera de los elementos del transductor matricial—es decir, se comprueba la coincidencia de los valores teóricos con los ecos revelados en la imagen generada para cualquier elemento i actuando como emisor y el resto de elementos actuando como receptores (método *pitch-catch*, FMC); **2)** verificar el alineamiento del transductor con respecto a su geometría; **3)** definir la secuencia de trayectorias, también en base a su geometría; y, finalmente, **4)** almacenar la información en formato crudo, i.e., datos A-scans e índices de cruce de umbral, con sus respectivos metadatos para el subsecuente post-procesamiento y entrenamiento de las RNCs. Valga notar que la adquisición se llevó a cabo en una configuración por inmersión. Todas las piezas fueron colocadas dentro de un cubo de plástico lleno de agua, a una altura fija con respecto al componente z del sistema de coordenadas base, es decir, la mesa de apoyo del UR10e (ver figura 3.17). Sobre esta altura de referencia se posicionó a todas la piezas y se estableció con un plano base arbitrario, con el fin de tener una configuración más estable. Su ubicación dentro del cubo fue lo más centrada posible, y lo más coincidente posible con las coordenadas HOME, a partir de las cuales iniciarán las trayectorias definidas.

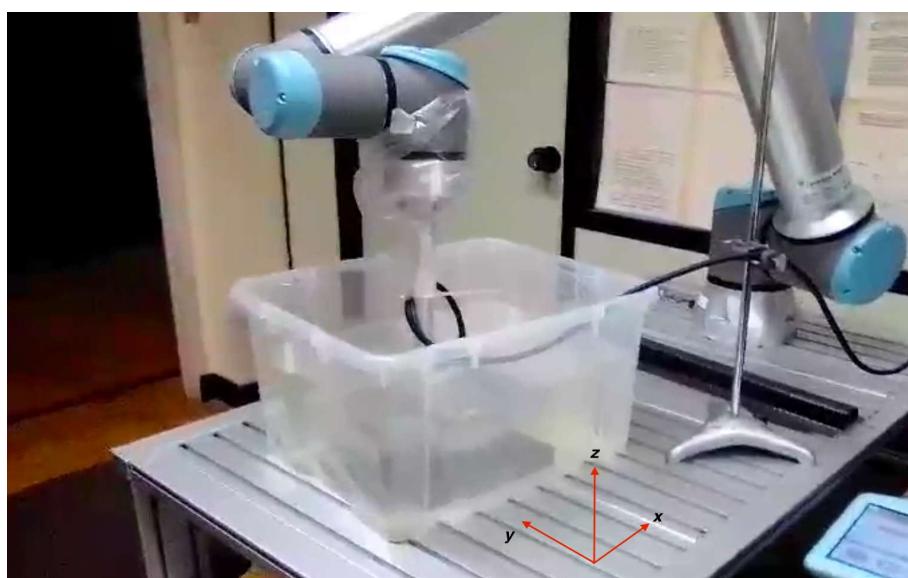


Figura 3.17: Cubo de inmersión para piezas de referencia en proceso de adquisición de datos

3.2. ADQUISICIÓN DE DATOS

El punto 1 del párrafo anterior, hace referencia al cálculo de los TDVs teóricos, que para cada geometría considerada utiliza criterios distintos. Sin embargo, la variable común para todos los casos es la distancia entre la superficie activa del transductor y un plano base de referencia. Esta variable se la denomina Δz . Cada pieza tiene su plano de referencia propio (que se definirá con mayor detalle en su sección correspondiente) y es esta cantidad, Δz , la que ayuda a estimar la distancia desde cada elemento a este plano de referencia que, a su vez, permite obtener el TDV. Este tiempo de vuelo calculado se superpone sobre las imágenes B-scan de las adquisiciones para evidenciar la eficacia del cálculo.

3.2.1. Estimación de Δz

La figura 3.18 muestra el procedimiento para estimar la variable Δz : 1) primero se define un punto de referencia, en nuestro caso, lo denominamos $HOME_{Init}$. A partir de este punto, utilizando la función incorporada en UR10e, `get_actual_tcp_pose()`, que nos entrega las coordenadas actuales del PCH se obtiene la cantidad de desplazamiento en el eje-z con respecto a $HOME_{Init}$. Entonces, por ejemplo, si el componente z en $HOME_{Init}$ es **100 mm** y el transductor es llevado a una posición cuyo componente z es **80 mm**, obtenemos un $\Delta z = 20 \text{ mm}$, es decir, nos hemos desplazado **20 mm** con respecto al punto de referencia. La idea, por lo tanto, consiste en trasladarse hasta tener contacto con la superficie de referencia, y así tendremos información de a qué distancia (en **mm**) se encuentra $HOME_{Init}$ del plano.

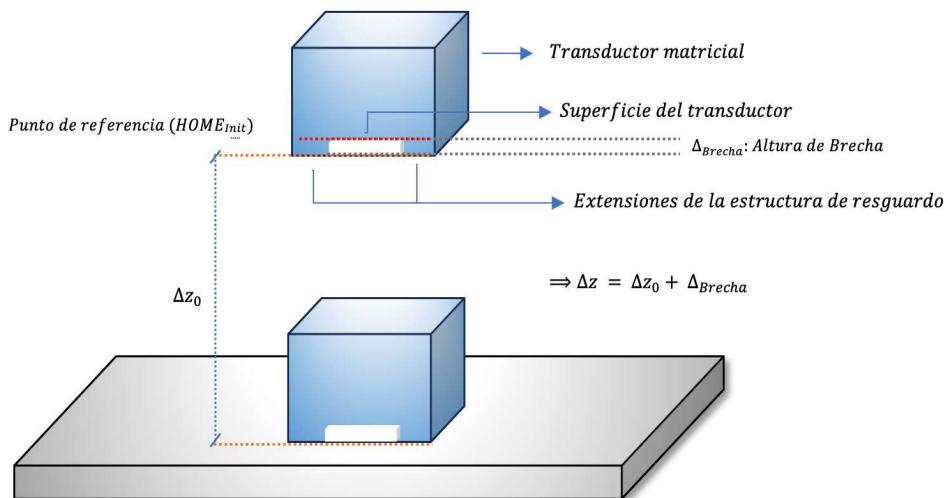


Figura 3.18: Estimación de Δz para TDVs teóricos

Ahora, debido a que el transductor ha sido resguardado por medidas de seguridad en una pequeña estructura que, como se observa en la figura, presenta unas cortas extensiones que harán contacto con el plano de referencia. Como lo que realmente se desea conocer es la distancia de los elementos del transductor con respecto al plano de referencia, la altura desde estas extensiones hasta la superficie del transductor se la debe considerar para definir al Δz final. El cálculo se define en la ecuación 3.13

$$\Delta z = \Delta z_0 + \Delta_{Brecha} \quad (3.13)$$

Es necesario aclarar que el plano de referencia para esta estimación corresponde al plano rectangular de la figura 3.1.

3.2.2. Plano Rectangular

Alineamiento pieza-transductor:

En el caso de esta pieza, para verificar su alineamiento con respecto al transductor se emplearon ciertas funcionalidades implementadas en la interfaz de usuario que se muestra en la figura 3.4. Para esta prueba se emplea la técnica de cruce de umbral, se aplica el método de pulso-eco y se activan solamente 5 elementos del transductor, sus esquinas y el elemento central. El criterio de evaluación fue detectar el primer eco para cada elemento activo, desplegar visualmente sus índices de cruce asociados para poder compararlos, y valorar el alineamiento del transductor con respecto al plano en términos de la diferencia de estos valores. Para esto se fija un *umbral de error de diferencia de índices* (campo 8 en la figura 3.4), que no debía superarse para satisfacer el criterio impuesto.

Entonces, primero se establece una ventana de trabajo (campos 5 y 6 de la GUI), que permite prevenir la captación de señales no deseadas (e.g., las emitidas por los generadores de pulsos de cada elemento); luego se desplaza el transductor, partiendo de la posición HOME, y aproximándose a la pieza lo suficiente para obtener una lectura clara de señales (esto se visualizará en la ventana de despliegue). La lectura de los índices para cada elemento se la realiza mediante las etiquetas de la sección 12 en la GUI, que indican los valores directos, y a través de líneas verticales superpuestas a la señales en la ventana de despliegue (para una evaluación visual más evidente). Tanto los valores como las líneas se

3.2. ADQUISICIÓN DE DATOS

actualizan conforme se detectan los ecos en cada elemento. En cada segmento de adquisición se calcula la diferencia del valor máximo y mínimo, se consulta si ésta sobrepasa el umbral de error definido, y de no superarlo, se considera alineado al transductor (esto se verá reflejado en el recuadro rojo de la figura 3.4, que se tornará verde al satisfacerse el criterio de alineamiento). La figura 3.19 muestra el resultado de la evaluación descrita para el plano previo a la toma de datos.

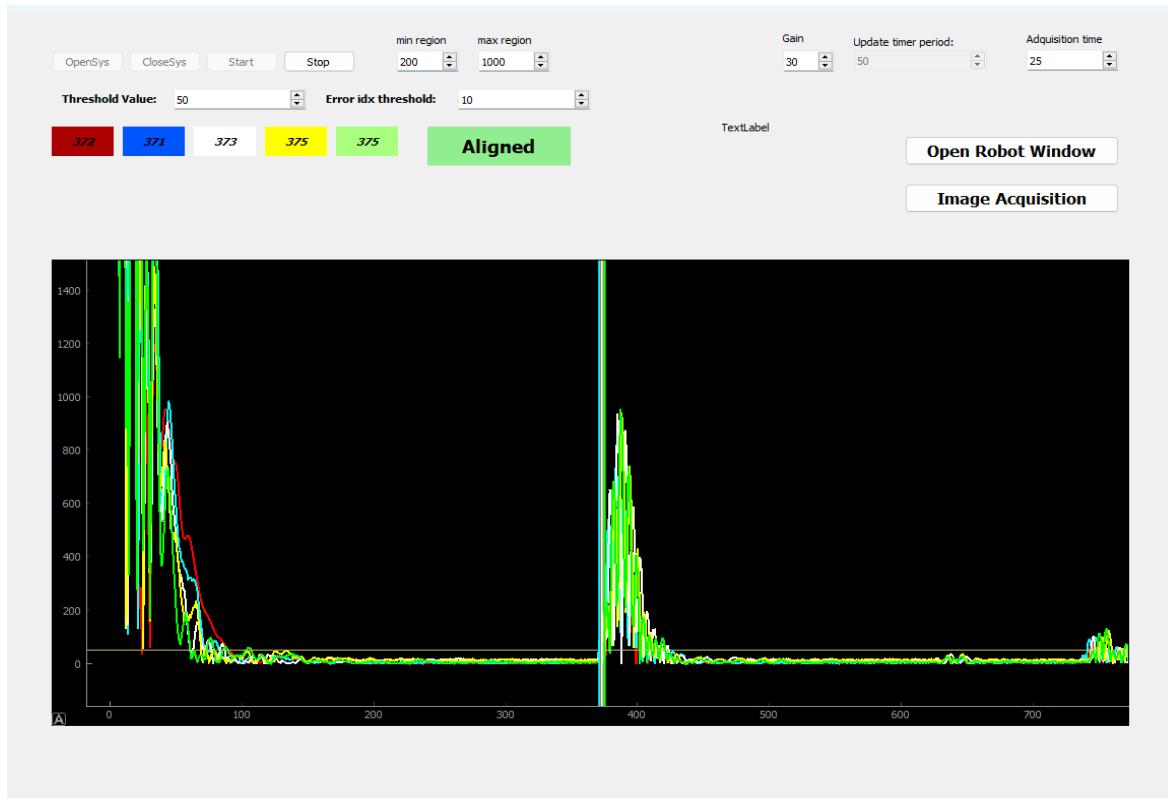


Figura 3.19: Evaluación de alineamiento transductor-plano en GUI 1

Cálculo de TDV teórico:

El cálculo de estos valores depende de la cantidad Δz estimada previamente, por lo tanto, previo a tomar los datos oficiales de la pieza, se lleva a cabo una verificación que los valores teóricos de TDVs se computen de manera correcta, ya que estos serán las *etiquetas* en el proceso de entrenamiento de las RNCs. De ser el caso que estos no correspondan adecuadamente a lo esperado, es necesario revisar el procedimiento de estimar Δz con mayor detenimiento. Este cálculo utiliza la ley de reflexión, que establece que los ángulos de incidencia y reflexión son iguales con respecto a la normal de la superficie ($\theta_{inc} = \theta_{refl}$). La figura 3.20 muestra el esquema de la geometría en del fenómeno de reflexión especular.

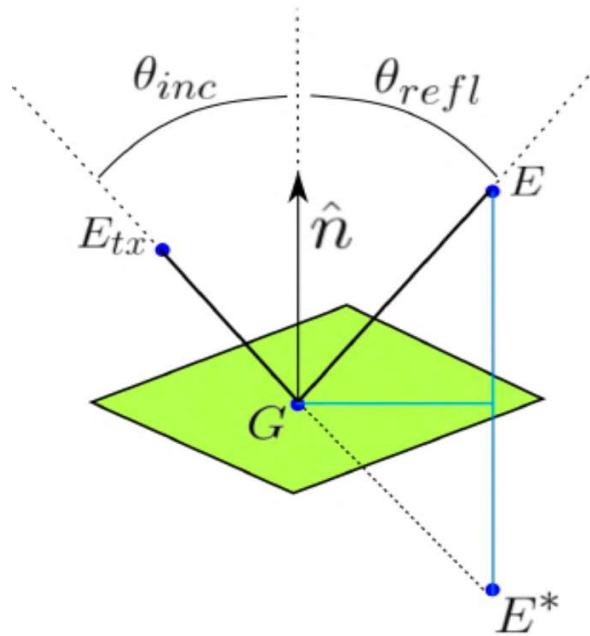


Figura 3.20: Geometría de la ley de reflexión (imagen especular). Tomado de [27]

Debido a esta relación de ángulos, la trayectoria desde \mathbf{E}_{tx} (elemento emisor) hasta \mathbf{E} (elemento receptor), tiene la misma longitud que el vector que une los puntos \mathbf{E} y \mathbf{E}^* (donde \mathbf{E}^* corresponde a la imagen especular del punto \mathbf{E}). De esta manera es posible representar la distancia recorrida por la señal desde que es emitida, se refleja y retorna al transductor, aplicando la norma del vector $\overline{\mathbf{EE}^*}$. Teniendo en cuenta que las coordenadas del punto \mathbf{E}^* son $(\mathbf{E}_x^*, \mathbf{E}_y^*, -\mathbf{E}_z^*)$, la ecuación 3.14 muestran el cómputo respectivo para obtener el TDV correspondiente, siendo c la velocidad de propagación en el agua.

$$TDV = \frac{1}{c} \sqrt{(\mathbf{E}_x - \mathbf{E}_x^*)^2 (\mathbf{E}_y - \mathbf{E}_y^*)^2 (\mathbf{E}_z + \mathbf{E}_z^*)^2} \quad (3.14)$$

Para obtener el TDV teórico para una adquisición en particular para el sistema de medida de este trabajo, se apela a este criterio. Primero es necesario obtener las coordenadas y ángulos de orientación de la posición actual del PCH, el programa entrega estos valores con respecto al punto de referencia HOME_{Init}, de tal manera que el componente z de esta posición indica el desplazamiento relativo del PCH con respecto a este punto de referencia, \mathbf{z}_0 en figura 3.21. En el escenario de la figura el valor de \mathbf{z}_0 es un valor negativo, ya que se lo calcula como la diferencia entre el componente z del PCH actual y el componente z de HOME_{Init}. Ya con \mathbf{z}_0 , y Δz podemos calcular la distancia entre los elementos del

3.2. ADQUISICIÓN DE DATOS

transductor y el plano de referencia, z_1 (ecuación 3.15).

$$z_1 = z_0 + \Delta z \quad (3.15)$$

Posterior a esto, se obtienen las coordenadas en **mm** de los elementos del transductor, tanto para el elemento emisor, como para los receptores; se aplican las rotaciones relativas del PCH a todas; se las desplaza a la posición z_1 , es decir la distancia estimada entre los elementos del transductor y el plan; se invierte el signo del componente z para las coordenadas del elemento emisor, para que represente el punto E^* de la figura 3.20; se computan las coordenadas para representar el vector $\overline{EE^*}$, y se obtiene su módulo correspondiente.

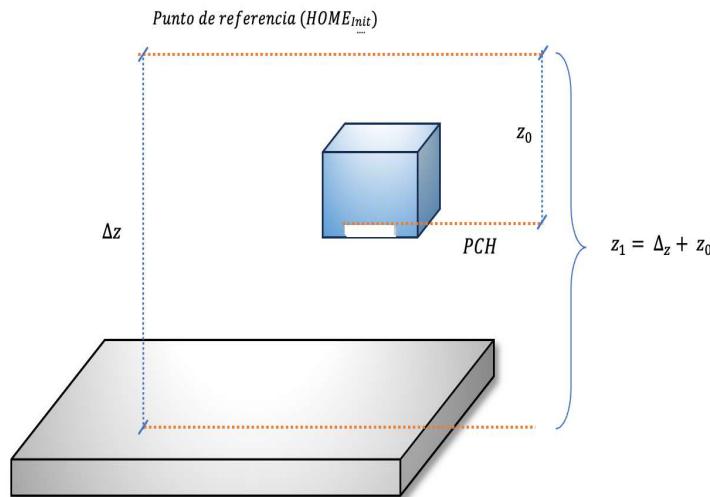


Figura 3.21: Posición de componente z con respecto a plano de referencia

Así se obtiene las distancias desde el elemento emisor, hasta el plano reflectante, y de vuelta a cada elemento receptor. Dividiendo para el valor de velocidad de propagación en el agua, tenemos nuestros TDVs teóricos para la posición de adquisición actual del transductor. Los cálculos descritos se lo representa en las ecuaciones 3.19 y 3.20, donde la matriz de elementos receptores P_h (ecuación 3.16), y el vector del elemento emisor p_h (ecuación 3.17) se escriben en su forma homogénea, y se utiliza la matriz de roto-traslación T (ecuación 3.18. Con r : rotaciones y t : traslaciones).

$$\mathbf{P}_h = \begin{bmatrix} x_1 & y_2 & z_1 & 1 \\ x_2 & y_2 & z_2 & 1 \\ \vdots & \vdots & \vdots & \vdots \\ x_{121} & y_{121} & z_{121} & 1 \end{bmatrix} \quad (3.16)$$

$$\mathbf{p}_h = [x \ y \ z \ 1]^T \quad (3.17)$$

$$\mathbf{T} = \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (3.18)$$

$$\mathbf{p}_{rt} = \mathbf{T} \cdot \mathbf{p}_h \quad (3.19)$$

$$\mathbf{P}_{rt} = \mathbf{P}_h \cdot \mathbf{T}^T \quad (3.20)$$

La figura 3.22 muestra un caso de adquisición (B-scan) superpuesta con sus TDVs teóricos (curva verde). El campo en el rectángulo rojo indica el elemento emisor, en este caso el elemento central. En la sección izquierda se indican las posiciones y orientaciones relativas del transductor. La coincidencia de los A-scan con sus respectivos TDVs indica que el modelo funciona bastante bien, y que la estimación del Δz se ha realizado correctamente.

Secuencia de trayectorias y Adquisición de datos:

La secuencia de trayectorias se refiere a las translaciones y orientaciones que cubrirá el transductor alrededor de la pieza para adquirir datos. Como se indicó previamente, para

3.2. ADQUISICIÓN DE DATOS

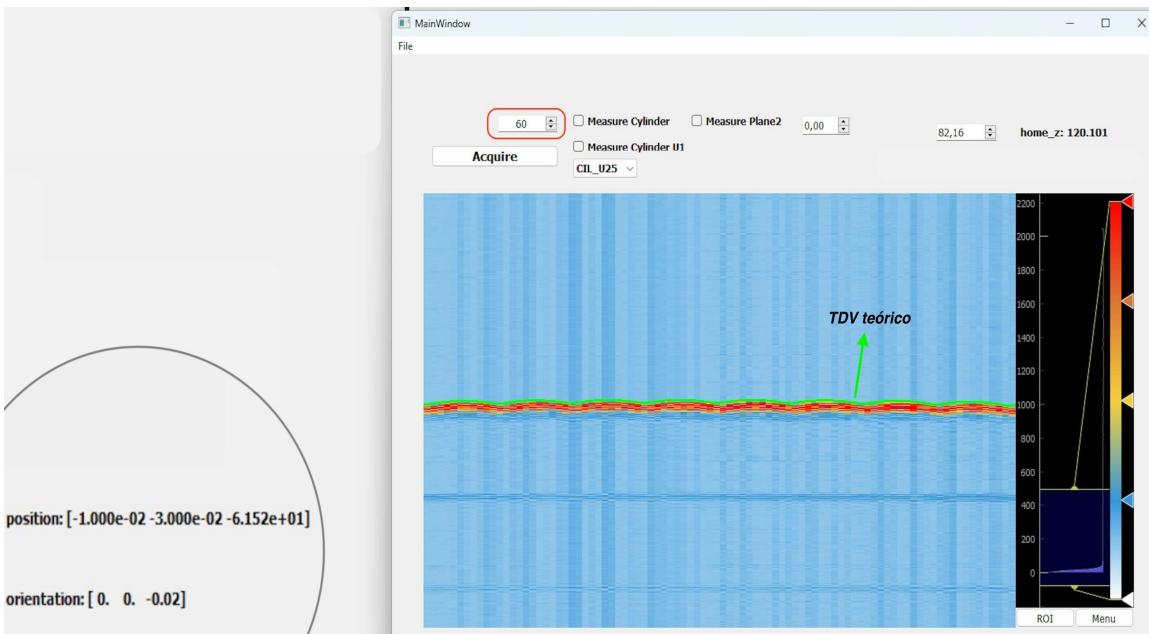


Figura 3.22: Ejemplo de adquisición y sus respectivos TDVs teóricos

definir qué orientaciones y traslaciones tomará el transductor durante la adquisición, se considera su geometría. Se debe tomar en cuenta que lo que se desea es obtener información de la pieza desde distintos “puntos de vista”, por lo tanto, para el plano, generar un desplazamiento, ya sean en x o en y no provee una “visión” distinta desde el transductor a la pieza, razón por la cual estas traslaciones no fueron tomadas en cuenta. De este modo, las combinaciones de movimientos definidas fueron: **1)** desplazamiento en z , **2)** rotación en x , y **3)** rotación en y . Para poder cubrir el espacio de posiciones posible de la mejor manera, se generaron aleatoriamente (con distribución uniforme) arreglos de valores de traslación y para cada rotación, entre límites dados y con un número máximo de 200, y se generó, a partir de cada uno de estos, las posiciones en lenguaje UR10e.

Los datos de las adquisiciones se mostrarán con más detalle en el apartado de *Resultados*, donde se comentará sobre el desempeño de cada uno de los métodos convencionales con respecto a lo obtenido con la técnica RNC. Se considera, sin embargo, reportar aquí los parámetros definidos para la toma de los datos. El desplazamiento en el eje- z , se limitó entre 43 mm para la posición más alta, y 16 mm para la más cercana al plano. Las rotaciones permitidas en el eje x e y se acotaron entre 0° y 20° . Además, para evitar contactos del transductor con la pieza en posiciones muy bajas en el eje- z se añadió una restricción a los ángulos de inclinación en función de dicha distancia, de tal manera que, si la posición en z era menor que 24 mm, las rotaciones no debían superar los 2° .

3.2.3. Cilindro 1 y 2 (35 y 12 mm)

Alineamiento pieza-transductor:

Para las piezas cilíndricas el proceso de alineamiento con respecto al plano utiliza también la GUI que permite visualizar los ecos. La pieza se la ubica recostada sobre un plano, con su eje axial en la dirección del eje-*x* del sistema de coordenadas del plano. La figura 3.23 muestra un esquema de la configuración, aquí los puntos corresponden a los elementos activos—central (rojo) y esquineros (verdes)—en el proceso de alineamiento. Lo que se intenta mostrar es la ubicación relativa entre transductor y cilindro para considerarlos alineados, es decir con el elemento central del transductor lo más próximo al eje de la pieza. Se busca, entonces, que las señales detectadas con los elementos de cada esquina coincidan lo más posible—teniendo en cuenta que la superficie del transductor es paralela al plano—y que sea el elemento central aquel que detecte la primera señal reflejada.

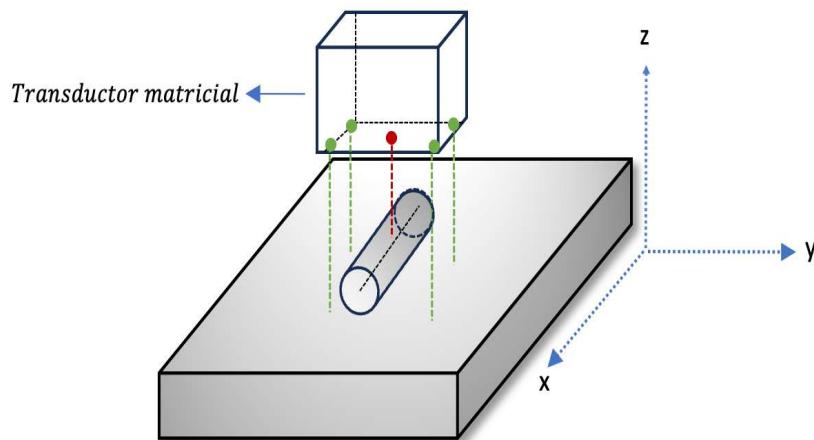


Figura 3.23: Esquema de posicionamiento del cilindro para la etapa de adquisición

El patrón de alineamiento, por lo tanto, es el de una señal seguida de cuatro que se superponen lo mejor posible. La figura 3.24 muestra lo obtenido. Una vez alineado se procede con la verificación del cálculo de los TDVs.

Cálculo de TDV teórico:

Para las geometrías no-planas el criterio aplicado para obtener los tiempos de vuelo ciertamente involucra consideraciones más complejas que en el caso plano, sin embargo, es válido presentarlas como versiones similares al cálculo de TDVs para la superficie plana, es

3.2. ADQUISICIÓN DE DATOS

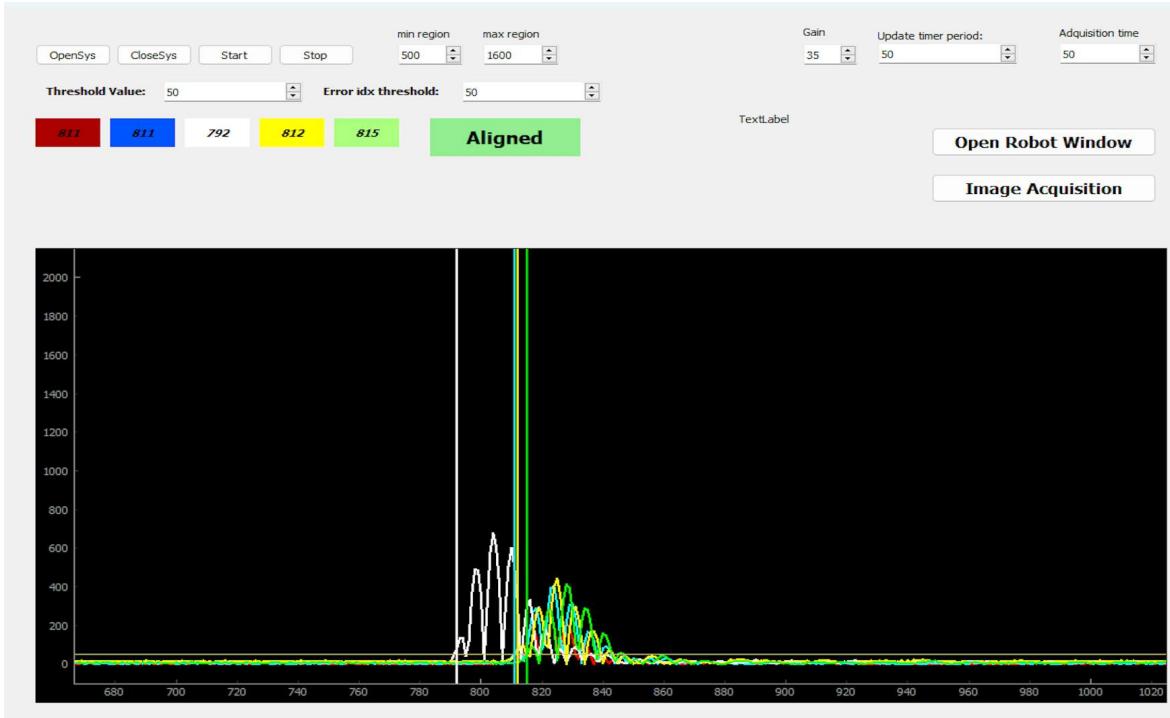


Figura 3.24: Evaluación de alineamiento transductor-cilindro1 en GUI 1

decir, el cálculo se logra en el contexto de imágenes especulares. Adentrarse con excesivo detalle en las modificaciones respectivas no es relevante al tema de este documento y, por lo tanto, su descripción no apelará a ecuaciones o diagramas técnicos sobre los conceptos de óptica empleados. No obstante, se deriva al lector al estudio donde los pormenores relevantes pueden ser consultados [46].

Las funciones que implementan el cálculo mencionado dentro de las interfaces de usuario desarrolladas requieren, como en el caso de la geometría plana, la distancia entre los elementos del transductor y el plano de referencia de la pieza, llamada z_1 en la figura 3.21. La configuración para estimar este valor es básicamente la misma que para el caso del plano, pero apelando al plano de referencia del cilindro. La figura 3.25 indica lo mencionado, y el cálculo lo muestra también la ecuación 3.15. Lo que se puede observar es que, ahora, el plano de referencia es un plano paralelo a la superficie de apoyo que pasa por el eje del cilindro.

La consistencia de los TDVs teóricos con las adquisiciones (B-scan) se muestran en la figura 3.26.

De igual manera esto indica que tanto el modelo teórico, como la estimación de Δz y z_1 funcionan bastante bien. En la esquina inferior izquierda de la figura 3.26 se observan la

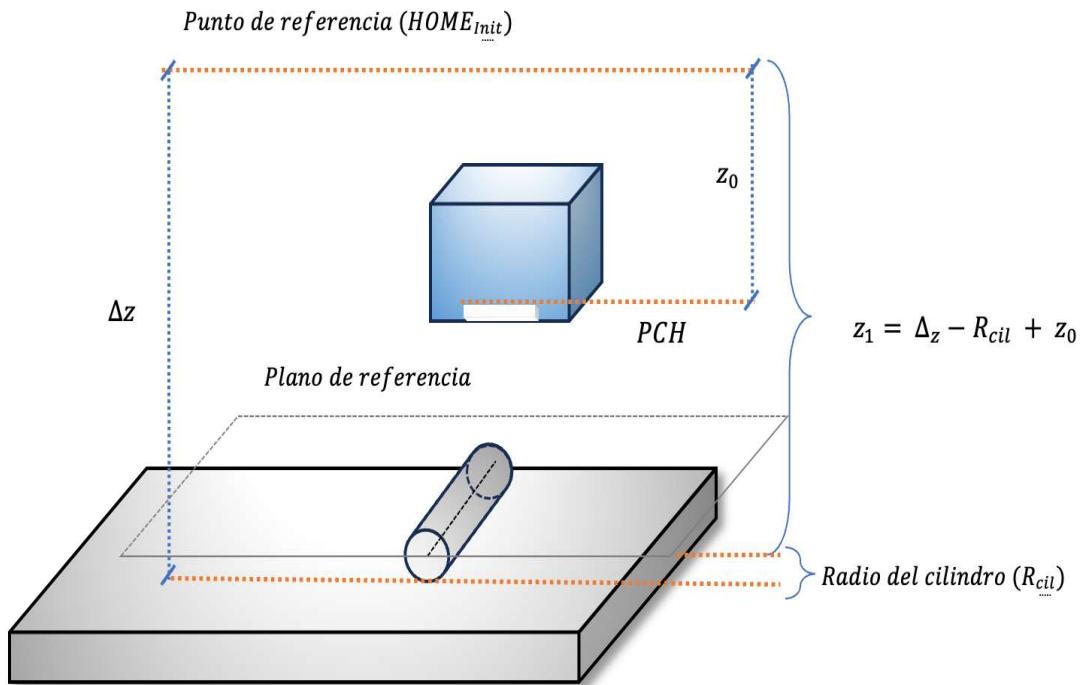


Figura 3.25: Posición de componente z con respecto a plano de referencia (cilindro 1 y 2)

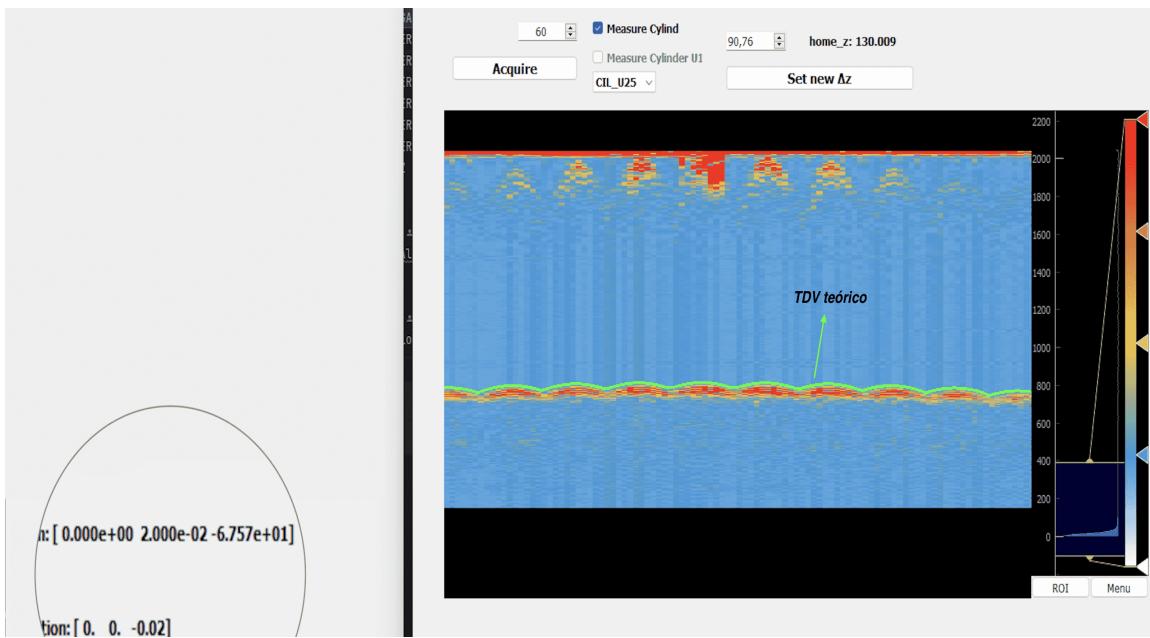


Figura 3.26: Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 1 y 2

posición (fila superior) y orientación relativa (fila inferior) del transductor al momento de realizar la adquisición. Los datos corresponden al elemento central como elemento emisor. Con una orientación de $\approx 14^\circ$ en el eje- y , los valores teóricos de TDVs se corresponden bien a sus respectivos A-scans. Este tipo de corroboraciones generaron confianza de que al momento de las mediciones, que exploran distintas posiciones e inclinaciones, los TDVs teóricos coincidirán bien en cada caso.

3.2. ADQUISICIÓN DE DATOS

Secuencia de trayectorias y adquisición de datos:

Como se mencionó antes, la secuencia de trayectorias depende de la geometría de la pieza. Para los cilindros 1 y 2 también se consideró solamente ciertos movimientos que aportarían a los distintos “puntos de vista” al desplazarse alrededor de la pieza. Entonces, apelando a la figura 3.23 para visualizar esto, si se considera que un desplazamiento del transductor en el eje-*y* es equivalente a una rotación en el eje-*x*, se puede descartar uno de estos movimientos. En nuestro caso se excluyó la rotación en *x*. Dicha equivalencia reside en que el par de movimientos desplazan los elementos del transductor de manera similar, y considerar ambos sería redundante en los datos adquiridos, haciendo más pesados los archivos de almacenamiento, y más engorroso el post-procesamiento. Por otro lado, el desplazamiento en el eje-*x* se lo descartó por la misma razón que fueron excluidos en el caso del plano, es decir, este no aporta un “punto de vista” diferente a la medición en su aplicación. Rotaciones y desplazamientos en el eje-*z* aportan distintas perspectivas, y son, por lo tanto, movimientos añadidos a la secuencia de trayectorias. Aquí también se generan arreglos aleatorios, con distribución uniforme, entre límites dados para cada movimiento.

Finalmente, los parámetros definidos para la etapa de adquisición son:

1) Cilindro 35 mm: Para la traslación en el eje-*z*, la posición más alta fue 66 mm (desde el plano de referencia), y la más cercana a la superficie del cilindro, 38 mm. El desplazamiento en el eje-*y* se limita entre 0 a 6 mm. La idea es no alejarse demasiado de la superficie del cilindro en esa dirección. El rango es en un cuadrante positivo ya que, por simetría, trasladarse en dirección negativa sería redundante. La rotación en eje-*y* admite inclinaciones entre 0° a 20°, que se considera suficiente para cubrir el espacio a explorar en esa dirección. Finalmente, el rango de rotación en el eje-*z* se define entre 0° a 90°. De igual manera que en el caso de la geometría plana, se implementan ciertas restricciones en la orientación en función de la altura de la posición. En este caso, si la distancia desde el plano referencia es menor a 41 mm, la rotación en *y* no supere los 3°. Además, se restringe la rotación en *y* a 15° si la rotación en *z* no supera los 25°. Esto último intenta limitar también contactos inadecuados del transductor con la pieza a alturas cercanas a la misma.

2) Cilindro 12 mm: rango en *z*: desde 16 mm a 44 mm. Desplazamiento en *y*: 0 a 0.5 mm. Rotación en *y*: desde 0° a 20°. Rotación en *z*: desde 0° a 30°. Se restringe: si la distancia desde el

plano referencia desciende a menos de 21 mm, la rotación en y no supere los 3° . Además, se restringe la rotación en y a 15° si la rotación en z no supera los 25° .

3.2.4. Cilindro 3 y 4 (25 y 40 mm)

Para el caso de estas geometrías, específicamente para el cilindro de 25 mm, las adquisiciones se llevaron a cabo en configuración cóncava y convexa, ya que la pieza lo permitía. Esto proporcionó más variedad a los datos con los que se entrena a las RNCs. En esta sección se cubrirá los procedimientos para ambas posiciones de la pieza y para el cilindro de 40 mm en su perfil cóncavo.

Alineamiento pieza-transductor:

El procedimiento es el mismo que en el caso anterior. Lo que se busca básicamente es coincidir el elemento central al eje de cada pieza, ya sea en configuración cóncava o convexa, y verificar los índices de detección de ecos en la interfaz gráfica. La figura 3.27 indica el posicionamiento para ambos escenarios.

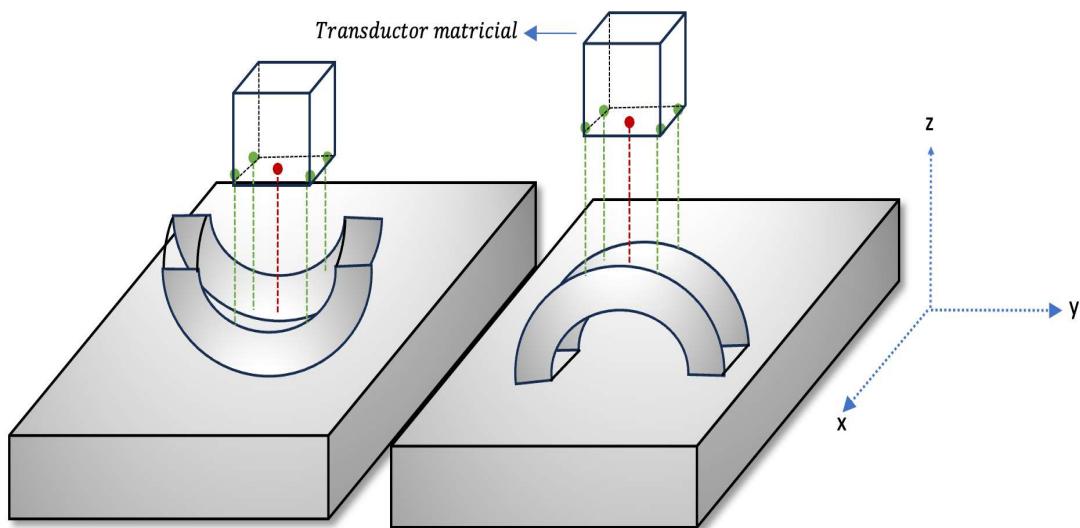


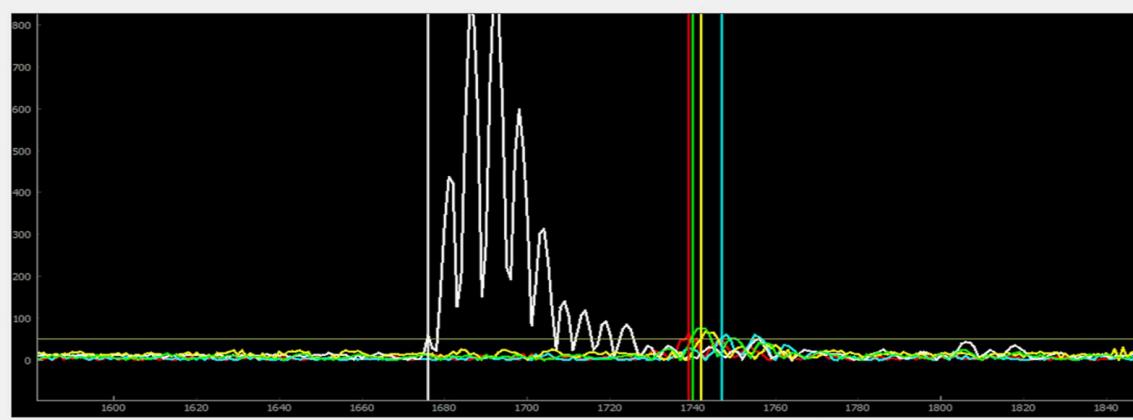
Figura 3.27: Esquema de posicionamiento de cilindros en configuración cóncava y convexa para la etapa de adquisición

La figura 3.28 muestra la verificación de los alineamientos para el cilindro 4 (3.28.a) en configuración cóncava, y el cilindro 3 (3.28.b) en su posicionamiento convexo, respectivamente.

Cálculo de TDV teórico:

3.2. ADQUISICIÓN DE DATOS

a)



b)

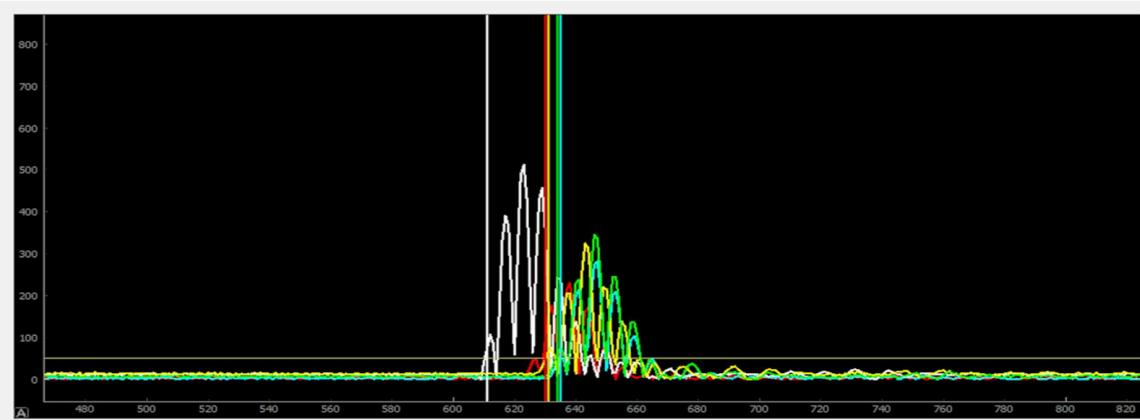


Figura 3.28: Evaluación de alineamiento: a) transductor-cilindro 4 (cóncavo); b) transductor-cilindro 3 (convexo) en GUI 1

De la misma manera que en el caso de los cilindros 1 y 2, la base teórica del cálculo de TDVs para estas piezas, son versiones semejantes a las descritas en el caso del plano, estas también se las aproxima a un escenario de imágenes especulares. De nuevo, se reporta, para consulta de los pormenores necesarios, el artículo de referencia [46]. Como es el caso para todas las piezas bajo consideración, estimar el valor z_1 (i.e., distancia entre los elementos del transductor y el plano de referencia de la pieza), es necesario para el cómputo de TDVs teóricos. Se muestra entonces el esquema de estimación correspondiente a los cilindros 3 y 4 en cada una de sus configuraciones (figuras 3.29 y 3.30). Como se puede apreciar, y de la misma manera que en los cilindros 1 y 2, los planos de referencia cruzan por el eje de cada cilindro. Debido a esto, en el caso convexo el plano de referencia coincidirá con el plano de apoyo, dado que el mismo se halla cortado a través de un plano diametral.

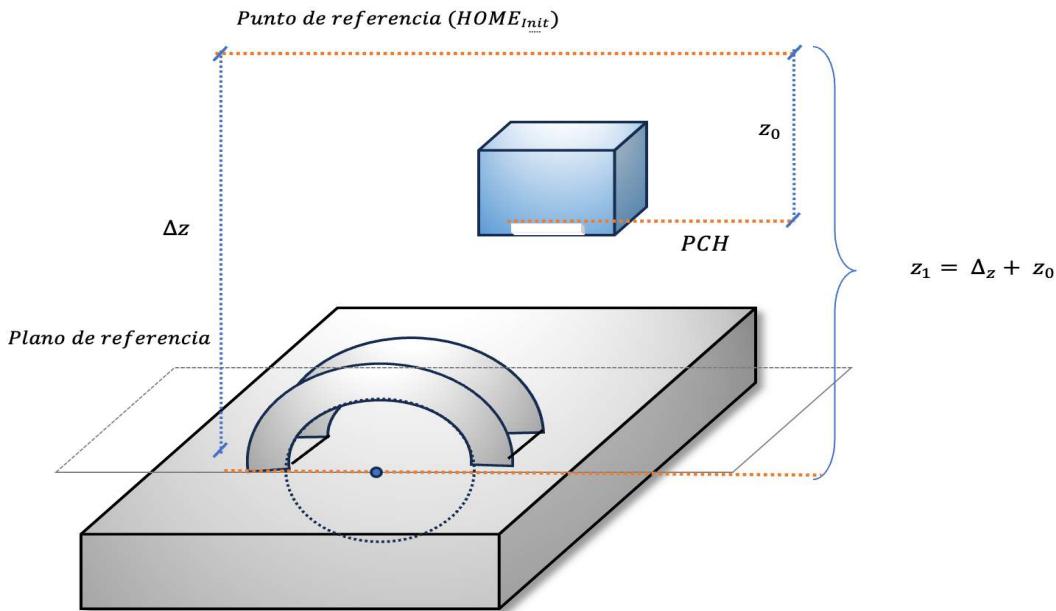


Figura 3.29: Posición de componente z con respecto a plano de referencia: cilindro 3 convexo

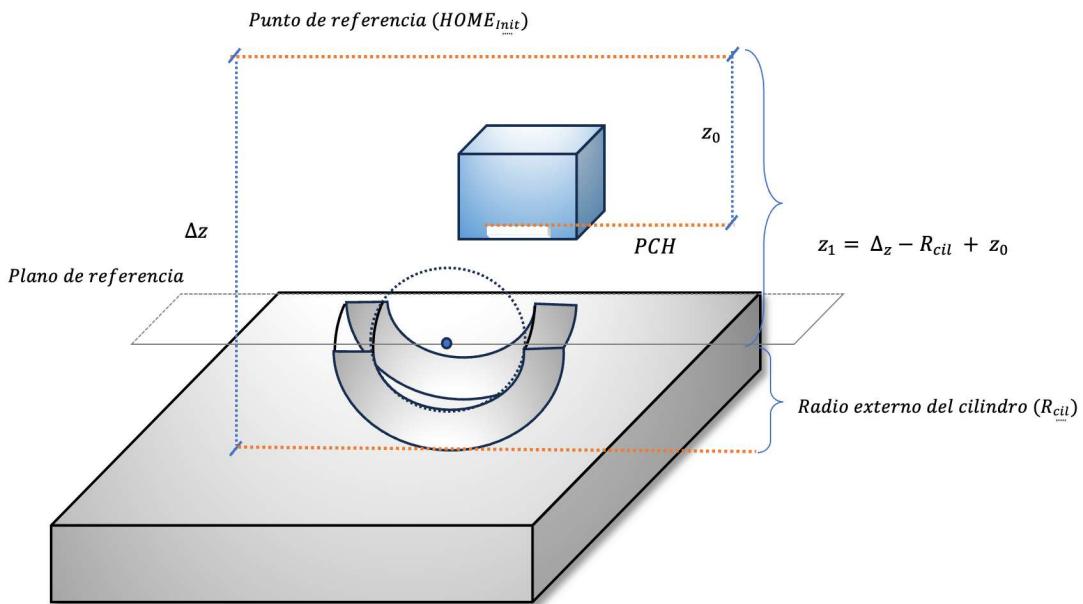


Figura 3.30: Posición de componente z con respecto a plano de referencia: cilindro 4 cónvexo

Una vez determinados los valores z_1 , se comprueba el cálculo de TDVs mediante la GUI de adquisición que permite superponerlos con las imágenes B-scan correspondientes a un elemento específico actuando como elemento emisor. La figura 3.31 muestra un caso de adquisición para el primer elemento emitiendo la señal ultrasónica (cilindro 3 convexo).

La figura 3.32 es el caso del elemento 10 como emisor (cilindro 4 cónvexo).

3.2. ADQUISICIÓN DE DATOS

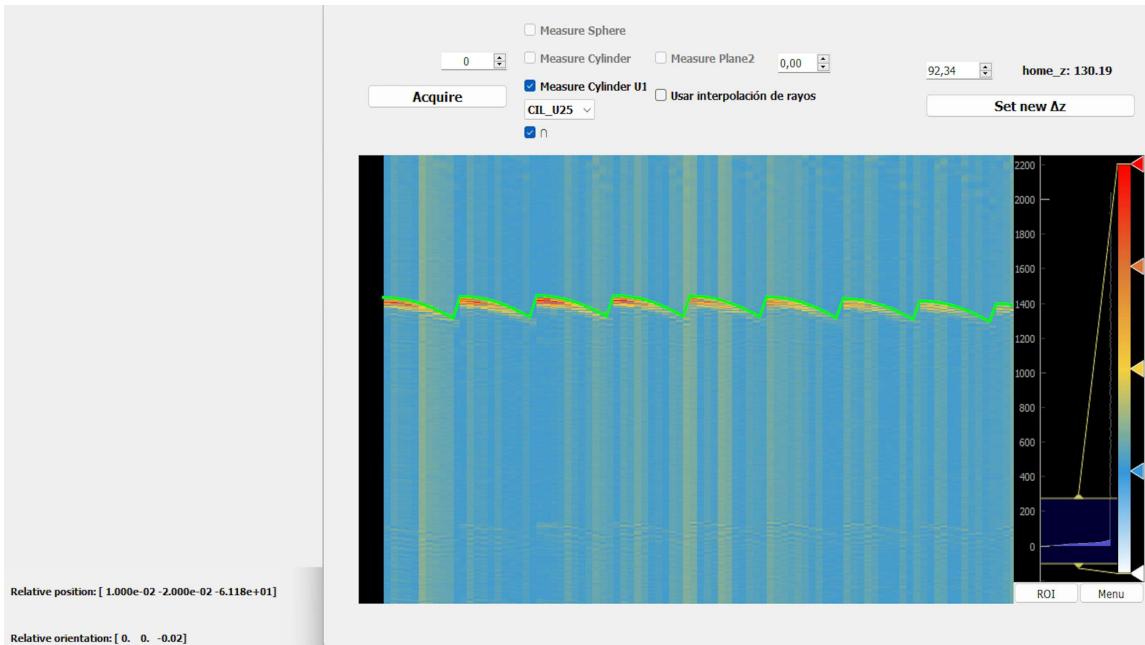


Figura 3.31: Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 3 (convexo)

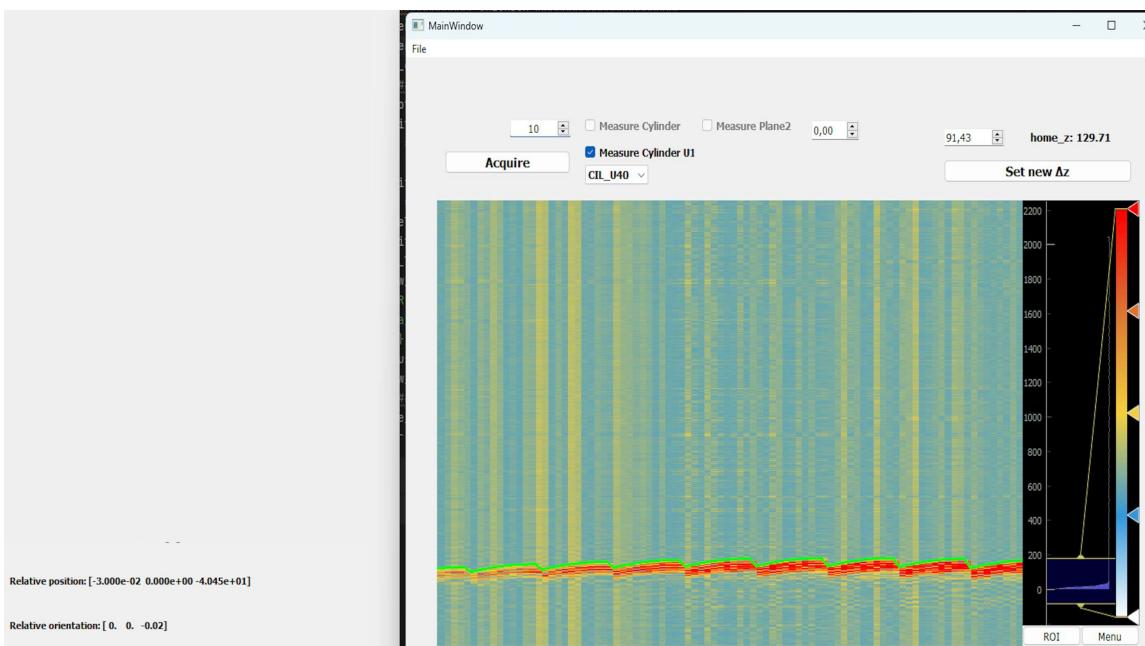


Figura 3.32: Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 4 (cóncavo)

Para cada uno se indica las posiciones y orientaciones relativas del transductor. Una vez más, mediante este paso es posible cerciorarse de que, tanto la estimación de Δz y z_1 es adecuada, como el cálculo teórico de TDVs para la geometría de cilindros cóncavos y convexas, en base al criterio de imágenes especulares, se ajusta correctamente con los ecos de superficie que se aprecian en la imagen.

Secuencia de trayectorias y Adquisición de datos:

Para estas geometrías, el criterio para definir los desplazamientos y orientaciones convenientes es igual que para el caso de los cilindros 1 y 2, es decir, las trayectorias establecidas para la adquisición son: traslaciones en los ejes z e y , e inclinaciones en z y en y . Los parámetros son:

1. **Cilindro 25 mm (cónexo):** Rango en z : desde 25 mm a 45 mm. Desplazamiento en y : 0 a 3 mm. Rotación en y : desde 0° a 20° . Rotación en z desde 0° a 90° . Se restringe: si la distancia desde el plano referencia desciende a menos de 29 mm, la rotación en y no supere los 3° . Además, se restringe la rotación en y a 15° si la rotación en z no supera los 25° .
2. **Cilindro 25 mm (convexo):** Rango en z : desde 24 mm a 49 mm. Desplazamiento en y : 0 a 3 mm. Rotación en y : desde 0° a 20° . Rotación en z desde 0° a 90° . Se restringe: si la distancia desde el plano referencia desciende a menos de 28 mm, la rotación en y no supere los 3° . Además, se restringe la rotación en y a 15° si la rotación en z no supera los 25° .
3. **Cilndro 40 mm (cónexo):** Rango en z : desde 40 mm a 51 mm. Desplazamiento en y : 0 a 3 mm. Rotación en y : desde 0° a 20° . Rotación en z desde 0° a 30° . Se restringe: si la distancia desde el plano referencia desciende a menos de 43 mm, la rotación en y no supere los 3° . Además, se restringe la rotación en y a 15° si la rotación en z no supera los 25° .

3.2.5. Esfera

Alineamiento pieza-transductor:

Criterio similar a los casos anteriores. Se desea idealmente ubicar al transductor sobre la pieza de tal manera que el elemento central se ubique sobre la linea perpendicular al plano de apoyo y que pasa por el centro de la esfera, y que los elementos esquineros detecten ecos provenientes del plano de apoyo a un mismo tiempo de llegada. La figura 3.33 muestra el posicionamiento descrito. La comprobación del alineamiento realizado en base a la detección de ecos se muestra en la figura 3.34.

3.2. ADQUISICIÓN DE DATOS

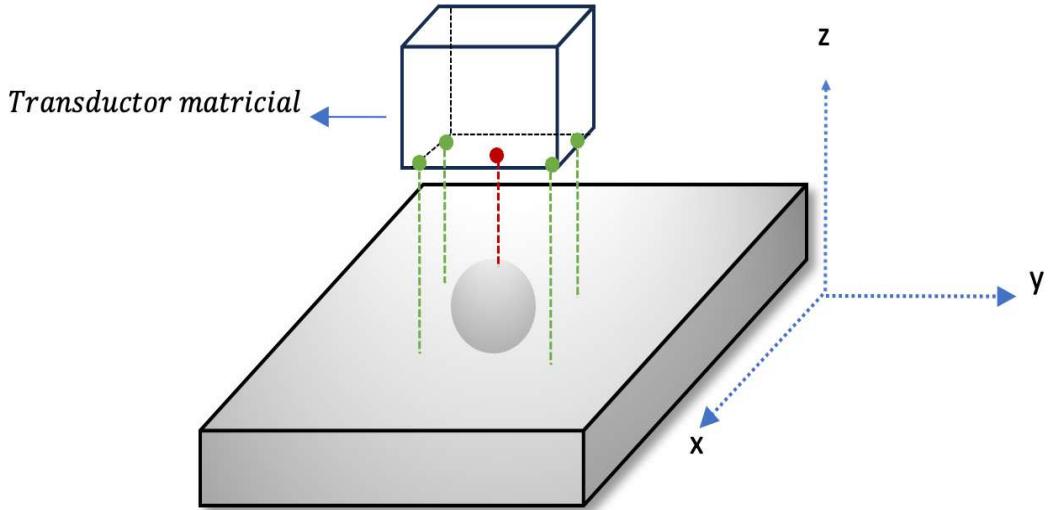


Figura 3.33: Esquema de posicionamiento de esfera para la etapa de adquisición

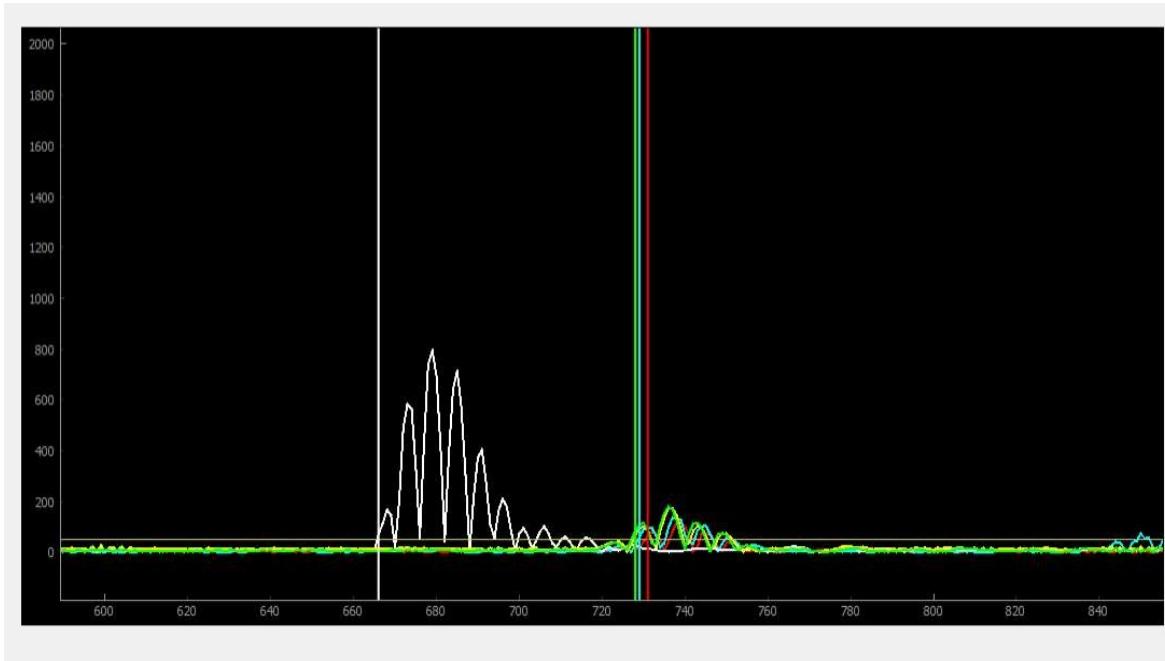


Figura 3.34: Evaluación de alineamiento transductor-esfera 3 en GUI 1

Cálculo de TDV teórico:

Como se ha señalado ya, para las geometrías no planas, el cálculo de los TDVs es en base a una aproximación del modelo de imagen especular utilizada para el caso de la superficie plana. Los detalles de las adaptaciones correspondientes se pueden encontrar en [46]. De igual forma, la estimación de los valores Δz y z_1 consideran un plano de referencia virtualmente ubicado en el centro de la esfera y paralelo al plano de apoyo, como es posible observar en la figura 3.35.

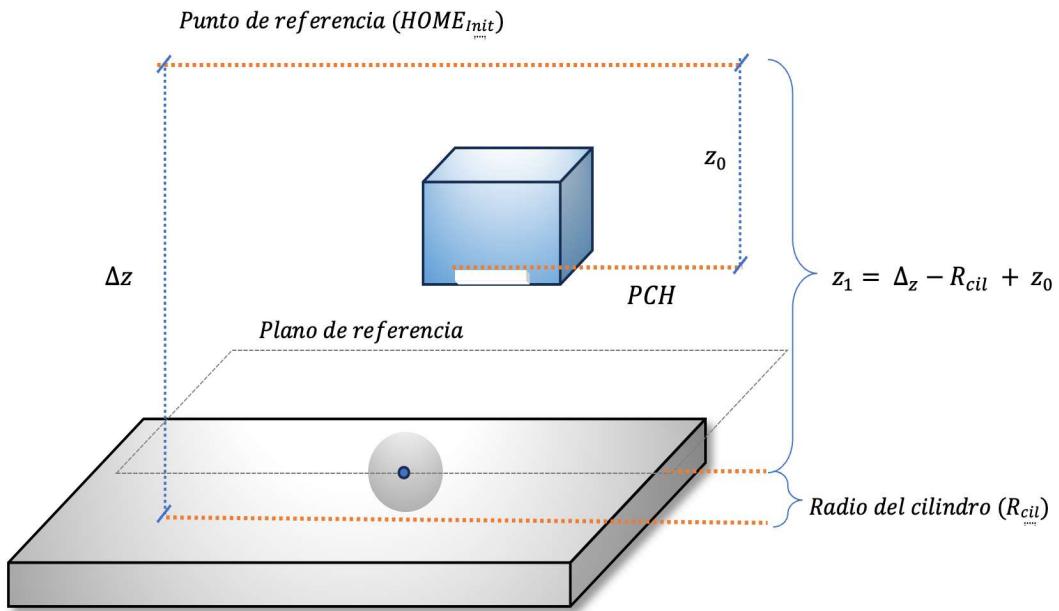


Figura 3.35: Posición de componente z con respecto a plano de referencia: esfera

La comprobación de cálculo de TDVs se indica en la figura 3.36. La coincidencia de valores teóricos indica que el modelo es compatible con las adquisiciones en una posición representativa del transductor sobre la pieza.

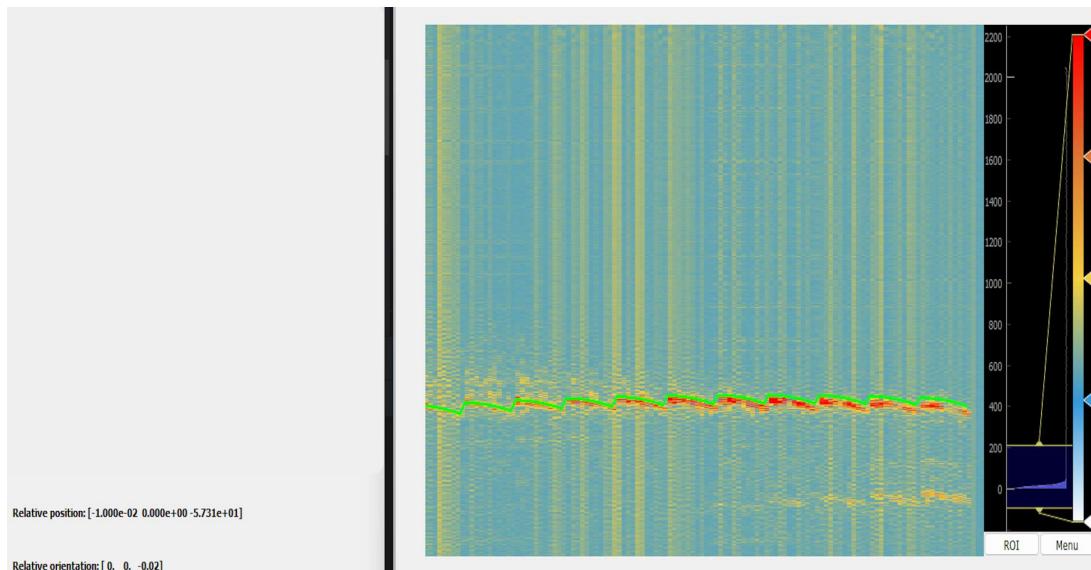


Figura 3.36: Ejemplo de adquisición y sus respectivos TDVs teóricos, caso cilindro 4 (cón-cavo)

Secuencia de trayectorias y adquisición de datos:

Para la geometría esférica, el criterio para excluir movimientos sobre la pieza considera las siguientes redundancias: un desplazamiento en el eje- y equivale a una rotación en el

3.2. ADQUISICIÓN DE DATOS

eje x , y un desplazamiento en el eje- x equivale a una rotación en y . En este caso se han descartado las ambas rotaciones. Además, se excluye también la rotación en z porque esta no aporta información extra al entrenamiento. De esta forma, la secuencia de trayectorias se conformaron solamente con desplazamientos en x , y y z . Los rangos de movimiento para cada grado de libertad se definieron así: desplazamiento en z : desde 20 mm a 32 mm; desplazamiento en x e y : desde 0 a 2 mm.

3.2.6. Plano Fibra de carbono

Alineamiento pieza-transductor:

Los criterios de alineamiento para esta pieza son los mismos que los aplicados para el plano rectangular. Se muestra a continuación la comprobación mediante la GUI de visualización de A-scans (figura 3.37).

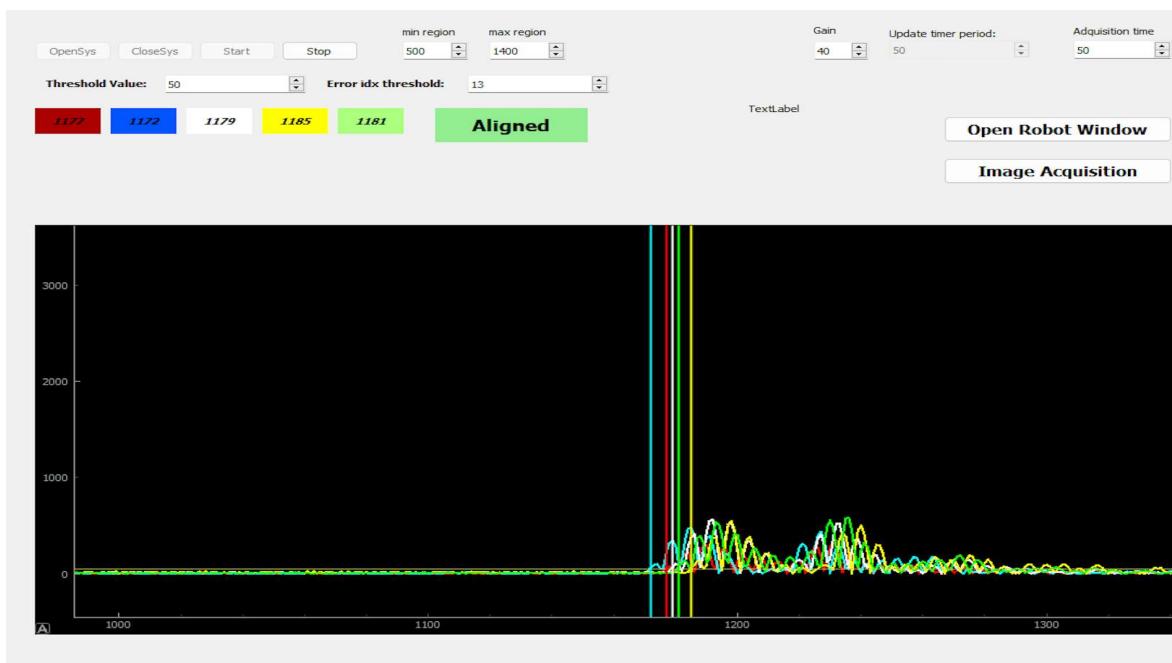


Figura 3.37: Evaluación de alineamiento transductor-plano 2 en GUI 1

Cálculo de TDV teórico:

De igual manera, el cálculo de TDVs para esta pieza consiste en el modelo aplicado para el plano rectangular, es decir, la ley de reflexión e imagen especular. La estimación de Δz y z_1 es, de nuevo, igual, pero, de igual manera que para las geometrías no-planas, considerando la dimensión geométrica del componente, es decir su espesor (1.9 mm). La figura 3.38 indica la adquisición de evaluación del cálculo de TDV, con su correspondiente

imagen B-scan.

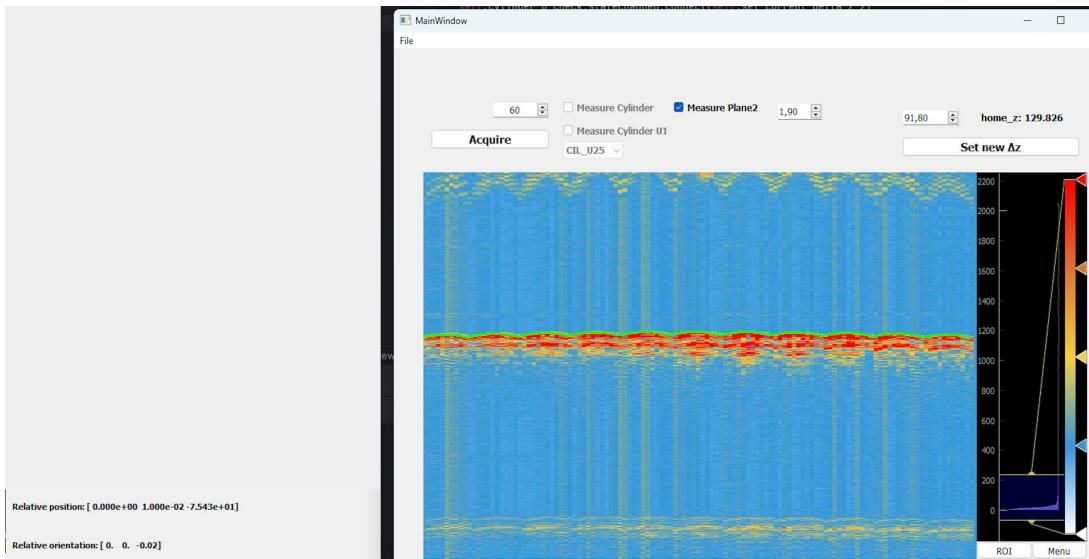


Figura 3.38: Ejemplo de adquisición y sus respectivos TDVs teóricos, caso plano fibra de carbono

Secuencia de trayectorias y Adquisición de datos:

La exclusión de movimientos sigue los mismos criterios que para el caso del plano rectangular. Por lo tanto, la secuencia se definió como: desplazamiento en el eje-z: entre 16 y 40 mm. Las rotaciones en el eje x e y se acotaron entre 0° y 20° . La restricción en ángulos de inclinación a distancias cercanas, se estableció de tal manera que, si la posición en z era menor a 20 mm, las rotaciones no debían superar los 2° .

3.2.7. Adquisiciones en distancias cercanas a la pieza

Complementariamente a las adquisiciones descritas, se llevaron a cabo mediciones en el plano rectangular de aluminio y en el cilindro de 12 mm de diámetro, con distancias suficientemente cortas entre el transductor y la pieza de tal modo que los ecos de su superficie interfieran con la cola del pulser y/o las ondas superficiales del transductor.. Se reporta para cada uno los movimientos definidos en cada caso:

1. **Plano:** desplazamiento en z : desde 3 mm a 10 mm, y con rotaciones permitidas en x e y entre 0° y 2° .
2. **Cilindro:** rango en z : desde 13 mm a 15 mm. Desplazamiento en y : 0 a 0.5 mm. Rotación en y : desde 0° a 1° . Si rotación en z . Se restringe: si la distancia desde el

plano referencia desciende a menos de 21 mm, la rotación en y no supere los 3° .

El objeto de realizar estas adquisiciones es disponer de datos cuyas señales detectadas se encuentren cercanas a las señales generadas por los generadores de pulsos, esto con el fin de alimentar las redes neuronales con información que podría ser causa de categorización incorrecta, y poner a prueba la arquitectura propuesta. Las consecuencias se discutirán en el apartado de resultados.

3.3. Red Neuronal Convolucional

En este apartado se describe la arquitectura propuesta de la red neuronal convolucional para la detección de ecos de superficie para datos adquiridos en inspecciones END, en una configuración de medida FMC. La arquitectura seleccionada utiliza como base la arquitectura V-Net [38]. Siguiendo el criterio explicado en la sección anterior se han almacenado múltiples conjuntos de datos FMC, estructuras de datos volumétricas con dimensiones $11 \times 11 \times 1000$, correspondientes a cada par de combinaciones de elementos emisores-receptores del transductor. Este formato 3D de las señales ultrasónicas registradas hacen apropiados a los diseños del tipo V-net.

3.3.1. Implementación de arquitectura de la red

Se describe a continuación la implementación de la arquitectura que se adecuó específicamente para la detección de ecos de superficie, mediante optimización de hiperparámetros.

Hiperparámetros

Son valores de configuración que se establecen antes de que inicie el entrenamiento del modelo. A diferencia de los parámetros del modelo (como pesos, valores de activación y sesgos) que se aprenden durante el proceso de entrenamiento, los hiperparámetros no se aprenden a partir de los datos, sino que se los establece manualmente. Optimizar el conjunto de hiperparámetros con los que se entrena un modelo RNC es crucial debido a que estos impactan directamente en el desempeño, eficiencia y habilidad de generalización de la red. El modelo empleado se instancia con específicos parámetros de entrada, que posteriormente se procede a optimizar en términos de tres métricas que se definen más adelante. Los hiperparámetros son:

1. **Función de pérdida**, mide la diferencia entre el resultado previsto del modelo y los valores objetivo reales. La elección de la función de pérdida afecta directamente el proceso de aprendizaje y el rendimiento de la RNC. Se exploró la efectividad de tres funciones comunes en aplicaciones de segmentación: Entropía cruzada binaria [47]; función Tversky [48]; y función DICE [49].
2. **Número de bloques convolucionales**. Cantidad adecuada para equilibrar suficiente extracción de características y evitar el sobreajuste. El rango de búsqueda se estableció para 2,3,4 o 5 bloques convolucionales.
3. **Tamaño de filtro (kernel)**. Afecta el llamado *campo receptivo* de la red. Filtros pequeños logran capturar características locales de mayor detalle. Filtros de mayor tamaño tienen un campo receptivo más amplio, lo que significa que pueden capturar características más globales, es decir, se enfoca más en el contexto que en los detalles. La búsqueda se definió entre [3,3,6] a [3,3,21].
4. **Número de filtros**. Una mayor cantidad de filtros puede capturar más características y potencialmente generar un mejor desempeño en tareas complejas, pero a costa de mayores demandas computacionales y el riesgo de sobreajuste. Su rango de optimización fue entre 8 a 16 filtros.
5. **Tamaño de pooling**. Su propósito es la reducción de dimensiones de la imagen. En el caso de un tamaño de agrupación de 2x2x2, las dimensiones espaciales se reducen a la mitad (por ejemplo, de 64x64x64 a 32x32x32). La elección del tamaño de agrupación afecta la cantidad de información espacial retenida. Los tamaños de agrupación más pequeños retienen más detalles, mientras que los tamaños más grandes enfatizan las características dominantes de manera más agresiva. Los ejes *x* e *y* se ajustaron con valores 1 o 2, y el eje temporal se ajustó con valores entre 2, 4 u 8.
6. **Tasa de aprendizaje**. Afecta directamente la velocidad y la eficacia del proceso de entrenamiento y desempeña un papel crucial para garantizar que el modelo converja hacia una solución óptima.

Optimización de Hiperparámetros

Como ya se señaló, la elección de hiperparámetros afecta significativamente el rendimiento del modelo. Los hiperparámetros mal elegidos pueden provocar un ajuste insuficiente o un sobreajuste. La optimización de hiperparámetros es el proceso de búsqueda sistemática de la mejor combinación de estos para maximizar el rendimiento del modelo, en base al objetivo estipulado para este proyecto, es decir, reducir lo más posible el numero de desviaciones o valores atípicos en el proceso de detección de ecos de superficie.

La técnica empleada para la optimización de los hiperparámetros mencionados fue el algoritmo ***Hyperband***, que está diseñado para, durante la búsqueda, asignar eficientemente recursos computacionales (e.g., número de épocas de entrenamiento, o tamaño del conjunto de datos para evaluar el modelo) a diferentes configuraciones de hiperparámetros. Al implementar el algoritmo, se ha añadido un criterio de *finalización temprana*⁶, que ayuda a evitar el efecto de sobreajuste [50]. El algoritmo asigna una puntuación a cada configuración que evalúa en función de su desempeño (en nuestro caso, el puntaje viene dado por el número de outliers). El proceso descarta a los modelos con peor puntaje, y de esta manera llega a una solución óptima en menor tiempo que utilizando otros tipos de algoritmos de optimización de hiperparámetros, como por ejemplo, el algoritmo *Grid Search* [51].

El algoritmo realiza la exploración dentro del espacio de hiperparámetros asignado, seleccionando aleatoriamente diversos subconjuntos, y asignando inicialmente una pequeña cantidad de recursos para brevemente evaluarlo en base a la puntuación definida (en nuestro caso reducción de valores atípicos). Mientras el algoritmo identifica configuraciones más prometedoras, asigna mayores recursos para refinar tales subconjuntos. Se ha decidido aplicar 6 iteraciones del algoritmo de hiperbúsqueda para identificar y descartar los modelos menos eficientes. Para ser lo más consistentes posibles en la selección de la configuración adecuada, se seleccionan los 5 modelos con mejor resultado y se da paso a una exploración extra. Esta consistió en una secuencia de 5 reentrenamientos con el objetivo de buscar la solución más estable.

⁶Early Stopping

Definiendo Ground Truth

En el contexto de la evaluación de una RNC o cualquier modelo de aprendizaje automático, el GT, se refiere a los datos o etiquetas que se consideran correctos o verdaderos. Estos son los resultados de referencia que se utilizan para evaluar las predicciones del modelo. Por ejemplo, en una tarea de segmentación, el GT podría ser imágenes etiquetadas manualmente que indiquen los segmentos o clases correctos. Para nuestro caso en particular estas corresponden a los índices asociados a los TDVs teóricos calculados como se indica en la sección sobre adquisición de datos. La figura 3.39 muestra un ejemplo del GT en nuestros datos FMC, además presenta la máscara de segmentación binaria construida a partir de los TDVs teóricos.

Dichas etiquetas, por lo tanto, se determinan como una máscara binaria a partir de los TDVs teóricos, es decir, se calcula un índice de muestra teórico \mathbf{Idx}_{vrd} , y se comprueba, mediante el número de muestra de la señal (id), si esta ha superado o no el valor correspondiente \mathbf{Idx}_{vrd} , ver ecuación 3.21.

$$GT = \begin{cases} 0, & id < \mathbf{Idx}_{vrd} \\ 1, & id > \mathbf{Idx}_{vrd} \end{cases} \quad (3.21)$$

Esto debe interpretarse como: cualquier muestra con índice menor a \mathbf{Idx}_{vrd} , es decir $GT = 0$, indica que esta se encuentra fuera de la pieza, sobre el eco de superficie. Para casos en los que $GT = 1$, el modelo indica una muestra dentro del componente (por debajo del eco de superficie).

Definiendo métricas de evaluación de red

Para cualquier modelo RNC, existen funciones que proporcionan medidas cuantitativas para evaluar el rendimiento del modelo en tareas específicas. Las métricas ayudan a comprender qué tan bien está aprendiendo el modelo, qué tan efectivamente se generaliza a nuevos datos y dónde se pueden realizar mejoras. Para nuestra red, se generan 3 métricas personalizadas que promedian valores sobre un lote o época, y proveerán el criterio para el proceso de optimización de parámetros, y posteriormente la valoración del desempeño de la red con datos de prueba.

3.3. RED NEURONAL CONVOLUCIONAL

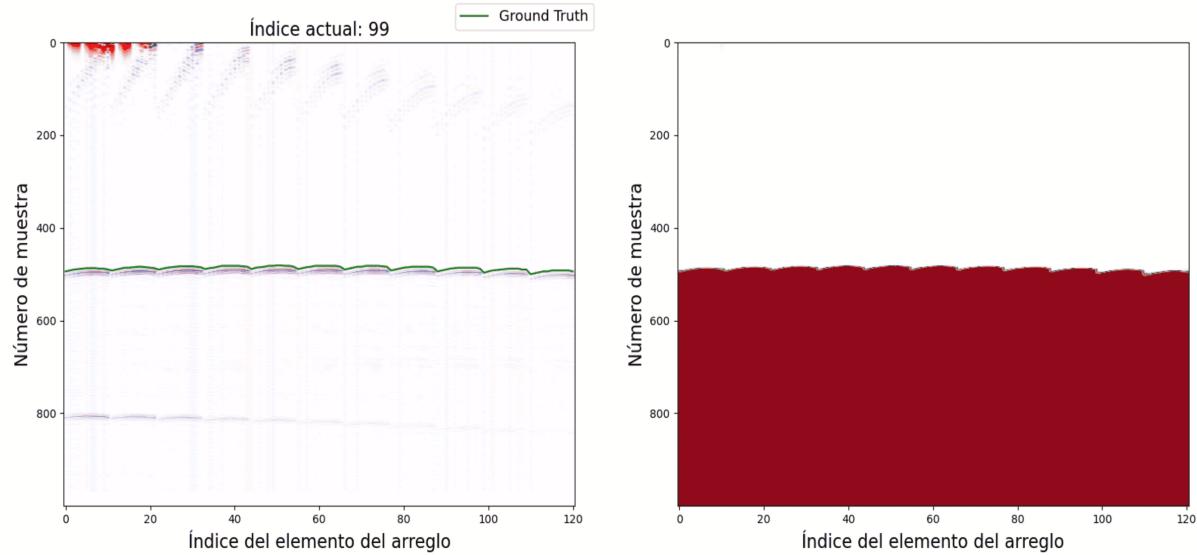


Figura 3.39: Ejemplo de *Ground Truth*

1. **Valores atípicos (tipo 1):** Esta métrica cuantifica índices que no exceden un umbral dado y entrega el total de casos por cada conjunto de datos FMC. Por lo tanto, evalúa las intancias donde el modelo no detecta ecos de superficie. Esta métrica en particular se aplica en el monitoreo de las fases de reentrenamiento, y como uno de los indicadores de desempeño en la exploración del algoritmo *hyperband*. También se la utiliza al comparar los resultados de la red con respecto a los métodos convencionales.
2. **Valores atípicos (tipo 2):** Aquí se considera la diferencia entre un índice predicho y el índice teórico, estimado a partir de los TDVs calculados, que representan los GTs, y se comprueba que dicha diferencia no supere un límite dado ***max_idx_error***. Si se supera dicho umbral, la métrica informa sobre casos en los que el modelo ha detectado ecos, pero ecos no correspondientes a la superficie de la pieza, por lo tanto valores atípicos. De la misma manera que la métrica 1, este indicador de desempeño se lo aplica al evaluar la búsqueda *hyperband*, y al contrastar la red con los casos convencionales. La ecuación 3.22 define el cálculo de esta métrica, siendo ***Conteo_{err}*** la cantidad de valores atípicos por adquisición FMC. ***Idx_{pred(i)}*** son los índices predichos por cada método (convencional o RNC). ***Idx_{vrd(i)}*** el índice de muestra teórico. Y se utiliza la función indicadora ***1*** que es

igual a 1 si la condición se cumple y 0 en caso contrario.

$$Conteo_{err} = \sum_i \mathbf{1}(Idx_{pred(i)} - Idx_{vrd(i)} > max_idx_err) \quad (3.22)$$

3. **Error de índice:** Este entrega el máximo del valor absoluto de la diferencia mencionada en la segunda métrica. Mientras menor sea esta cantidad, se interpreta que el modelo es más eficiente en detectar ecos provenientes de la superficie de la pieza. Esta métrica se aplica durante las iteraciones del algoritmo *hyperband* donde el criterio seleccionar las configuraciones que la minimizan, indicando mejor desempeño del modelo al detectar ecos de superficie. La expresión que la define se muestra en la ecuación 3.23. Con

$$Idx_{error} = \max(|Idx_{pred} - Idx_{vrd}|) \quad (3.23)$$

Durante el entrenamiento de los datos, la RNC hace un seguimiento de estas métricas para evaluar la fiabilidad del modelo.

Criterio de selección de la arquitectura de red

Posterior a la optimización de hiperparámetros, se lleva a cabo un proceso de:

1. **Preselección de modelos mediante *hyperband*,** donde ese eligen los 5 modelos con mejor relación entre valores atípicos y error de índice (ecuación 3.23).
2. **Reentrenamiento de modelos preseleccionados,** para corroborar su desempeño. Esta etapa se considera necesaria debido a la naturaleza estocástica en la definición de pesos durante el entrenamiento. Entonces, sobre este subconjunto se reentrenan 5 veces más para verificar cual de todos es el más estable.
3. **Selección final** de arquitectura de la red, en base a su desempeño, en términos de la reducción de valores atípicos e índice de error. La arquitectura final se aplica para los procesos de entrenamiento y prueba de la red, que se comentan en las siguiente sección de este capítulo, sin embargo los valores específicos de cada hiperparámetro

3.3. RED NEURONAL CONVOLUCIONAL

optimizado se los reportará en el capítulo de resultados y discusión.

Entrenamiento y Prueba

De entre todas las piezas que se indican en la sección 3.1.1, se distribuyen los datos de adquisición en dos grupos, uno para entrenar la red y otro para ponerla a prueba. A continuación la distribución de piezas.

Piezas de entrenamiento	Piezas de prueba
Plano rectangular	Cilindro 12 mm
Plano rectangular (adquisición cercana)	Cilindro 12 mm (adquisición cercana)
Esfera	Cilindro 35 mm
Cilindro 25 mm (convexa)	Cilindro 40 (cóncava)
Cilindro 25 mm (cóncava)	–
Plano fibra de carbono	–

Tabla 3.2: Entrenamiento y prueba: distribución de piezas

La asignación de las piezas a cada conjunto se la realizó para obtener suficiente diversidad en ambos grupos. Evaluar al modelo en las piezas de prueba nos proporciona información del desempeño de la red con datos desconocidos para la misma. La evaluación busca asegurar que el modelo mantenga un bajo índice de error y de valores atípicos.

Capítulo 4

Resultados y Conclusiones

4.1. Resultados

4.1.1. Optimización de hiperparámetros

La cantidad de hiperparámetros a optimizar, implicó una amplio número de posibles configuraciones (superior a 1000). Las configuraciones con las que se probó el algoritmo *Hyperband* (un total de 237 posibilidades) se evaluaron en términos de las tres métricas propuestas, es decir, se buscó cuales minimizaban, por un lado, el error de índice (\mathbf{Idx}_{error}) y, por otro, la cantidad de desviaciones (o valores atípicos), generados. En base a estos valores, se representa una nube de puntos en la figura 4.1 donde se puede observar los resultados obtenidos por cada una de las configuraciones probadas en el algoritmo de hiperbúsqueda. Si ampliamos el enfoque y nos fijamos en la nube de puntos de modelos con mejor rendimiento (figura 4.1.b), es posible evidenciar un patrón evidente en los modelos, es decir, aquellos que generan un menor valor de error de índice (más eficientes en la detección de ecos), admitirán menor cantidad de valores atípicos. Las figuras muestran en su eje-*y* la suma total de valores atípicos (**val_n_out_1**: valores atípicos tipo 1; **val_n_out_2**: valores atípicos tipo 2), y en su eje-*x* el error de índice (**val_idx_error**: error de índice para datos de validación).

La exploración complementaria sobre los 5 mejores modelos (óvalo rojo en figura 4.1.b) se muestran en la figura 4.2. A pesar de que no se realiza ninguna variacion en cada modelo durante estos nuevos entrenamientos, la dispersión de su comportamiento se debe a la

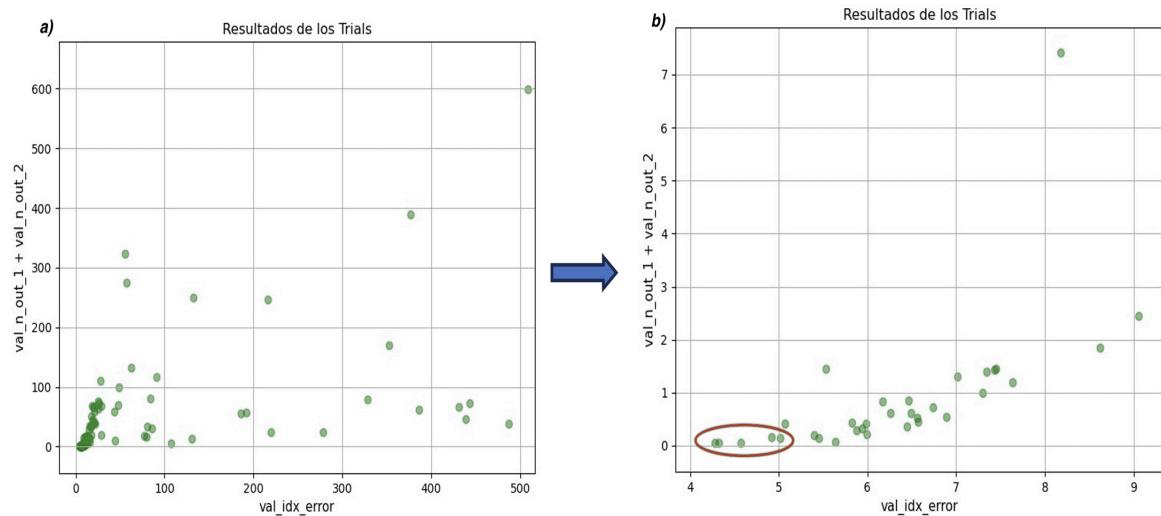


Figura 4.1: Exploración *Hyperband*: configuraciones de hiperparámetros

naturaleza estocástica del proceso de entrenamiento. De esta forma, se ha considerado

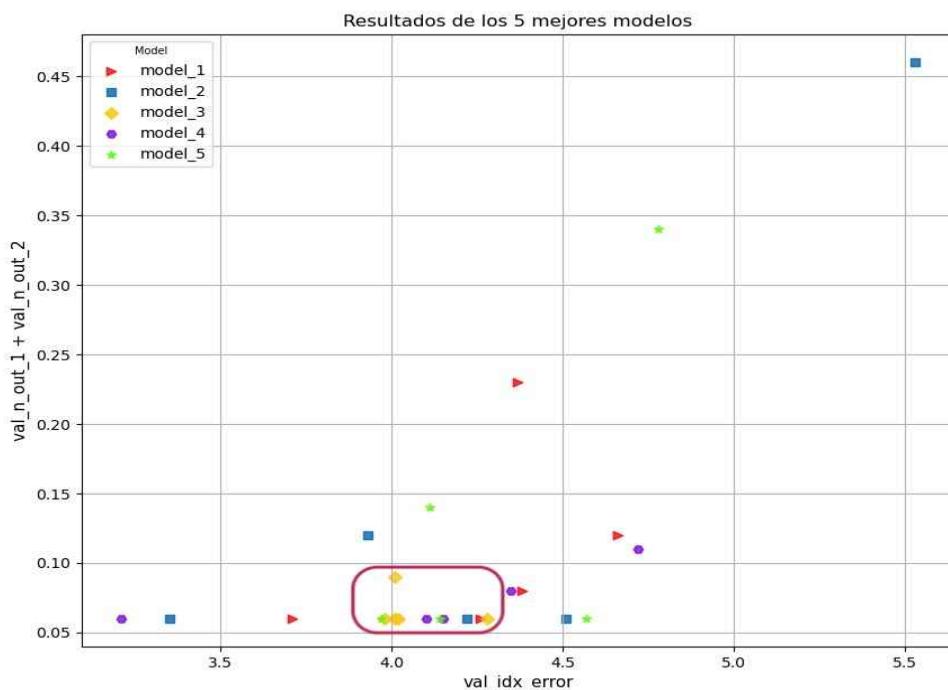


Figura 4.2: Optimización hiperparámetros: Exploración final

que el modelo más destacado ha sido aquel que, además de mostrar una aceptable reducción en sus métricas, también lo hace de la manera más estable posible. Este criterio llevó a seleccionar al modelo 3 como la configuración elegida para seguir evaluando su comportamiento para la detección de ecos de superficie (recuadro rojo en figura 4.2). Son

4.1. RESULTADOS

entonces sus hiperparámetros los que se aplican en las etapas subsecuentes. Dichos valores se muestran en la tabla 4.1.

Una vez determinada la configuración que define la arquitectura final de la red propuesta, se presenta, en la figura 4.3, el diagrama de su estructura.

Hiperparámetro	Valor Óptimo
Función de pérdida	Entropía cruzada binaria
Número de Bloques Convolucionales	2
Tamaño de Filtro (Kernel)	[3, 3, 12]
Número de Filtros	16
Tamaño de Pooling	[1, 1, 8]
Tasa de Aprendizaje	0.001

Tabla 4.1: Hiperparámetros Óptimos

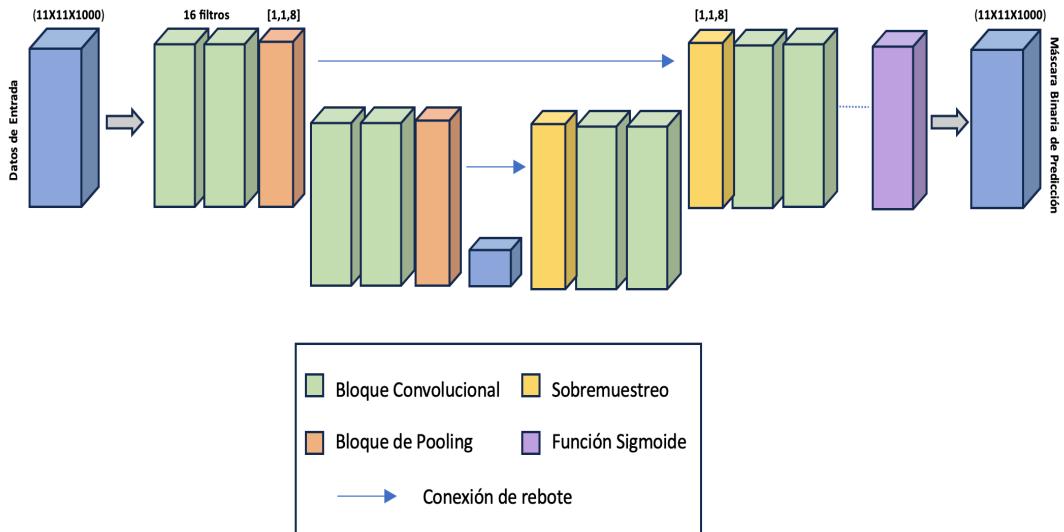


Figura 4.3: Esquema final de la red neuronal propuesta

4.1.2. Resultados de Prueba

En esta sección se discute la comparación de los métodos convencionales en detección de ecos de superficie con lo obtenido a partir de la arquitectura de red propuesta en este estudio. Se analiza el desempeño de la red en contraste con cada técnica considerada

individualmente. Se ha seleccionado un caso con cierta dificultad, donde la situación pone a prueba a cada técnica de detección y a la red, y se muestra el B-scan correspondiente, añadiendo el GT, y los índices de detección (**figuras a.**), y el resultado de segmentación del modelo (**figuras b.**). Se despliega una región agrandada en las (**figuras c.**). Para cada comparación se presenta también el A-scan asociado a un elemento donde se reconozca la presencia de valores atípicos, y se despliega la función al momento de detección (**figuras d.**). En las figuras el valor de índice actual indica el número de adquisición de cada adquisición de cada pieza de prueba.

Cruce de umbral vs Red

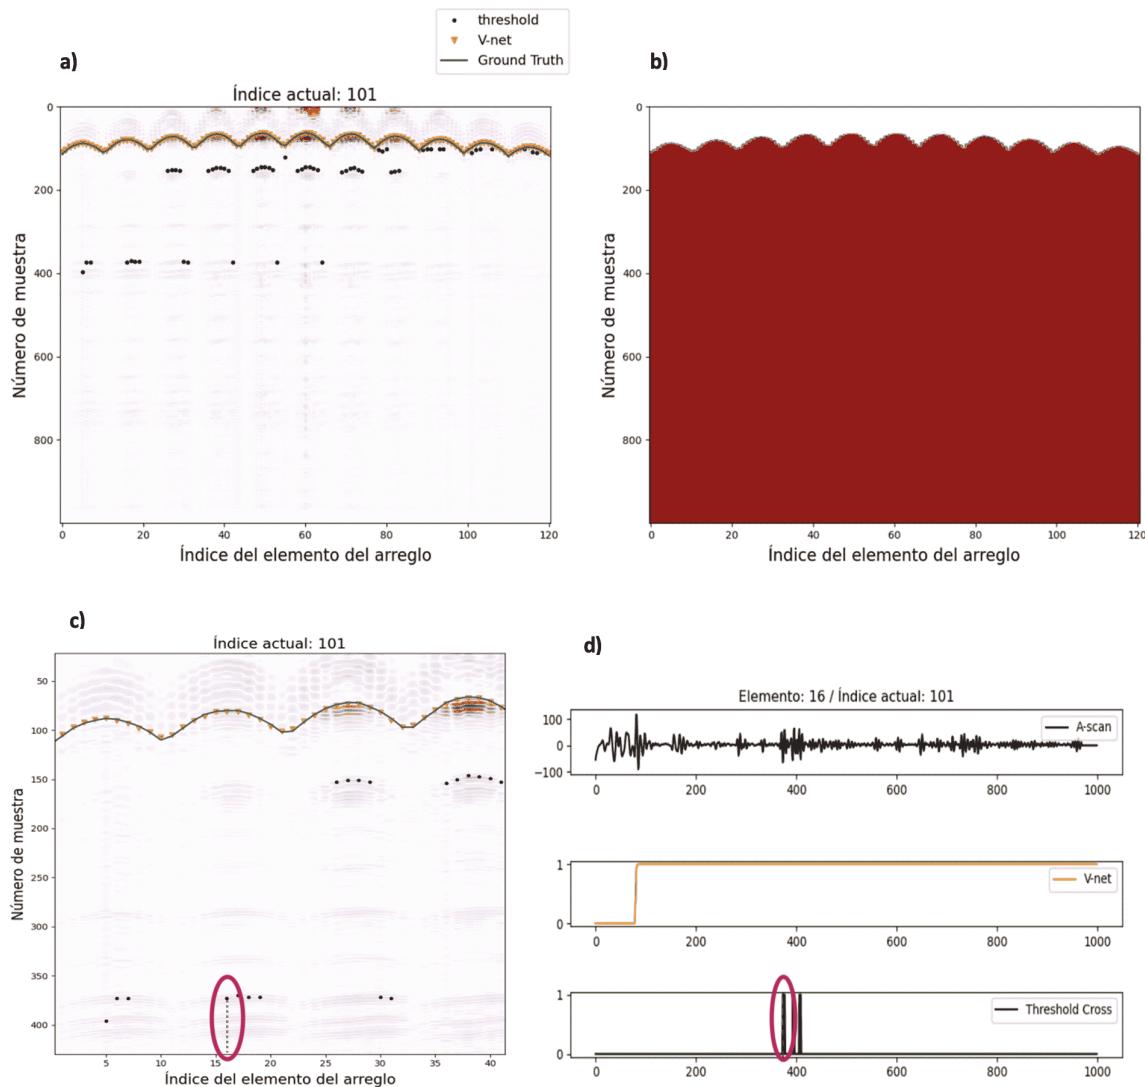


Figura 4.4: Comparación cruce de umbral vs Red propuesta

Se muestra en la figura 4.4: un caso en el que claramente la detección presenta fallos (valores atípicos) en los índices asociados (puntos negros) para el caso de cruce de umbral:

4.1. RESULTADOS

figura 4.4.a. En el ejemplo, el método utiliza un umbral de 50. Por otro lado, el desempeño del modelo es muy aceptable en términos de la segmentación obtenida (muy similar al los valores GT, figura 4.4.b), y los índices TDVs (puntos naranja) figura 4.4.c. El óvalo rojo indica un índice en particular donde se manifiesta un valor atípico de detección. Finalmente, la figura 4.4.d, nos indica el A-scan, la respuesta del modelo (línea naranja), y la detección basada en el cruce de umbral (línea negra). En este caso el método ha detectado un eco posterior al eco de superficie medido. La función asociada al modelo (función sigmoide) toma un valor de 1 al detectar el primer eco de llegada de superficie.

STA/LTA vs Red

Para la técnica STA/LTA, se indican resultados con dos distintas combinaciones de ventanas de larga (LTA) y corta duración (STA). La figura 4.5 indica la relación: [10,100]. El

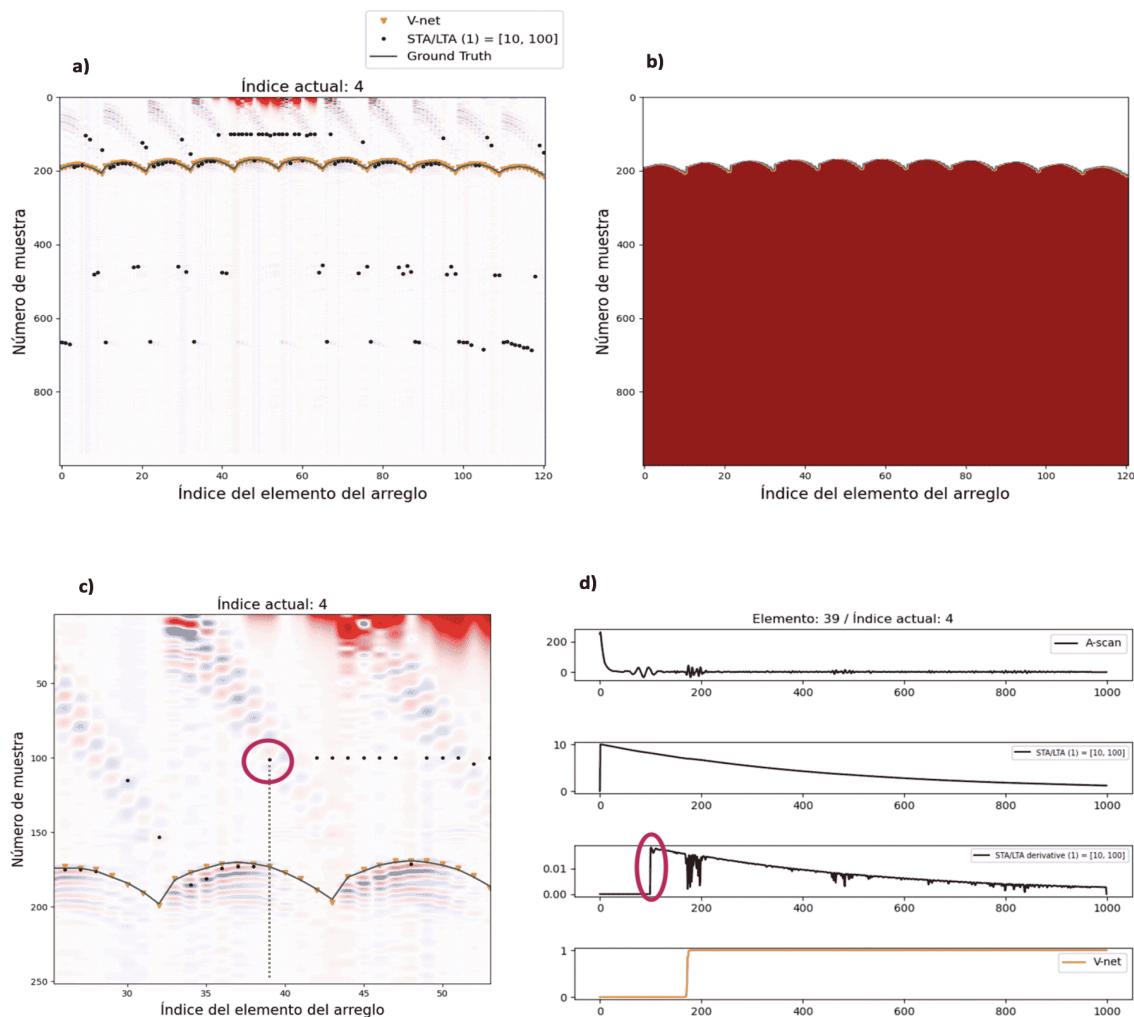


Figura 4.5: Comparación cruce de STA/LTA(10,100) vs Red propuesta

caso presentado indica alto contenido de valores atípicos para el método STA/LTA, mien-

tras que los índices TDVs a partir del modelo, concuerdan bien con la curva GT. El mapa de segmentación del modelo es consistente también a la máscara a partir del GT.

Para una selección de ventanas STA/LTA = [10,50] (figura 4.6), la presencia de valores atípicos es evidente. El modelo es consistente con la máscara GT, en los índices TDV y en el mapa de segmentación. La función de detección correspondiente (4.6.d), indica el punto de detección para el método STA/LTA (óvalo rojo), indicando la detección tardía. Por otro lado, la función de la red logra, una vez más, localizar correctamente el eco de superficie (curva naranja).

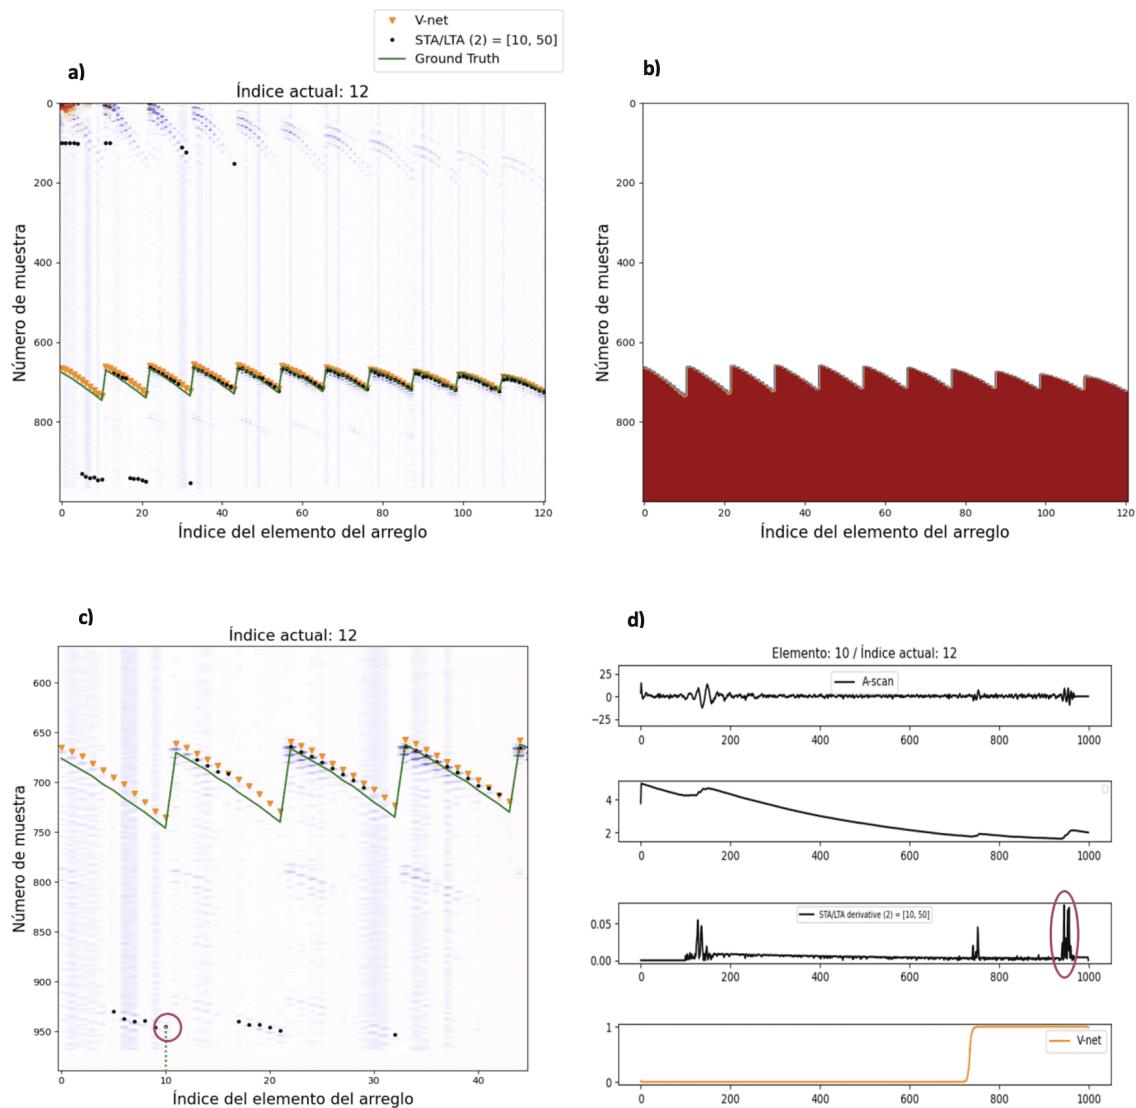


Figura 4.6: Comparación cruce de STA/LTA(10,50) vs Red propuesta

4.1. RESULTADOS

Filtro adaptado vs Red

El escenario nuevamente presenta un caso con valores atípicos para el método de filtro adaptado. Es necesario señalar que en la adquisición que se indica, la sección donde el filtro tiene problemas de detección es una región con poca energía de señal. Esto se puede distinguir en la ampliación de la región, i.e., figura 4.7.c. La figura 4.7.d muestra la detección imprecisa del filtro adaptado (óvalo rojo), y la detección correcta de la función del modelo, y esto se evidencia también en la coincidencia de la máscara de segmentación con la curva GT.

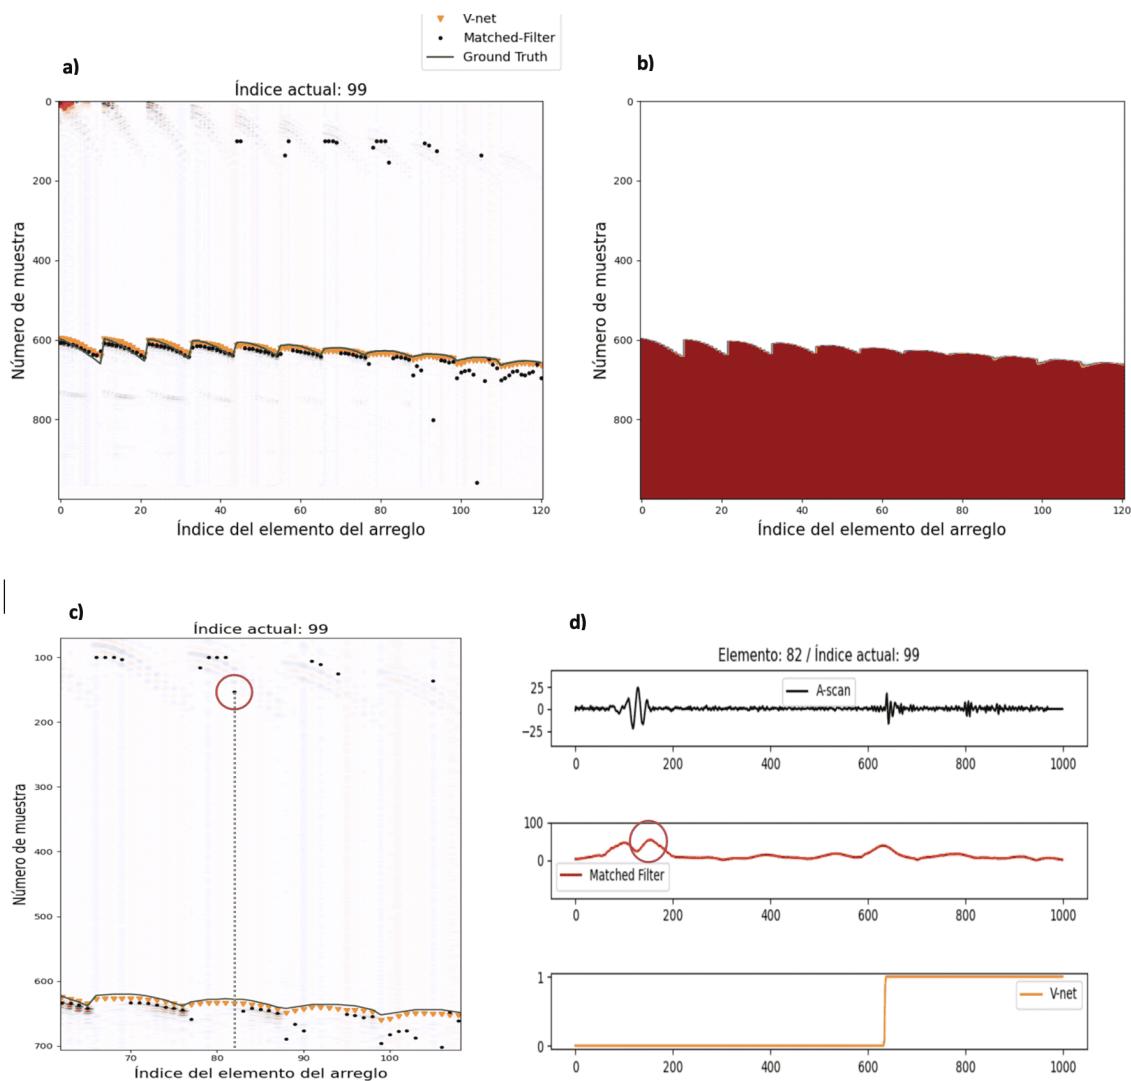


Figura 4.7: Comparación cruce de filtro adaptado vs red propuesta

Evaluación estadística de los resultados

Para evaluar la eficiencia de la red con respecto a los métodos más tradicionales de detección, se apela a la capacidad del modelo en reducir valores atípicos y el error de índice, descritos en la sección 3.3.1, ya que, a diferencia de las métricas generales de evaluación de redes neuronales (exactitud, precisión, coeficiente DICE, entre otros), estos criterios proveen una representación más adecuada para el problema que se desea resolver. Las figuras 4.8 y 4.9 muestran las estadísticas descriptivas.

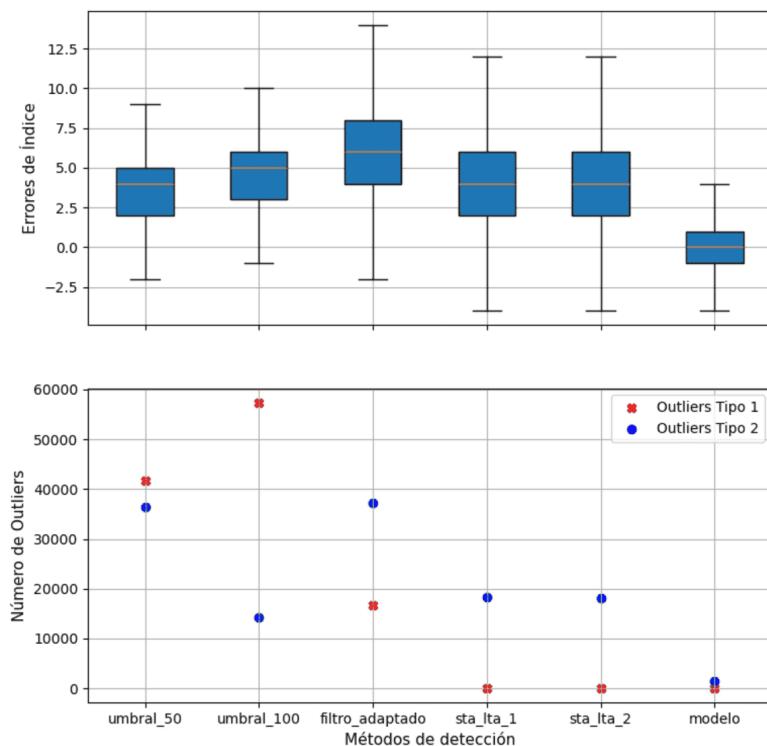


Figura 4.8: Resultados de estadística descriptiva: **a)** Diagramas de caja para error de índice. **b)** Cantidad de tipos de valores atípicos por método

La figura 4.8.a sugiere que, en términos de distribución de error de índice, el menos eficiente en la detección correcta de ecos de superficie, es el método de **filtro adaptado**. Su tendencia central de error (mediana) es la más alta de todas, aunque su rango de variabilidad de error (su rango intercuartil), es similar al resto de las técnicas convencionales, lo que indica una baja estabilidad en su comportamiento. Por otro lado, el buen desempeño y estabilidad de la RNC se refleja claramente en su baja tendencia central, y angosto rango de variación del error de índice.

La figura 4.8.b compara ambas categorías de valores atípicos. Teniendo en cuenta que el

4.1. RESULTADOS

valor atípico 1 cuantifica los ecos no detectados, y el valor atípico 2, aquellas instancias de falsos positivos, es decir, de detección no correspondientes a un eco de superficie (ecos “espurios”), los valores de tipo 2 son los más persistentes entre los métodos convencionales—con distinción del cruce de un umbral establecido en 100, donde los ecos no detectados predominan (lo que tiene sentido, ya que al incrementar el umbral a sobrepasar, menos ecos serán detectados). En contraste, de nuevo, el modelo de red neuronal, es muy eficiente en evitar este tipo de errores de detección mostrando valores significativamente menores que las técnicas convencionales evaluadas.

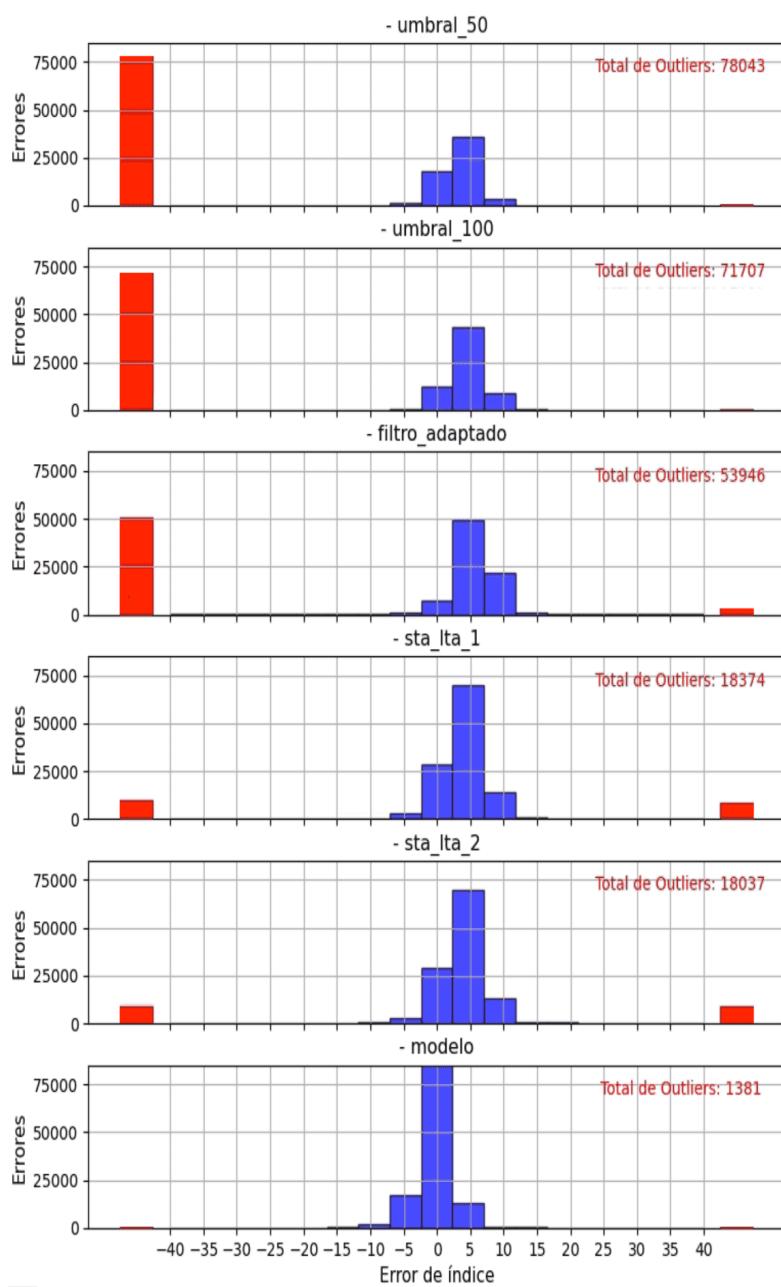


Figura 4.9: Histogramas de comparación

La figura 4.9 nos indica los siguiente: en comparación con las técnicas de detección evaluadas, el modelo presenta una baja variabilidad en su errores de índices calculados, con un alto valor representativo (aproximadamente 78000) centrado en 0. Los métodos convencionales muestran mayor varianza, con medias altas mayores que 0, lo cuál indica un error sistemático. Además, la suma total valores atípicos es significativamente menor para el modelo. Las métricas aplicadas indican, por lo tanto, una gran destreza del modelo en la detección de ecos de superficie. Valga notar, sin embargo, el desempeño del método STA/LTA al reducir valores atípicos, con respecto al resto de técnicas, ambos con distribuciones similares.

Para la evaluación estadística con la que se valida el desempeño de la red convolucional, se utilizó un conjunto de adquisiciones tomadas en piezas que diferían lo más posible de las piezas con las que se entrenó al modelo (ver tabla 4.1). Este criterio permite verificar que el modelo realmente ha aprendido a detectar las superficies de eco. El modelo fue entrenado con 6000 imágenes, de las cuales 1000 se usaron para el proceso de validación durante el entrenamiento. Estas 1000 imágenes de entrenamiento se las seleccionó aleatoriamente, y constituyen un subconjunto representativo del grupo de piezas de prueba, cantidad suficiente para confirmar la eficacia de la red.

4.2. Conclusiones y Discusión

4.2.1. Conclusiones

El propósito de este proyecto fue investigar el uso de una red neuronal convolucional adaptada para segmentación 3D, y entrenada con valores teóricos de tiempo de vuelo, para detectar ecos de superficie a partir de señales ultrasónicas adquiridas mediante la técnica FMC (*Full Matrix Capture*), abordando, a la vez, ciertas limitaciones en 3 métodos convencionales de detección: cruce de umbral, STA/LTA, y el método de filtro adaptado. La arquitectura de la red fue adaptada al problema, que se lo planteó como una tarea de segmentación volumétrica.

El método de detección de ecos basado en la red propuesta demostró una mejora significativa en la detección de ecos ultrasónicos, evidenciada por la reducción de valores atípicos

4.2. CONCLUSIONES Y DISCUSIÓN

($\approx 98\%$) y una mayor precisión en detección, en comparación con los métodos tradicionales. La red aprendió con éxito a identificar los ecos basándose en los datos teóricos de Tiempo de Vuelo, y mostró un rendimiento destacado en los casos de prueba, lo que indica su robustez y capacidad de generalización. Se desea hacer hincapié en que los valores teóricos de TDV se utilizaron para etiquetar el conjunto de datos de entrenamiento. Este proceso que, generalmente se realiza manualmente en el entrenamiento de redes profundas, fue automatizado en la etapa de adquisición, lo que contribuyó al rendimiento destacado del modelo.

Dados los resultados prometedores, como trabajo futuro, se sugiere explorar la aplicación de la red propuesta en geometrías más complejas, con el fin de evaluar si el entrenamiento en piezas de geometría simple impone limitaciones, o si el modelo puede generalizar eficazmente a escenarios más desafiantes. Si bien el conjunto de datos de entrenamiento y prueba fue adquirido utilizando geometrías relativamente simples—aunque representativas de piezas reales y comunes en aplicaciones de END—la capacidad de la red para abordar morfologías más complejas aún no ha sido explorada. Investigar esta capacidad de generalización permitiría ampliar el alcance del modelo y validar su aplicabilidad en piezas con formas más irregulares o variables que son comunes en la industria.

De igual manera, aunque la red propuesta ha demostrado desempeñarse de manera muy consistente, una dirección prometedora podría ser la integración de modelos híbridos, que combinen RNCs con redes neuronales recurrentes (RNR) o redes de memoria a corto plazo (LSTM), lo que podría permitir que el modelo capture dependencias temporales en la señal ultrasónica, mejorando potencialmente la precisión de la detección de eco en entornos dinámicos.

4.2.2. Discusión

En sismología aplicada las técnicas de detección consideradas en este proyecto se encuentran entre los esquemas más exitosos en tareas de localización de fuentes, en base a la detección del Tiempo de Arrivo (TDA). La técnica más simple consiste en un selector de umbral de amplitud, donde el TDA se determina cuando la señal cruza un valor de umbral predefinido. Sin embargo, señales de baja amplitud o con alto contenido de ruido implican

casos difíciles de manejar para la técnica [52]. Un enfoque generalizado que utiliza un umbral pre-establecido, que no se aplica a la señal cruda, es el llamado STA/LTA¹, que que detecta cambios repentinos en las señales, como la llegada de un eco o un evento sísmico, comparando dos promedios: STA, que representa los cambios o fluctuaciones recientes en la señal, y LTA, representa el nivel de base de la señal, nivel promedio sobre una ventana temporal amplia [10, 53]. De todas maneras, el método se ha visto, en ciertos casos, susceptible a la detección de falsos positivos [54]. En el contexto de localización microsísmica, la técnica de filtro adaptado es ampliamente utilizada, por ejemplo en [55, 56, 57].

La transición de este tipo de técnicas al campo de la evaluación no destructiva ha sido un avance significativo que aportó en la capacidad de detectar y caracterizar defectos en los materiales. Su adaptación en aplicaciones de END ha sido particularmente relevante porque las pruebas ultrasónicas comparten similitudes con la propagación de ondas sísmicas, ya que implican la transmisión y reflexión de ondas dentro de un medio. Al aplicar estas técnicas, los profesionales de END han podido mejorar, en cierto grado, la precisión en la detección de ecos para identificar fallas como grietas, huecos o inclusiones en materiales sin causar daños [52]. Sin embargo, cuando se aplican a señales ruidosas o complejas, estos métodos suelen enfrentar desafíos como la generación de valores atípicos y la precisión reducida de detección. Estas limitaciones forzaron a la comunidad de investigadores, tanto en sismología, como en END, a la exploración de métodos más robustos, lo que condujo a la aplicación de RNC [12, 58].

Nuestra arquitectura RNC personalizada demostró un rendimiento superior en la detección de ecos ultrasónicos en comparación con los métodos tradicionales. La red mostró una reducción significativa de los valores atípicos y mejoró la precisión de detección en varias configuraciones geométricas. Esta mejora se la puede atribuir a la capacidad del modelo de aprender y extraer características relevantes de los datos ultrasónicos sin procesar, una tarea con la que los métodos convencionales tienen dificultades, especialmente en entornos ruidosos.

Con los resultados obtenidos ha sido posible entonces validar la aplicación de una red neuronal convolucional adaptada a datos ultrasónicos para la correcta detección de ecos de

¹STA: Short Term Average, LTA: Long Term Average

4.2. CONCLUSIONES Y DISCUSIÓN

superficie para un conjunto de geometrías representativas de piezas comunes en inspección END. Se considera esto como un aporte significativo al campo de evaluación ultrasónica que no busca reemplazar en su totalidad la intervención del técnico y su conocimiento acumulado por años de experiencia, sino encaminar las técnicas END a un sistema de trabajo que automatize y acelere aquellos aspectos que suelen ser más propensos a error de interpretación humana y que suelen requerir de tiempo considerable para su ejecución. Adicionalmente, teniendo en cuenta que los métodos basados en aprendizaje profundo requieren un conjunto de datos de entrenamiento, el cual debe estar etiquetado, la precisión de las etiquetas es crucial para el entrenamiento. Sin embargo, el proceso suele ser manual y por lo tanto muy trabajoso para los conjuntos de datos de gran volumen necesarios para un buen entrenamiento de la red. Por esta razón la etapa de etiquetado automático propuesto en este estudio es de gran relevancia en el desempeño eficaz y consistente de la arquitectura RNC planteada.

Por último, señalando ciertas limitaciones del proyecto, se debe notar que, a pesar de las mejoras que ofrece la arquitectura RNC propuesta, el modelo se entrenó y validó en geometrías relativamente simples. Esto puede limitar su capacidad de generalización a formas irregulares más complejas que suelen encontrarse en aplicaciones END de la industria real. Además, la complejidad computacional de las RNCs requiere una consideración cuidadosa, en particular cuando se amplía a conjuntos de datos más grandes o arquitecturas más intrincadas. Para lo considerado en este trabajo los requerimientos computacionales ya fueron exigentes, siendo necesario apelar a recursos de hardware significativos, en este caso a una estrategia de distribución de entrenamiento a dos unidades de procesamiento gráfico, UPGs, que indica a *TensorFlow* reflejar el modelo en cada dispositivo y sincronizar gradientes después de cada lote, lo que permite un entrenamiento paralelo y eficiente. No obstante, conjuntos de datos más amplios podría ralentizar incluso dicho enfoque. Otro potencial inconveniente que se cree apropiado mencionar en la integración de aprendizaje profundo en aplicaciones END es que, después de todo, se puede presentar cierta limitación en términos de interpretación clara de sus resultados, dada la naturaleza de “caja negra” de una RNC. Para compensar este tipo de inconveniente se podría, por ejemplo, sugerir técnicas de visualización de características, que proveen mecanismos para entender en cierta medida las “razones” de sus predicciones, como se propone en [59, 60].

Aún hay mucho por avanzar con respecto a técnicas END, ya que incluso los sistemas phased array son relativamente actuales, y el uso de aprendizaje profundo en conjunto con este tipo de transductores es un enfoque muy prometedor en el campo.

Bibliografía

- [1] P. D. Wilcox, C. Holmes, and B. W. Drinkwater, “Advanced reflector characterization with ultrasonic phased arrays in nde applications,” *IEEE transactions on ultrasonics, ferroelectrics, and frequency control*, vol. 54, no. 8, pp. 1541–1550, 2007.
- [2] M. Li and G. Hayward, “Ultrasound nondestructive evaluation (nde) imaging with transducer arrays and adaptive processing,” *Sensors*, vol. 12, no. 1, pp. 42–54, 2011.
- [3] H. Shi, M. Ebrahimi, P. Zhou, K. Shao, and J. Li, “Ultrasonic and phased-array inspection in titanium-based alloys: A review,” *Proceedings of the Institution of Mechanical Engineers, Part E: Journal of Process Mechanical Engineering*, vol. 237, no. 2, pp. 511–530, 2023.
- [4] J. Krautkrämer and H. Krautkrämer, *Ultrasonic testing of materials*. Springer Science & Business Media, 2013.
- [5] J. Camacho, J. F. Cruza, J. Brizuela, and C. Fritsch, “Automatic dynamic depth focusing for ndt,” *IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control*, vol. 61, no. 4, pp. 673–684, 2014.
- [6] G. Cosarinsky, J. Cruza, M. Muñoz, and J. Camacho, “Optimized auto-focusing method for 3d ultrasound imaging in ndt,” *NDT & E International*, vol. 134, p. 102779, 2023.
- [7] A. J. Hunter, B. W. Drinkwater, and P. D. Wilcox, “Autofocusing ultrasonic imagery for non-destructive testing and evaluation of specimens with complicated geometries,” *Ndt & E International*, vol. 43, no. 2, pp. 78–85, 2010.
- [8] Q.-S. Chen, *Matched filtering techniques*. Cambridge University Press, 2011, pp. 112–130.

- [9] X. Qu, G. Yan, D. Zheng, S. Fan, Q. Rao, and J. Jiang, “A deep learning-based automatic first-arrival picking method for ultrasound sound-speed tomography,” *IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control*, vol. 68, no. 8, pp. 2675–2686, 2021.
- [10] A. Trnkoczy, “Understanding and parameter setting of sta/lta trigger algorithm,” in *New manual of seismological observatory practice (NMSOP)*. Deutsches GeoForschungsZentrum GFZ, 2009, pp. 1–20.
- [11] M. Withers, R. Aster, C. Young, J. Beiriger, M. Harris, S. Moore, and J. Trujillo, “A comparison of select trigger algorithms for automated global seismic phase and event detection,” *Bulletin of the Seismological Society of America*, vol. 88, no. 1, pp. 95–106, 1998.
- [12] P. Yuan, S. Wang, W. Hu, X. Wu, J. Chen, and H. Van Nguyen, “A robust first-arrival picking workflow using convolutional and recurrent neural networks,” *Geophysics*, vol. 85, no. 5, pp. U109–U119, 2020.
- [13] L. Hu, X. Zheng, and Y. Duan, “U-net convolutional networks for first arrival picking,” in *SEG 2018 Workshop: SEG Maximizing Asset Value Through Artificial Intelligence and Machine Learning, Beijing, China, 17-19 September 2018*. Society of Exploration Geophysicists and the Chinese Geophysical Society, 2018, pp. 15–18.
- [14] C. Hellier *et al.*, “Handbook of nondestructive evaluation,” Mcgraw-hill, Tech. Rep., 2003.
- [15] P. J. Shull, *Nondestructive evaluation: theory, techniques, and applications*. CRC press, 2002.
- [16] C. Maierhofer, H.-W. Reinhardt, and G. Dobmann, *Non-destructive evaluation of reinforced concrete structures: Non-destructive testing methods*. Elsevier, 2010.
- [17] M. Coramik and Y. Ege, “Discontinuity inspection in pipelines: A comparison review,” *Measurement*, vol. 111, pp. 359–373, 2017.
- [18] J. Jodhani, A. Handa, A. Gautam, R. Rana *et al.*, “Ultrasonic non-destructive evaluation of composites: A review,” *Materials Today: Proceedings*, vol. 78, pp. 627–632, 2023.

- [19] F. Aymerich and S. Meili, “Ultrasonic evaluation of matrix damage in impacted composite laminates,” *Composites Part B: Engineering*, vol. 31, no. 1, pp. 1–6, 2000.
- [20] S. Bansal, A. Saraf, R. Rana, and R. Lal, “Effect of picosecond laser texture surface on tribological properties on high-chromium steel under non-lubricated conditions,” in *Advances in Manufacturing and Industrial Engineering*, R. M. Singari, K. Mathiyazhagan, and H. Kumar, Eds. Singapore: Springer Nature Singapore, 2021, pp. 257–267.
- [21] J. C. Aldrin, J. N. Wertz, J. T. Welter, S. Wallentine, E. A. Lindgren, V. Kramb, and D. Zainey, “Fundamentals of angled-beam ultrasonic nde for potential characterization of hidden regions of impact damage in composites,” in *AIP conference proceedings*, vol. 1949, no. 1. AIP Publishing, 2018.
- [22] S. Doctor, T. Hall, and L. Reid, “Saft — the evolution of a signal processing technology for ultrasonic testing,” *NDT International*, vol. 19, no. 3, pp. 163–167, 1986. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/0308912686901057>
- [23] K. Yadav, S. Yadav, and P. Dubey, “A comparative study of ultrasonic contact and immersion method for dimensional measurements,” *MAPAN*, vol. 36, no. 2, pp. 319–324, 2021.
- [24] L. W. Schmmer Jr, “Fundamentals of ultrasonic phased arrays,” *Modern Physics Letters B*, vol. 22, no. 11, pp. 917–921, 2008.
- [25] M. Moles, C. Bird, P. Herzog, T. Armitt, P. Ciorau, R. Roberts, and M. Davis, “Introduction to phased array ultrasonic technology applications: Olympus guideline,” *Olympus: Waltham, MA, USA*, 2017.
- [26] H. N. . E. Inc., “Ultrasonic A/B/C-scans,” https://www.youtube.com/watch?v=7_gUYKqVrN4, Feb. 2023.
- [27] G. G. Cosarinsky Markman *et al.*, “Auto-focusing in three-dimensional ultrasound imaging,” Ph.D. dissertation, Universidad de Alcalá de Henares, 2024.
- [28] C. Holmes, B. W. Drinkwater, and P. D. Wilcox, “Post-processing of the full matrix

- of ultrasonic transmit–receive array data for non-destructive evaluation,” *NDT & e International*, vol. 38, no. 8, pp. 701–711, 2005.
- [29] G. Montaldo, M. Tanter, J. Bercoff, N. Benech, and M. Fink, “Coherent plane-wave compounding for very high frame rate ultrasonography and transient elastography,” *IEEE transactions on ultrasonics, ferroelectrics, and frequency control*, vol. 56, no. 3, pp. 489–506, 2009.
- [30] H. Sun, P. Ramuhalli, and R. E. Jacob, “Machine learning for ultrasonic nondestructive examination of welding defects: A systematic review,” *Ultrasonics*, vol. 127, p. 106854, 2023.
- [31] S. Cantero-Chinchilla, P. D. Wilcox, and A. J. Croxford, “Deep learning in automated ultrasonic nde—developments, axioms and opportunities,” *NDT & E International*, vol. 131, p. 102703, 2022.
- [32] K. Virupakshappa and E. Oruklu, “Unsupervised machine learning for ultrasonic flaw detection using gaussian mixture modeling, k-means clustering and mean shift clustering,” in *2019 IEEE International Ultrasonics Symposium (IUS)*. IEEE, 2019, pp. 647–649.
- [33] A. Al-Ataby, W. Al-Nuaimy, C. Brett, and O. Zahran, “Automatic detection and classification of weld flaws in tofd data using wavelet transform and support vector machines,” *Insight-Non-Destructive Testing and Condition Monitoring*, vol. 52, no. 11, pp. 597–602, 2010.
- [34] Ó. Martín, M. Pereda, J. I. Santos, and J. M. Galán, “Assessment of resistance spot welding quality based on ultrasonic testing and tree-based techniques,” *Journal of Materials Processing Technology*, vol. 214, no. 11, pp. 2478–2487, 2014.
- [35] I. Goodfellow, *Deep Learning*. MIT Press, 2016.
- [36] S. Saha, “A Comprehensive Guide to Convolutional Neural Networks — the ELI5 way,” <https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53>, Dec. 2018.
- [37] F. Chollet, *Deep learning with Python*. Simon and Schuster, 2021.

- [38] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” in *2016 fourth international conference on 3D vision (3DV)*. Ieee, 2016, pp. 565–571.
- [39] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18*. Springer, 2015, pp. 234–241.
- [40] F. Milletari, S.-A. Ahmadi, C. Kroll, A. Plate, V. Rozanski, J. Maiostre, J. Levin, O. Dietrich, B. Ertl-Wagner, K. Bötzel *et al.*, “Hough-cnn: Deep learning for segmentation of deep brain regions in mri and ultrasound,” *Computer Vision and Image Understanding*, vol. 164, pp. 92–102, 2017.
- [41] J. Long, E. Shelhamer, and T. Darrell, “Fully convolutional networks for semantic segmentation,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 3431–3440.
- [42] Dasel S.L., *Technical Datasheet SITAU MX / FP*, May. 2015.
- [43] Universal Robots, *Universal Robots e-Series User Manual*, Feb. 2022.
- [44] TensorFlow, “Plataforma de extremo a extremo enfocada en el aprendizaje automático,” <https://www.tensorflow.org/>, Nov. 2015.
- [45] Q. Technologies, “The future is written with Qt,” <https://doc.qt.io/>, Dec. 2014.
- [46] G. Cosarinsky, J. F. Cruza, M. Muñoz, and J. Camacho, “Automatic estimation of surface and probe location for 3d imaging with bidimensional arrays,” *NDT & E International*, vol. 141, p. 102990, 2024.
- [47] M. Yi-de, L. Qing, and Q. Zhi-Bai, “Automated image segmentation using improved pcnn model based on cross-entropy,” in *Proceedings of 2004 International Symposium on Intelligent Multimedia, Video and Speech Processing, 2004*. IEEE, 2004, pp. 743–746.
- [48] S. S. M. Salehi, D. Erdoganmus, and A. Gholipour, “Tversky loss function for image segmentation using 3d fully convolutional deep networks,” in *International workshop on machine learning in medical imaging*. Springer, 2017, pp. 379–387.

BIBLIOGRAFÍA

- [49] C. H. Sudre, W. Li, T. Vercauteren, S. Ourselin, and M. Jorge Cardoso, “Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations,” in *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: Third International Workshop, DLMIA 2017, and 7th International Workshop, ML-CDS 2017, Held in Conjunction with MICCAI 2017, Québec City, QC, Canada, September 14, Proceedings 3.* Springer, 2017, pp. 240–248.
- [50] L. Li, K. Jamieson, G. DeSalvo, A. Rostamizadeh, and A. Talwalkar, “Hyperband: A novel bandit-based approach to hyperparameter optimization,” *Journal of Machine Learning Research*, vol. 18, no. 185, pp. 1–52, 2018.
- [51] A. Nebro, E. Alba, and F. Luna, “Optimización multiobjetivo y computación grid,” in *A aparecer en Actas del Tercer Congreso Español de Metaheurísticas, Algoritmos Evolutivos y Bioinspirados, Córdoba, España*, 2003.
- [52] J. H. Kurz, C. U. Grosse, and H.-W. Reinhardt, “Strategies for reliable automatic onset time picking of acoustic emissions and of ultrasound signals in concrete,” *Ultrasonics*, vol. 43, no. 7, pp. 538–546, 2005.
- [53] L. QIU and C. LI, “Sta/lta method for picking up the first arrival of natural seismic waves and its improvement analysis,” *Progress in Geophysics*, vol. 38, no. 4, pp. 1497–1506, 2023.
- [54] J. P. Jones and M. van der Baan, “Adaptive sta-lta with outlier statistics,” *Bulletin of the Seismological Society of America*, vol. 105, no. 3, pp. 1606–1618, 2015.
- [55] S. J. Gibbons and F. Ringdal, “The detection of low magnitude seismic events using array-based waveform correlation,” *Geophysical Journal International*, vol. 165, no. 1, pp. 149–166, 2006.
- [56] D. R. Shelly, “A high-resolution seismic catalog for the initial 2019 ridgecrest earthquake sequence: Foreshocks, aftershocks, and faulting complexity,” *Seismological Research Letters*, vol. 91, no. 4, pp. 1971–1978, 2020.
- [57] Z. Peng and P. Zhao, “Migration of early aftershocks following the 2004 parkfield earthquake,” *Nature Geoscience*, vol. 2, no. 12, pp. 877–881, 2009.
- [58] R. J. Pyle, R. L. Bevan, R. R. Hughes, R. K. Rachev, A. A. S. Ali, and P. D. Wilcox,

- “Deep learning for ultrasonic crack characterization in nde,” *IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control*, vol. 68, no. 5, pp. 1854–1865, 2020.
- [59] Q. Zhang, Y. N. Wu, and S.-C. Zhu, “Interpretable convolutional neural networks,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 8827–8836.
- [60] C. Olah, A. Mordvintsev, and L. Schubert, “Feature visualization,” *Distill*, vol. 2, no. 11, p. e7, 2017.